



adot

Cours MS BGD : Spark

12 Septembre 2019

Nicolas Cosson
Florent Moiny



Présentation générale

Adot

Qui sommes-nous ?

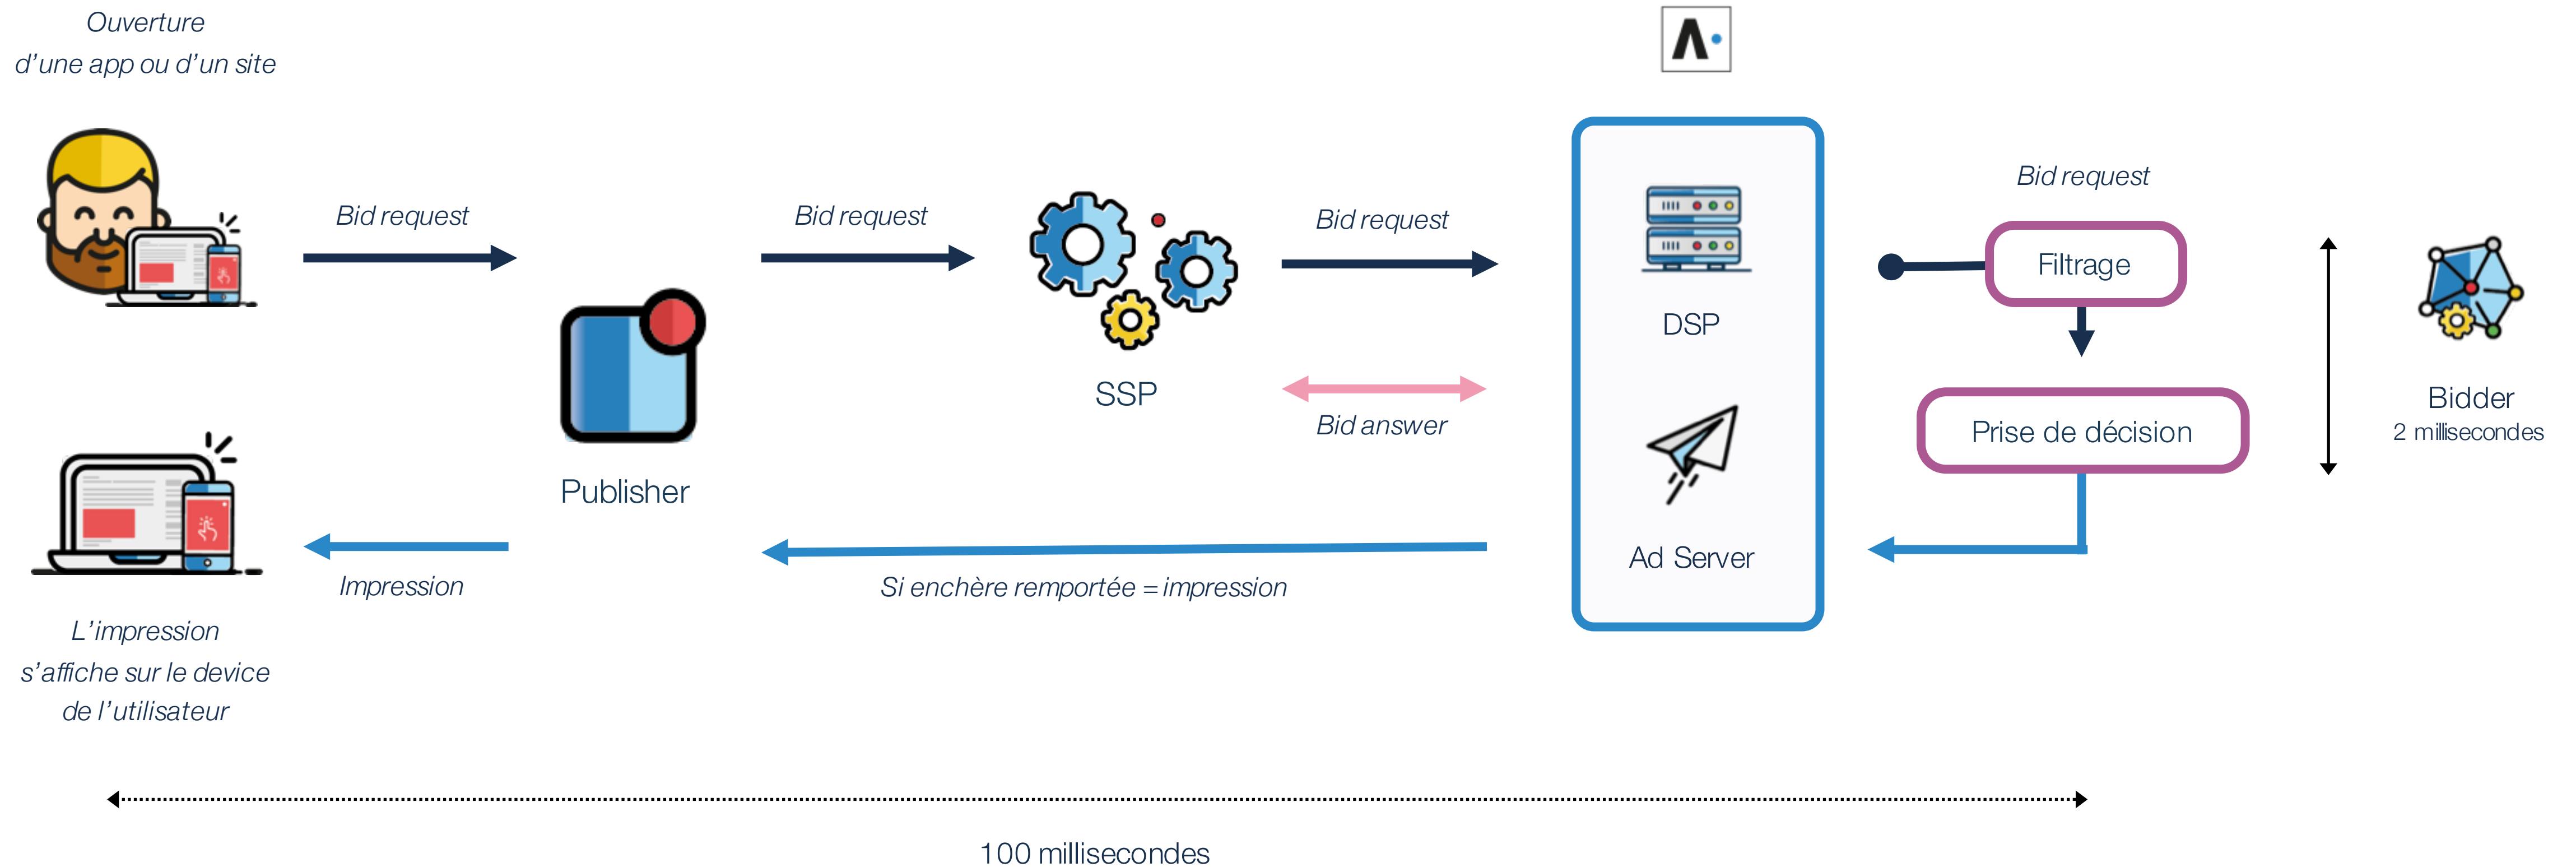
- Fondée en 2014
- Publicité ciblée achetée en RTB
- Présent à Paris, Londres, Milan, Madrid
- Toujours une forte croissance en 2019
- Investissements de 1M€ en 2015 puis 10M€ en 2016
- 110 employés dont 40 dans l'équipe technique

Quelques chiffres

- Enjeux :
 - Environ 15 To de données brutes par jour (en Europe)
 - Environ 15 milliards de requêtes par jour (en Europe)
 - Pics à 200 000 requêtes par seconde
 - Nombreuses sources de données à intégrer
- Infrastructure :
 - 100% sur AWS
 - Entre 350 et 600 serveurs
 - Temps de réponse inférieurs à 100ms
 - Déployée dans le monde entier (3 régions actuellement)

Fonctionnement du RTB

Généralités



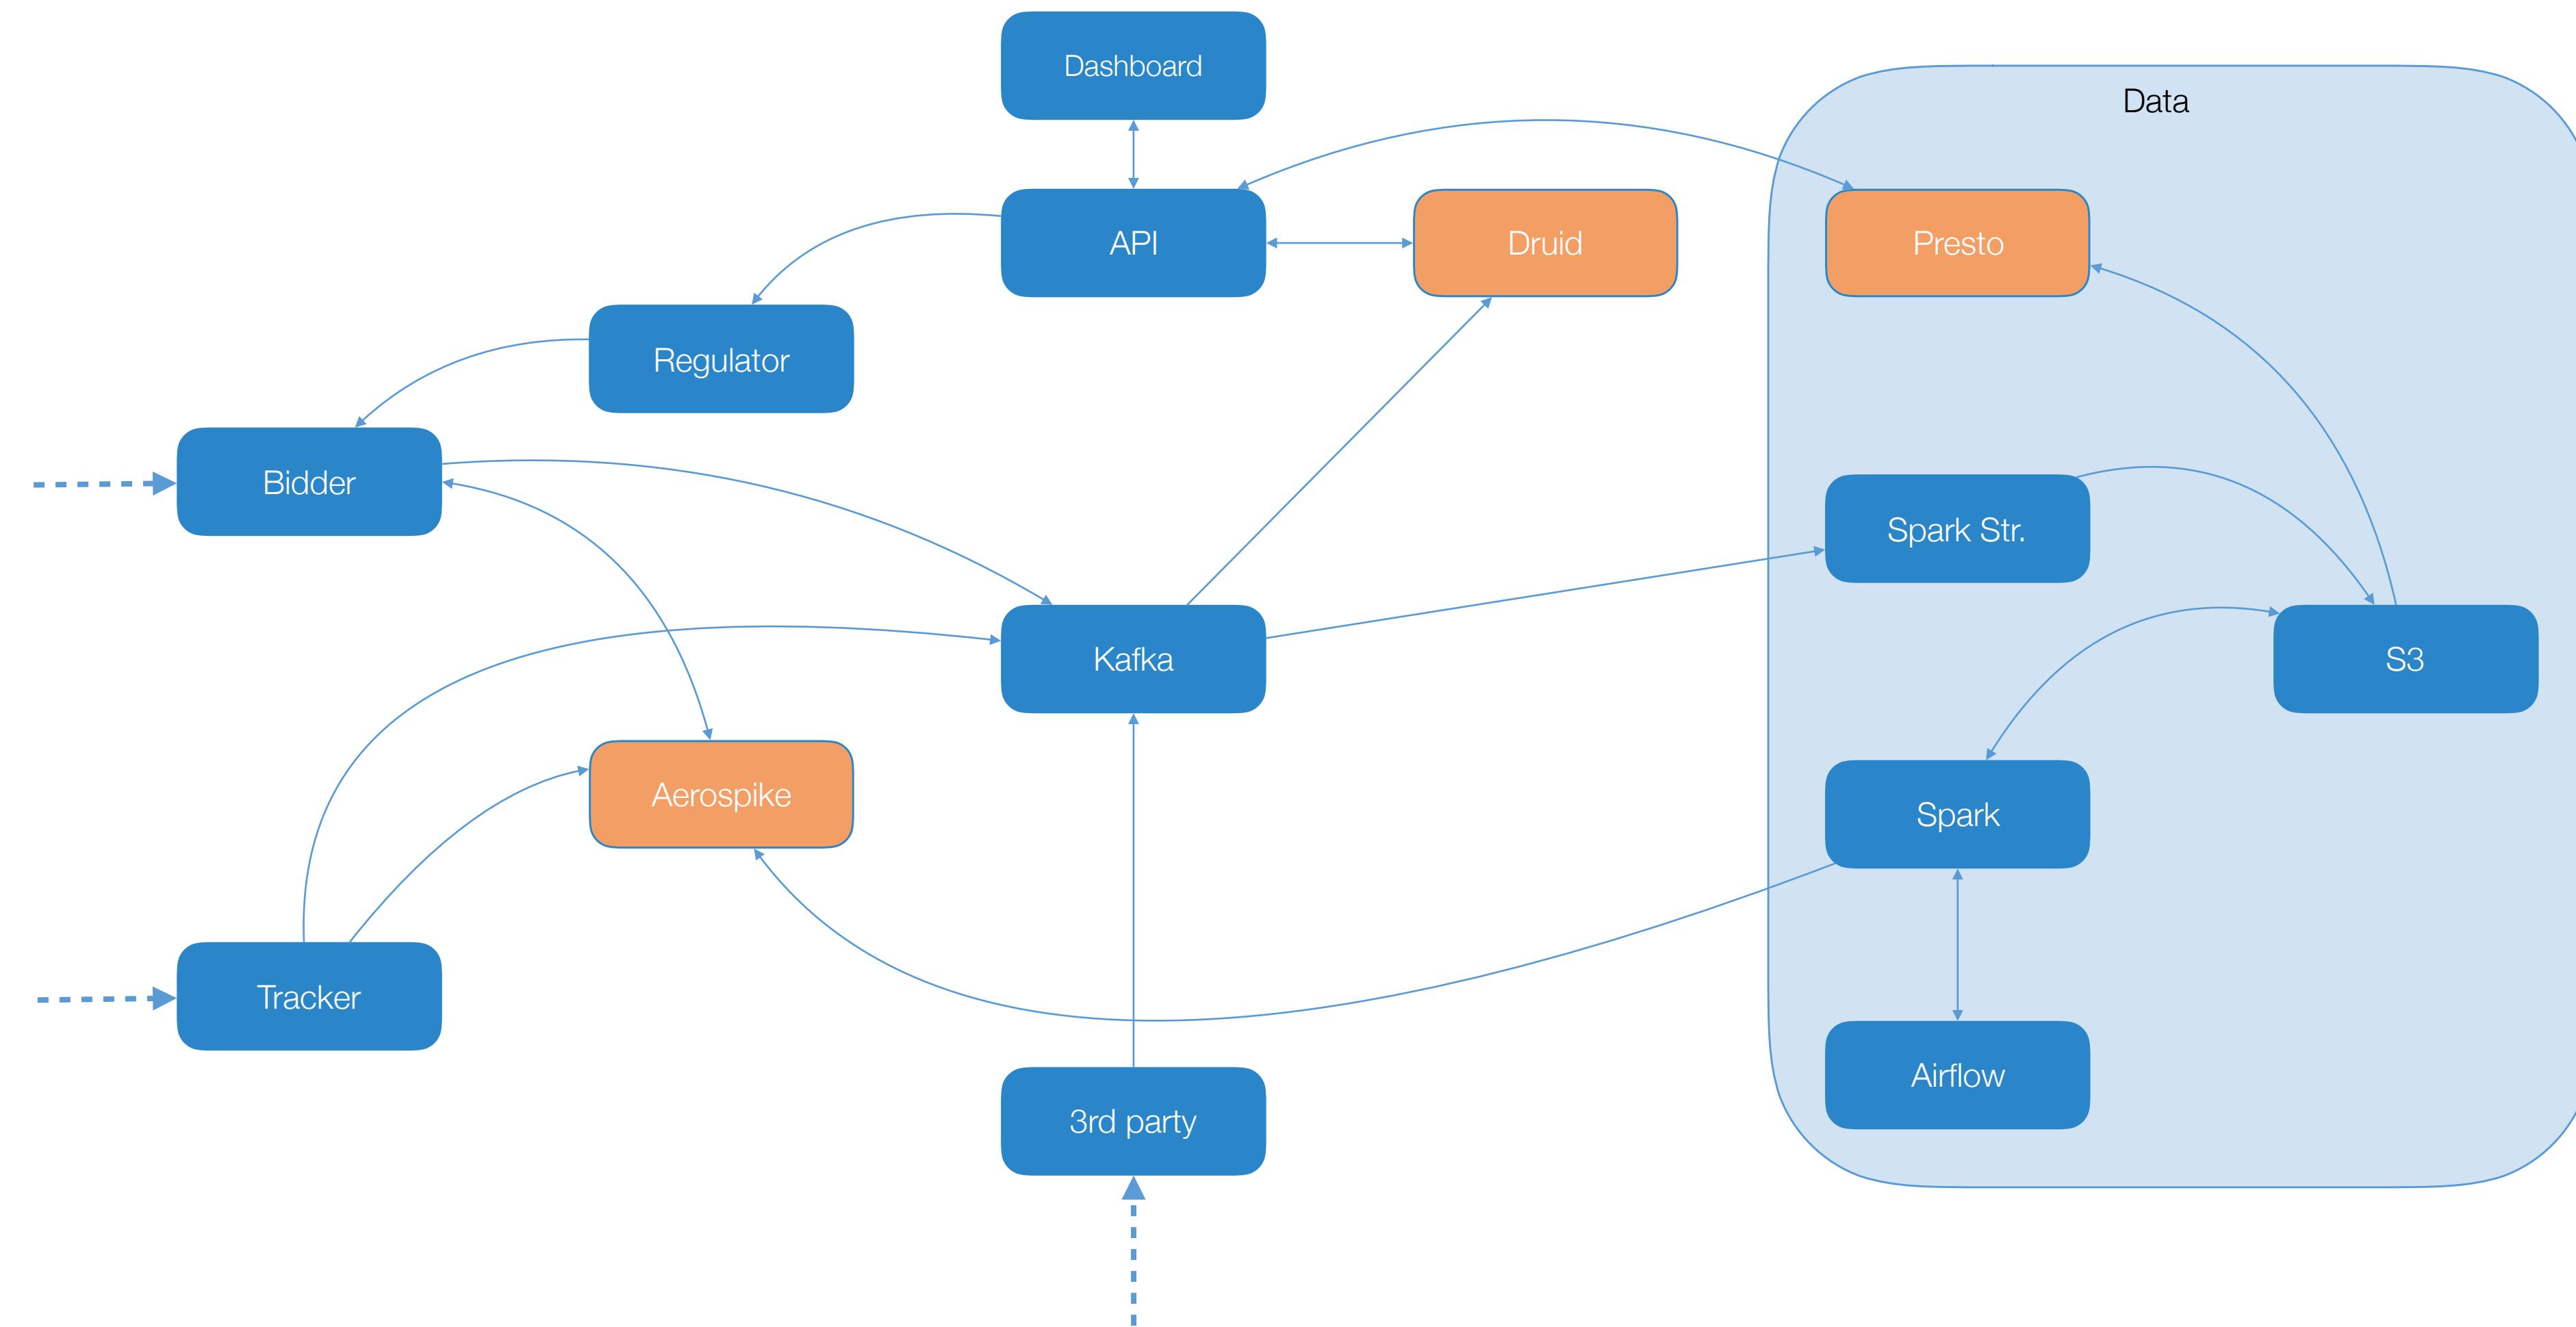
Stack technologique

Généralités



Infrastructure type

Généralités



Apache Spark

Programme du cours

Cours :

- Généralités sur les Systèmes distribués et l'écosystème Big Data
- Généralités sur Spark
- Composants de Spark :
 - Librairies
 - APIs
- Infrastructure de Spark :
 - Ecosystème
 - Cluster
 - Fault-Tolerance
- Spark Internals :
 - RDDs
 - Partitionnement
 - Actions/Transformations
 - Shuffling
 - Persistence

TP : introduction à Spark puis projet guidé (prédition de succès de projets Kickstarter) :

- Introduction
 - Prise en main à l'aide d'un Spark shell
 - Prise en main d'IntelliJ et lancement d'un premier job
- Projet
 - Récupération de données brutes
 - Traitement et formatage des données
 - Optimisation du script
 - Entraînement d'un algorithme de prédition
 - Sauvegarde d'un modèle

Évaluation :

- ▶ QCM sur le cours
- ▶ Projet de TP

Qu'est-ce que Spark ?

Généralités

Selon Wikipédia :

“Apache Spark is an open-source distributed general-purpose cluster-computing framework.

Spark provides an interface for programming entire clusters with implicit data parallelism and fault tolerance.”

Qu'est-ce que Spark ?

Généralités

Selon Wikipédia :

“Apache Spark is an open-source distributed general-purpose cluster-computing framework.

Spark provides an interface for programming entire clusters with implicit data parallelism and fault tolerance.”

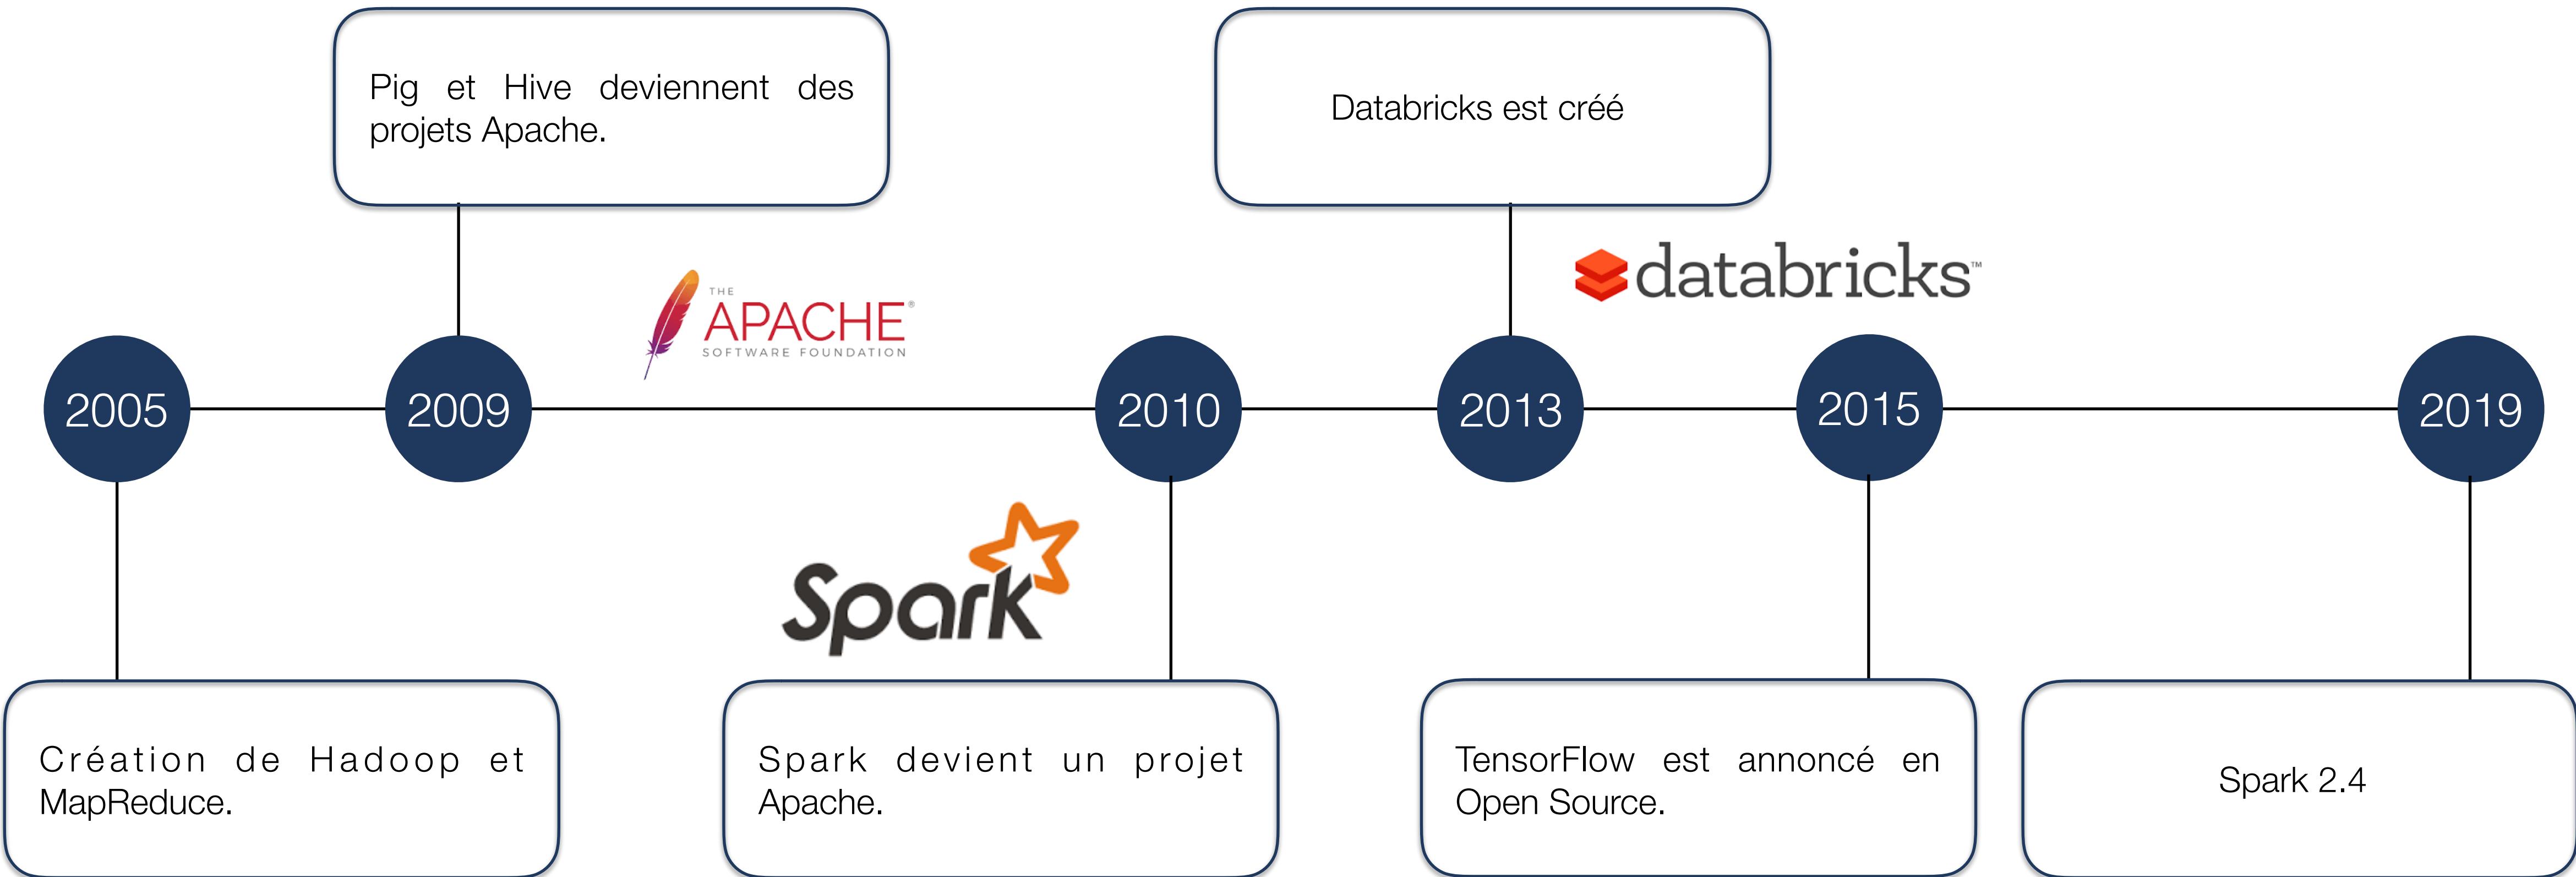
Meaning ?

1

Ecosystème

Historique

Ecosystème



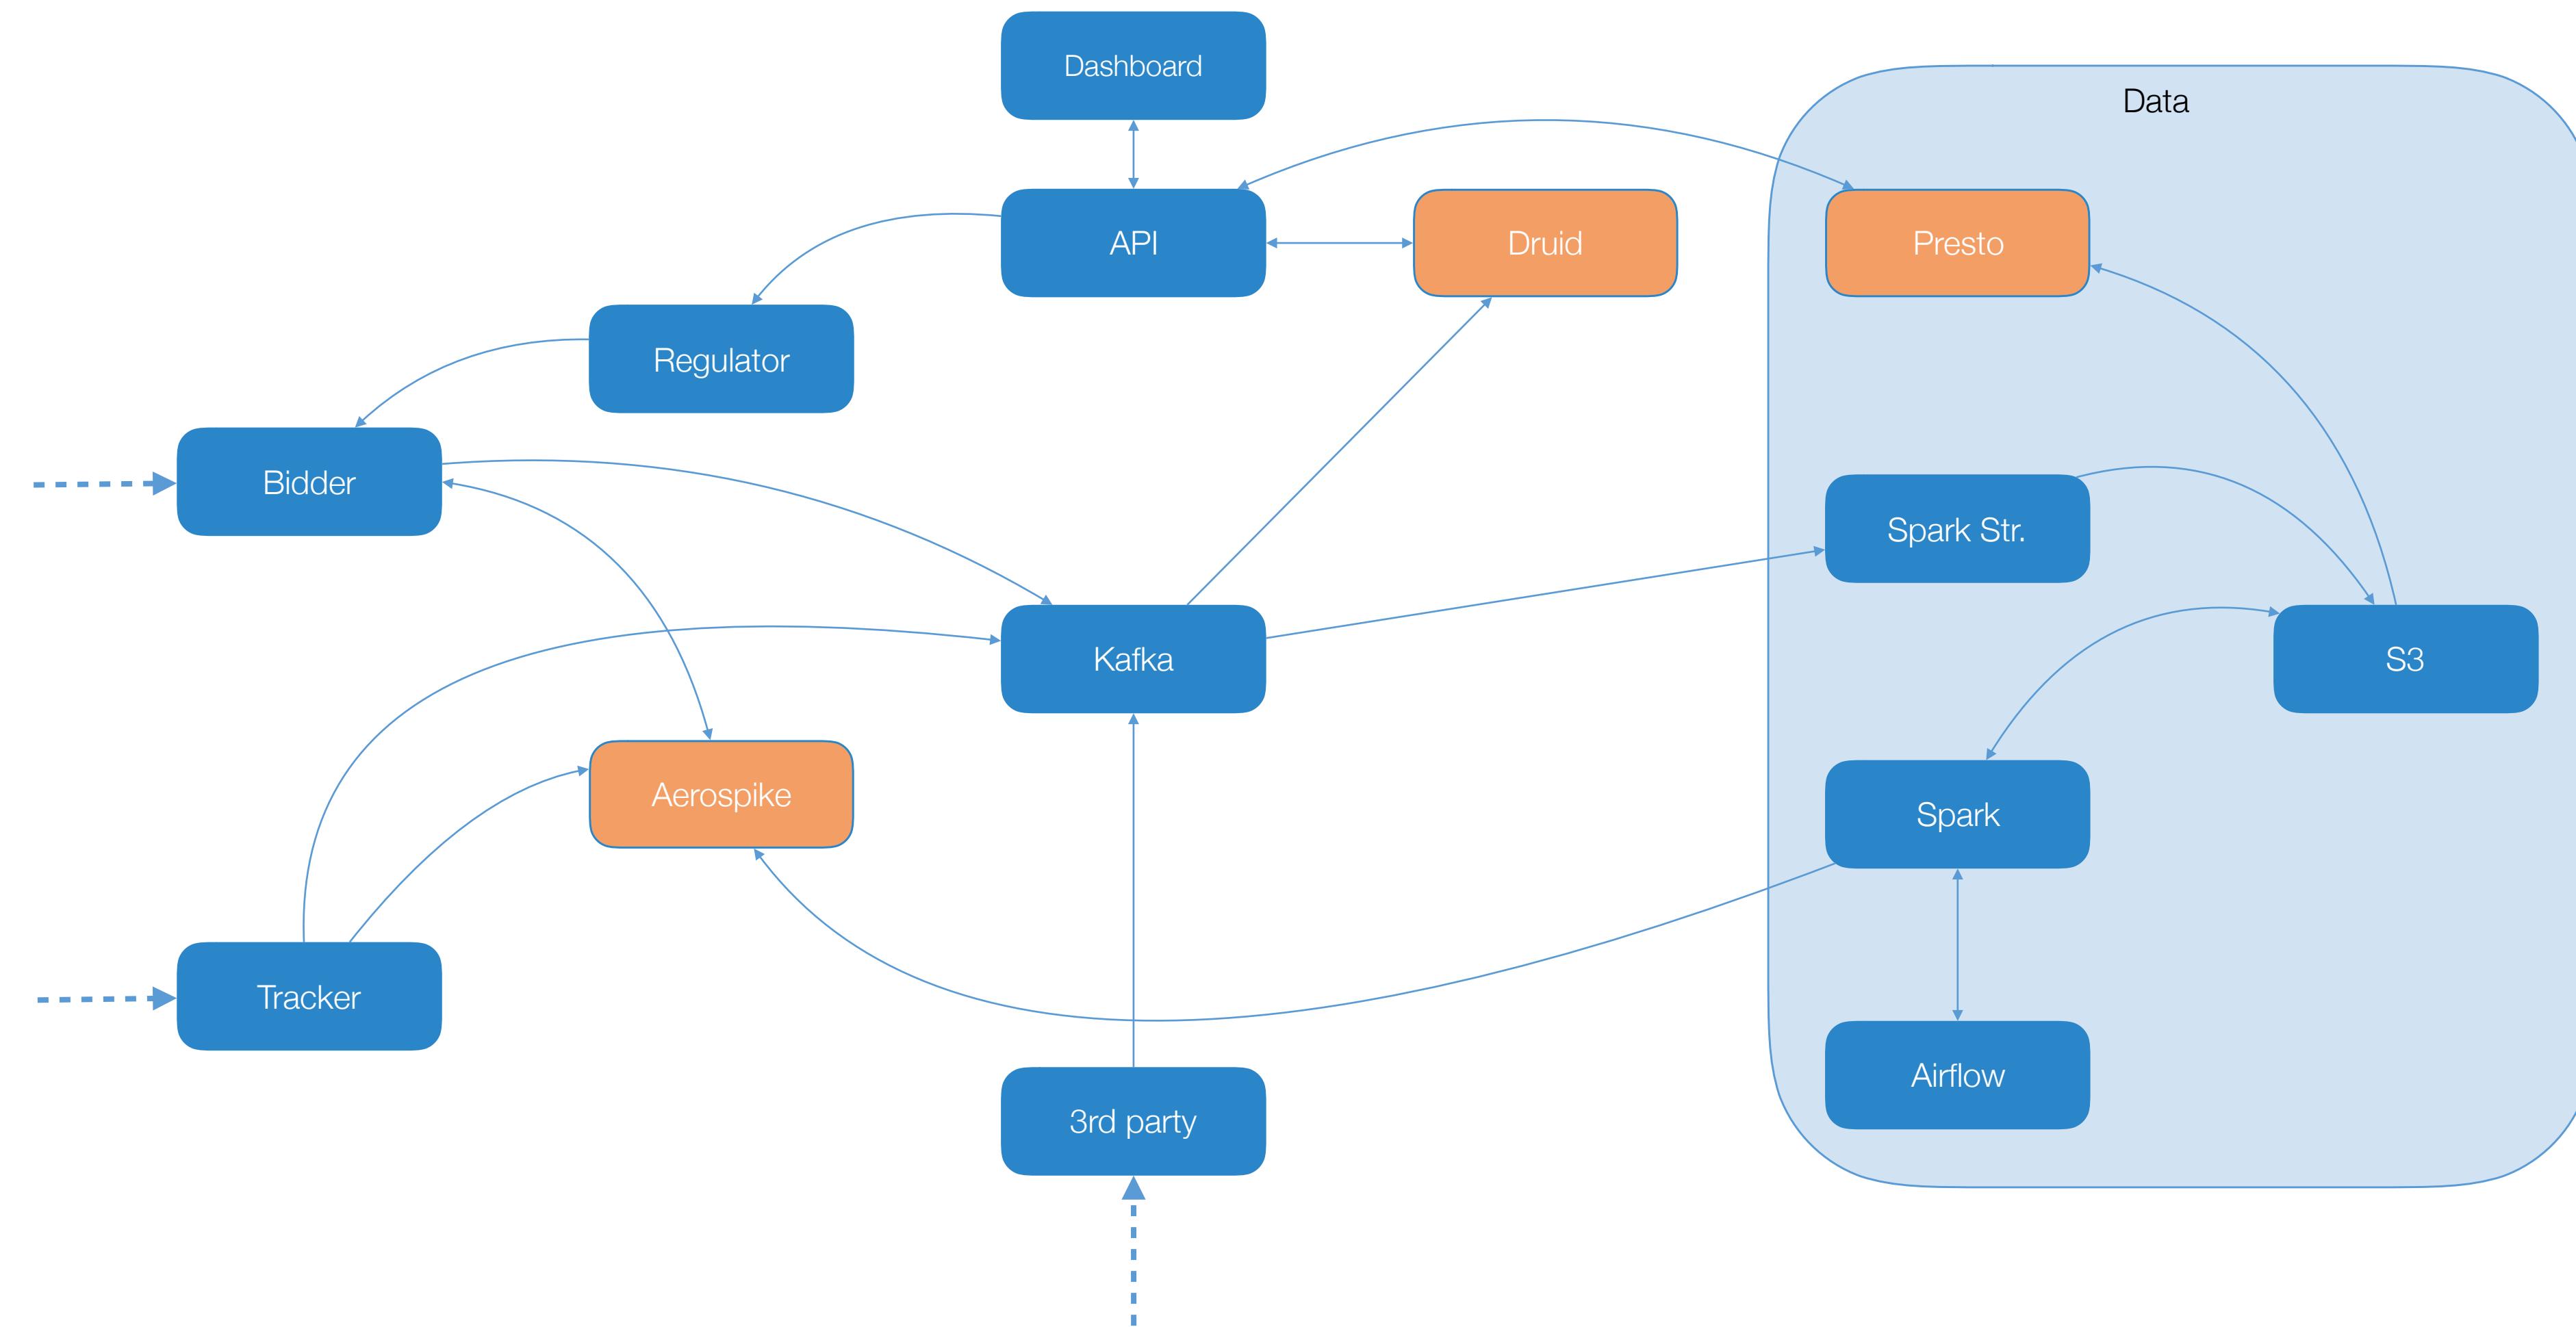
Systèmes distribués

Ecosystème

- Système informatique reposant sur la **parallélisation** des tâches sur différentes machines
- Plusieurs avantages :
 - répartition de la charge (processing + network)
 - meilleure résistance à l'erreur (fault-tolerance)
 - optimisation des coûts
 - aisément scalable
- Inconvénients :
 - plus complexe à mettre en place qu'un simple serveur
 - monitoring
 - éventuellement beaucoup d'IO

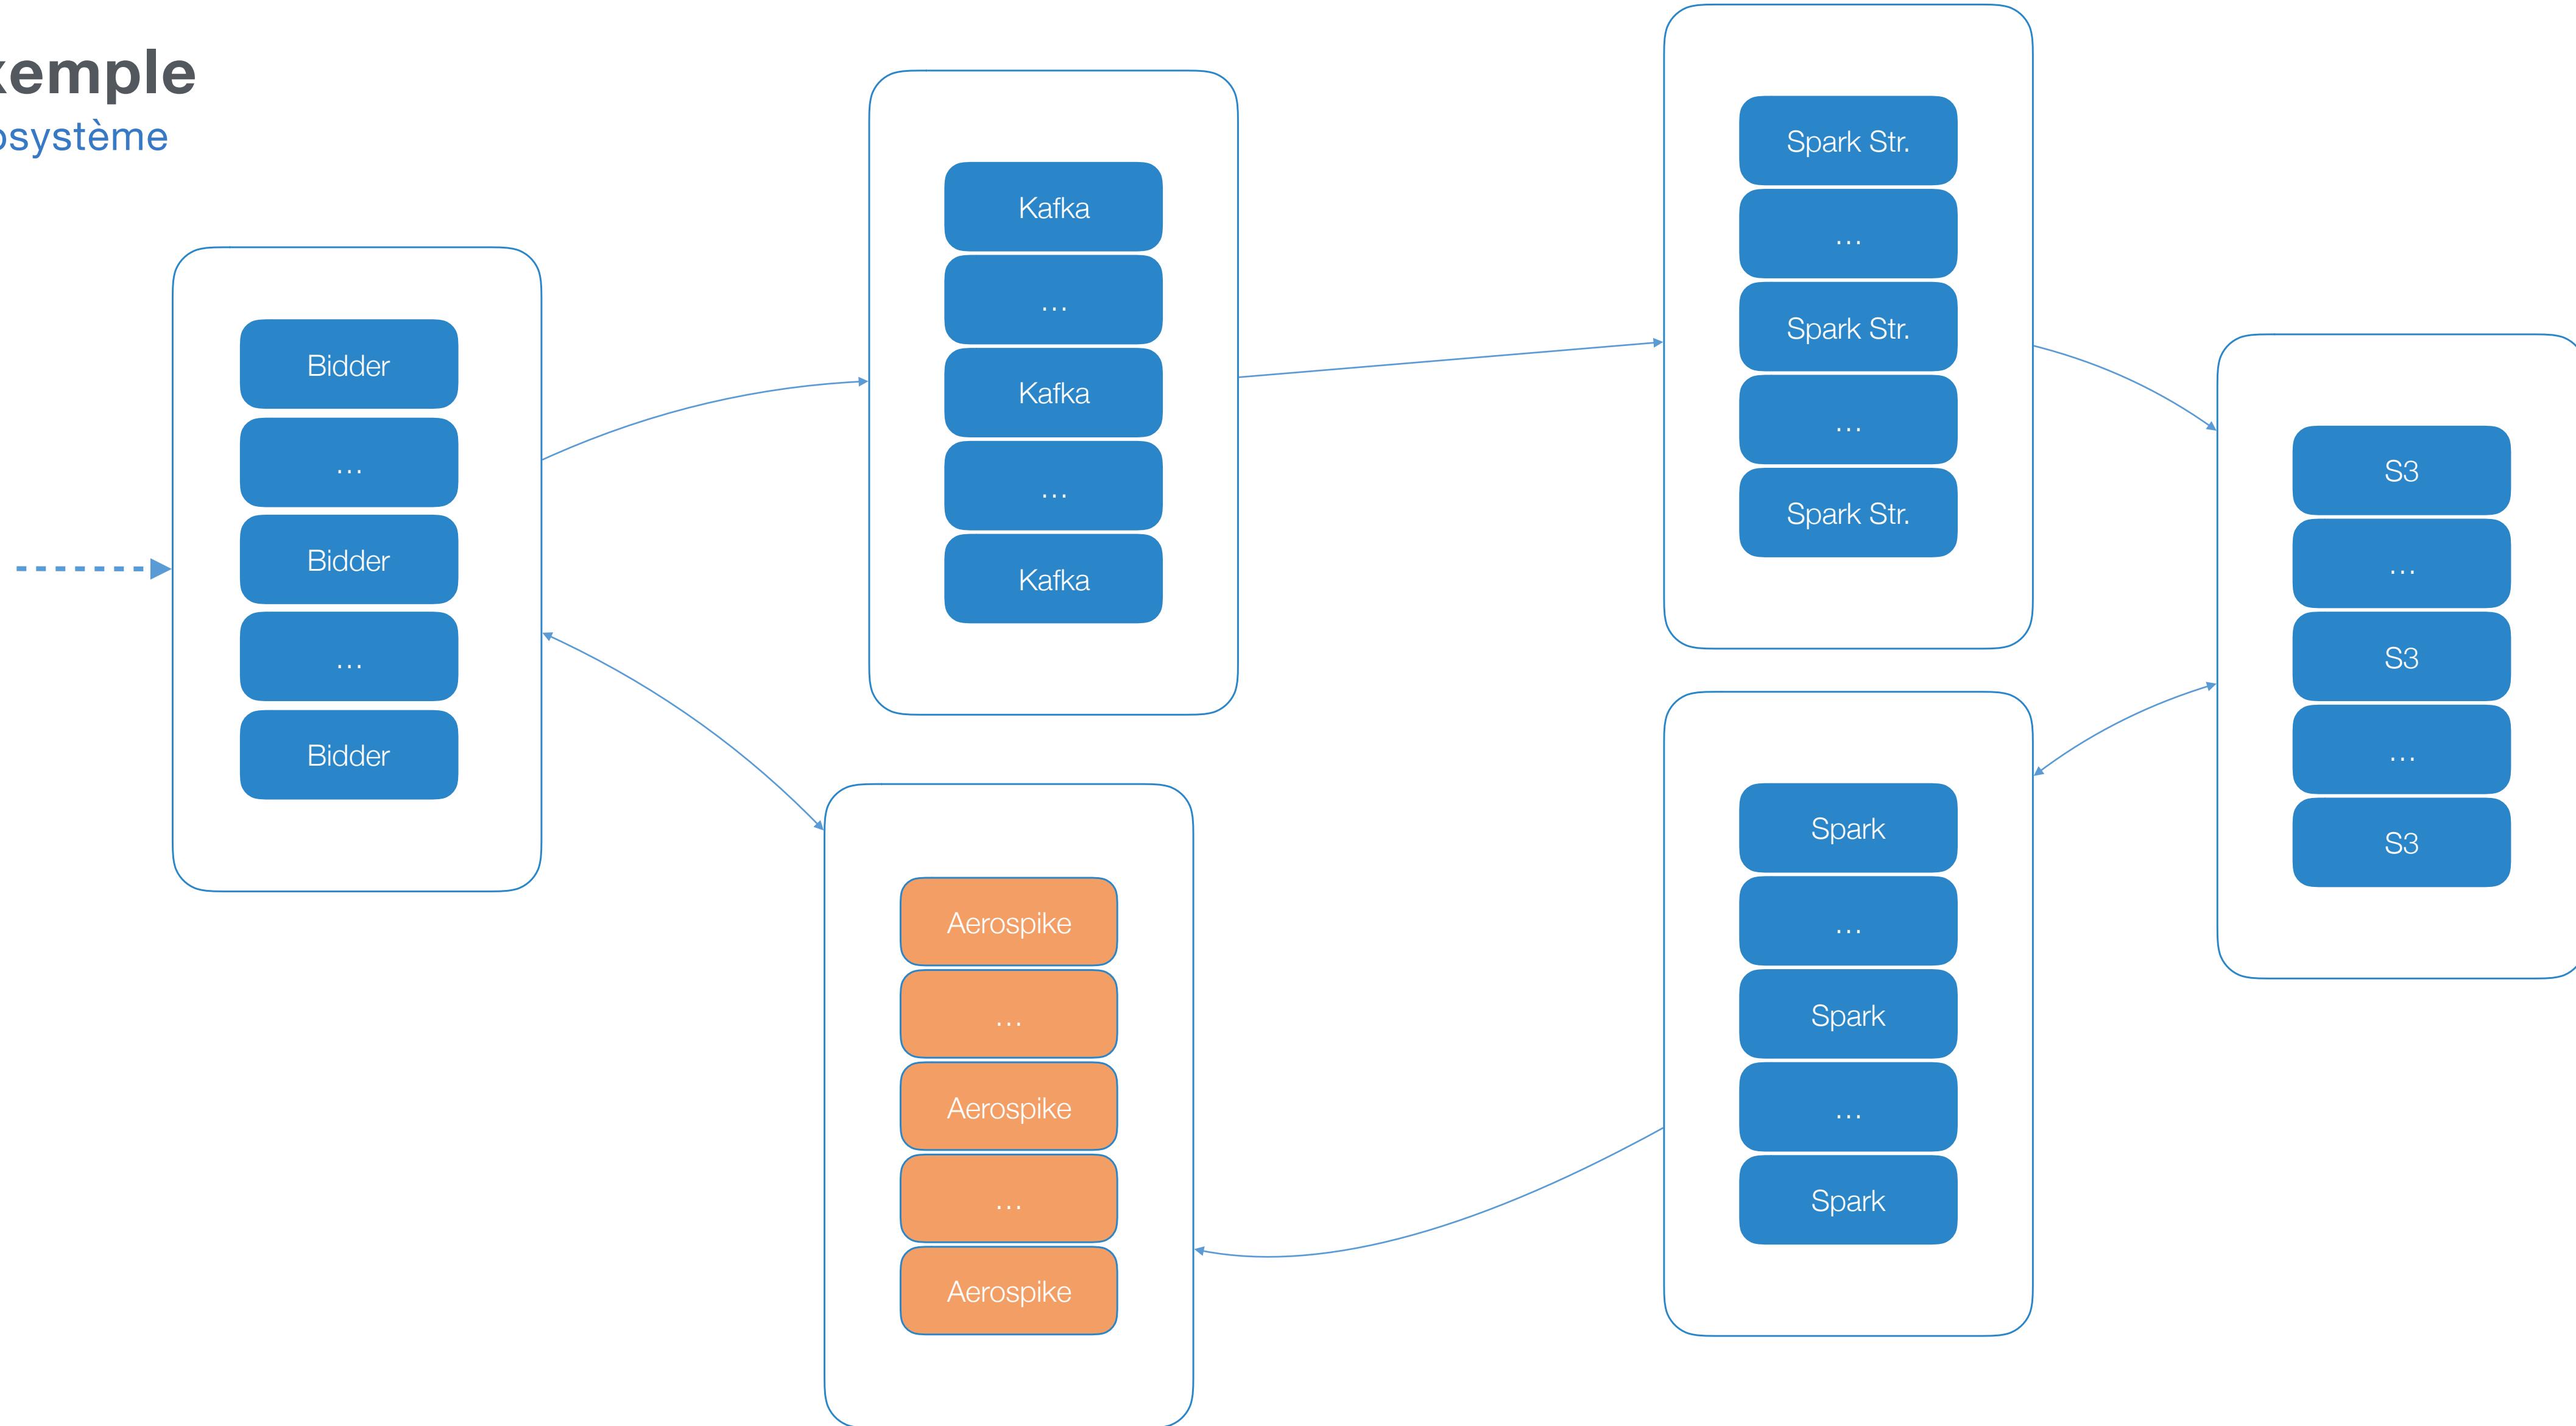
Infrastructure type

Ecosystème



Exemple

Ecosystème



Différents types de technologies

Ecosystème



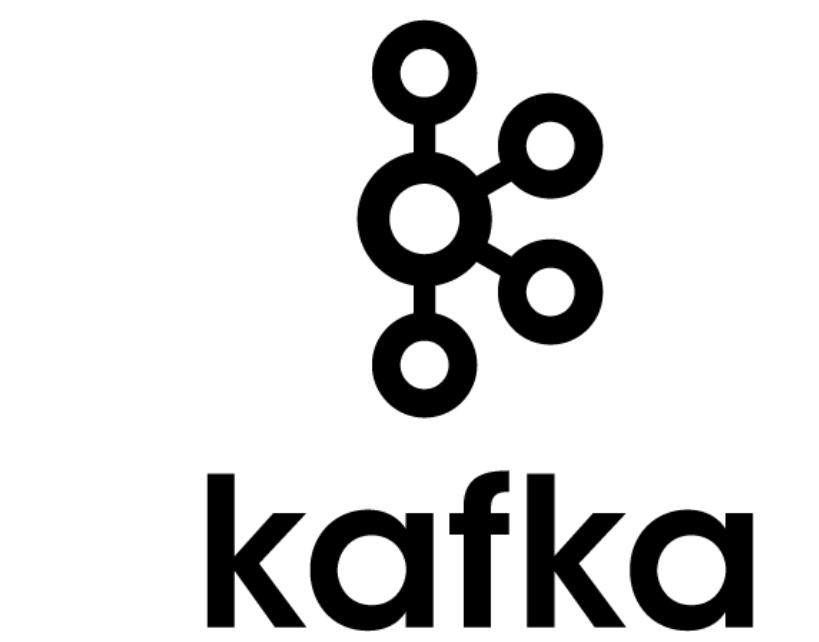
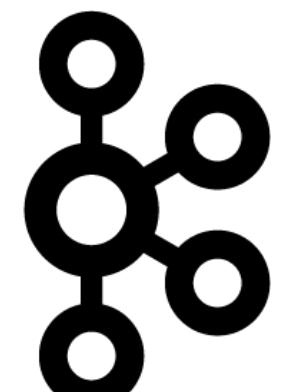
Stockage

Transmission



Compute

Mise à disposition



1

Généralités sur Spark

Quelques propriétés de Spark

Généralités sur Spark

- Outil de **processing** et **d'analyse de données** à grande échelle, codé en Scala, et open source.
- Différents modes de déploiement :
 - en single machine pour des tests ou pour traiter de petits échantillons de données
 - en **cluster** (multi-machines) pour traiter de gros volumes de données
- Fonctionne aisément sur un laptop en local (sans cluster manager)
- Accessible en plusieurs langages de programmation via des API **Scala**, Python, Java et R

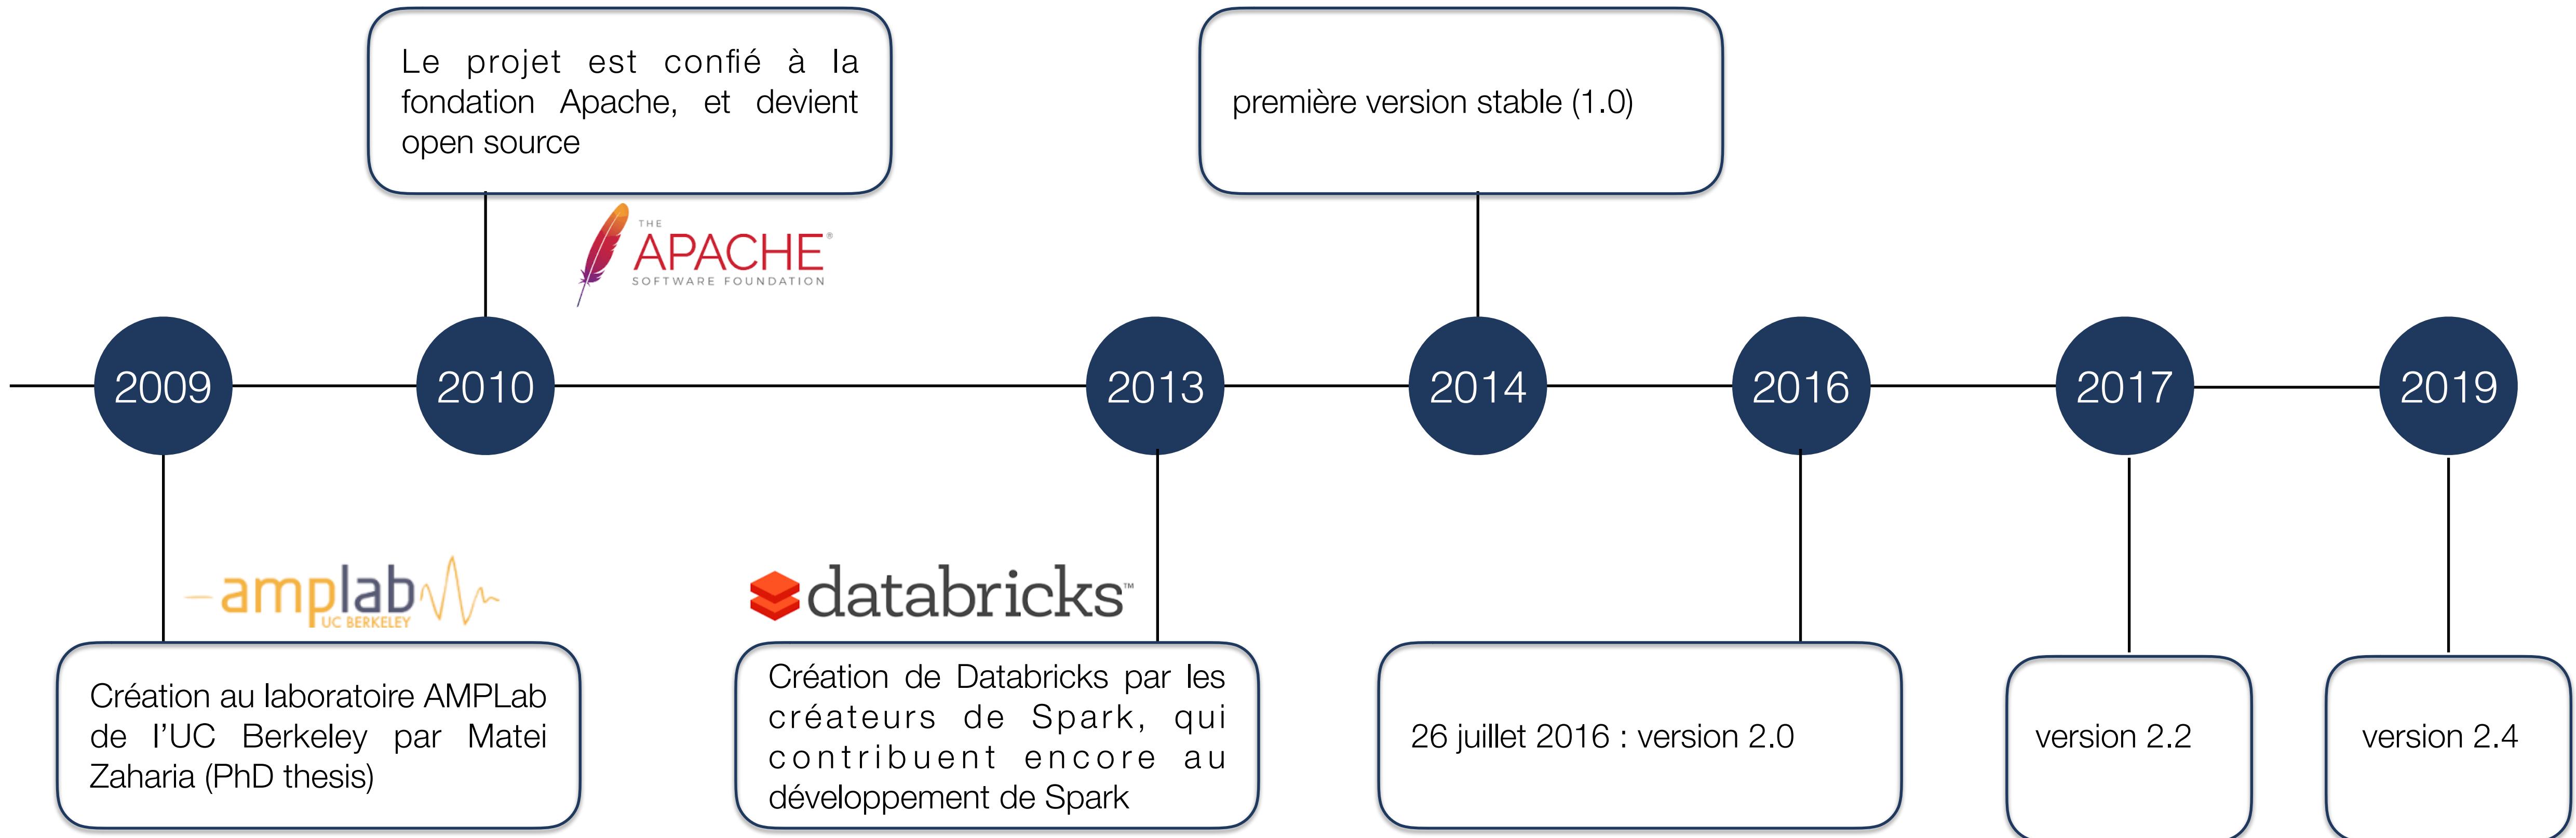
Spark, outil polyvalent

Généralités sur Spark

- Compatible avec la plupart des bases de données et systèmes de fichiers distribués (ou non)
 - **S3** (AWS), Google Storage
 - HDFS
 - Cassandra, HBase, Redshift,...
- Possède plusieurs librairies, à savoir :
 - un moteur **SQL**
 - du **Machine Learning**
 - du calcul sur graphes
 - du **streaming** (ou presque !)

Historique

Généralités sur Spark

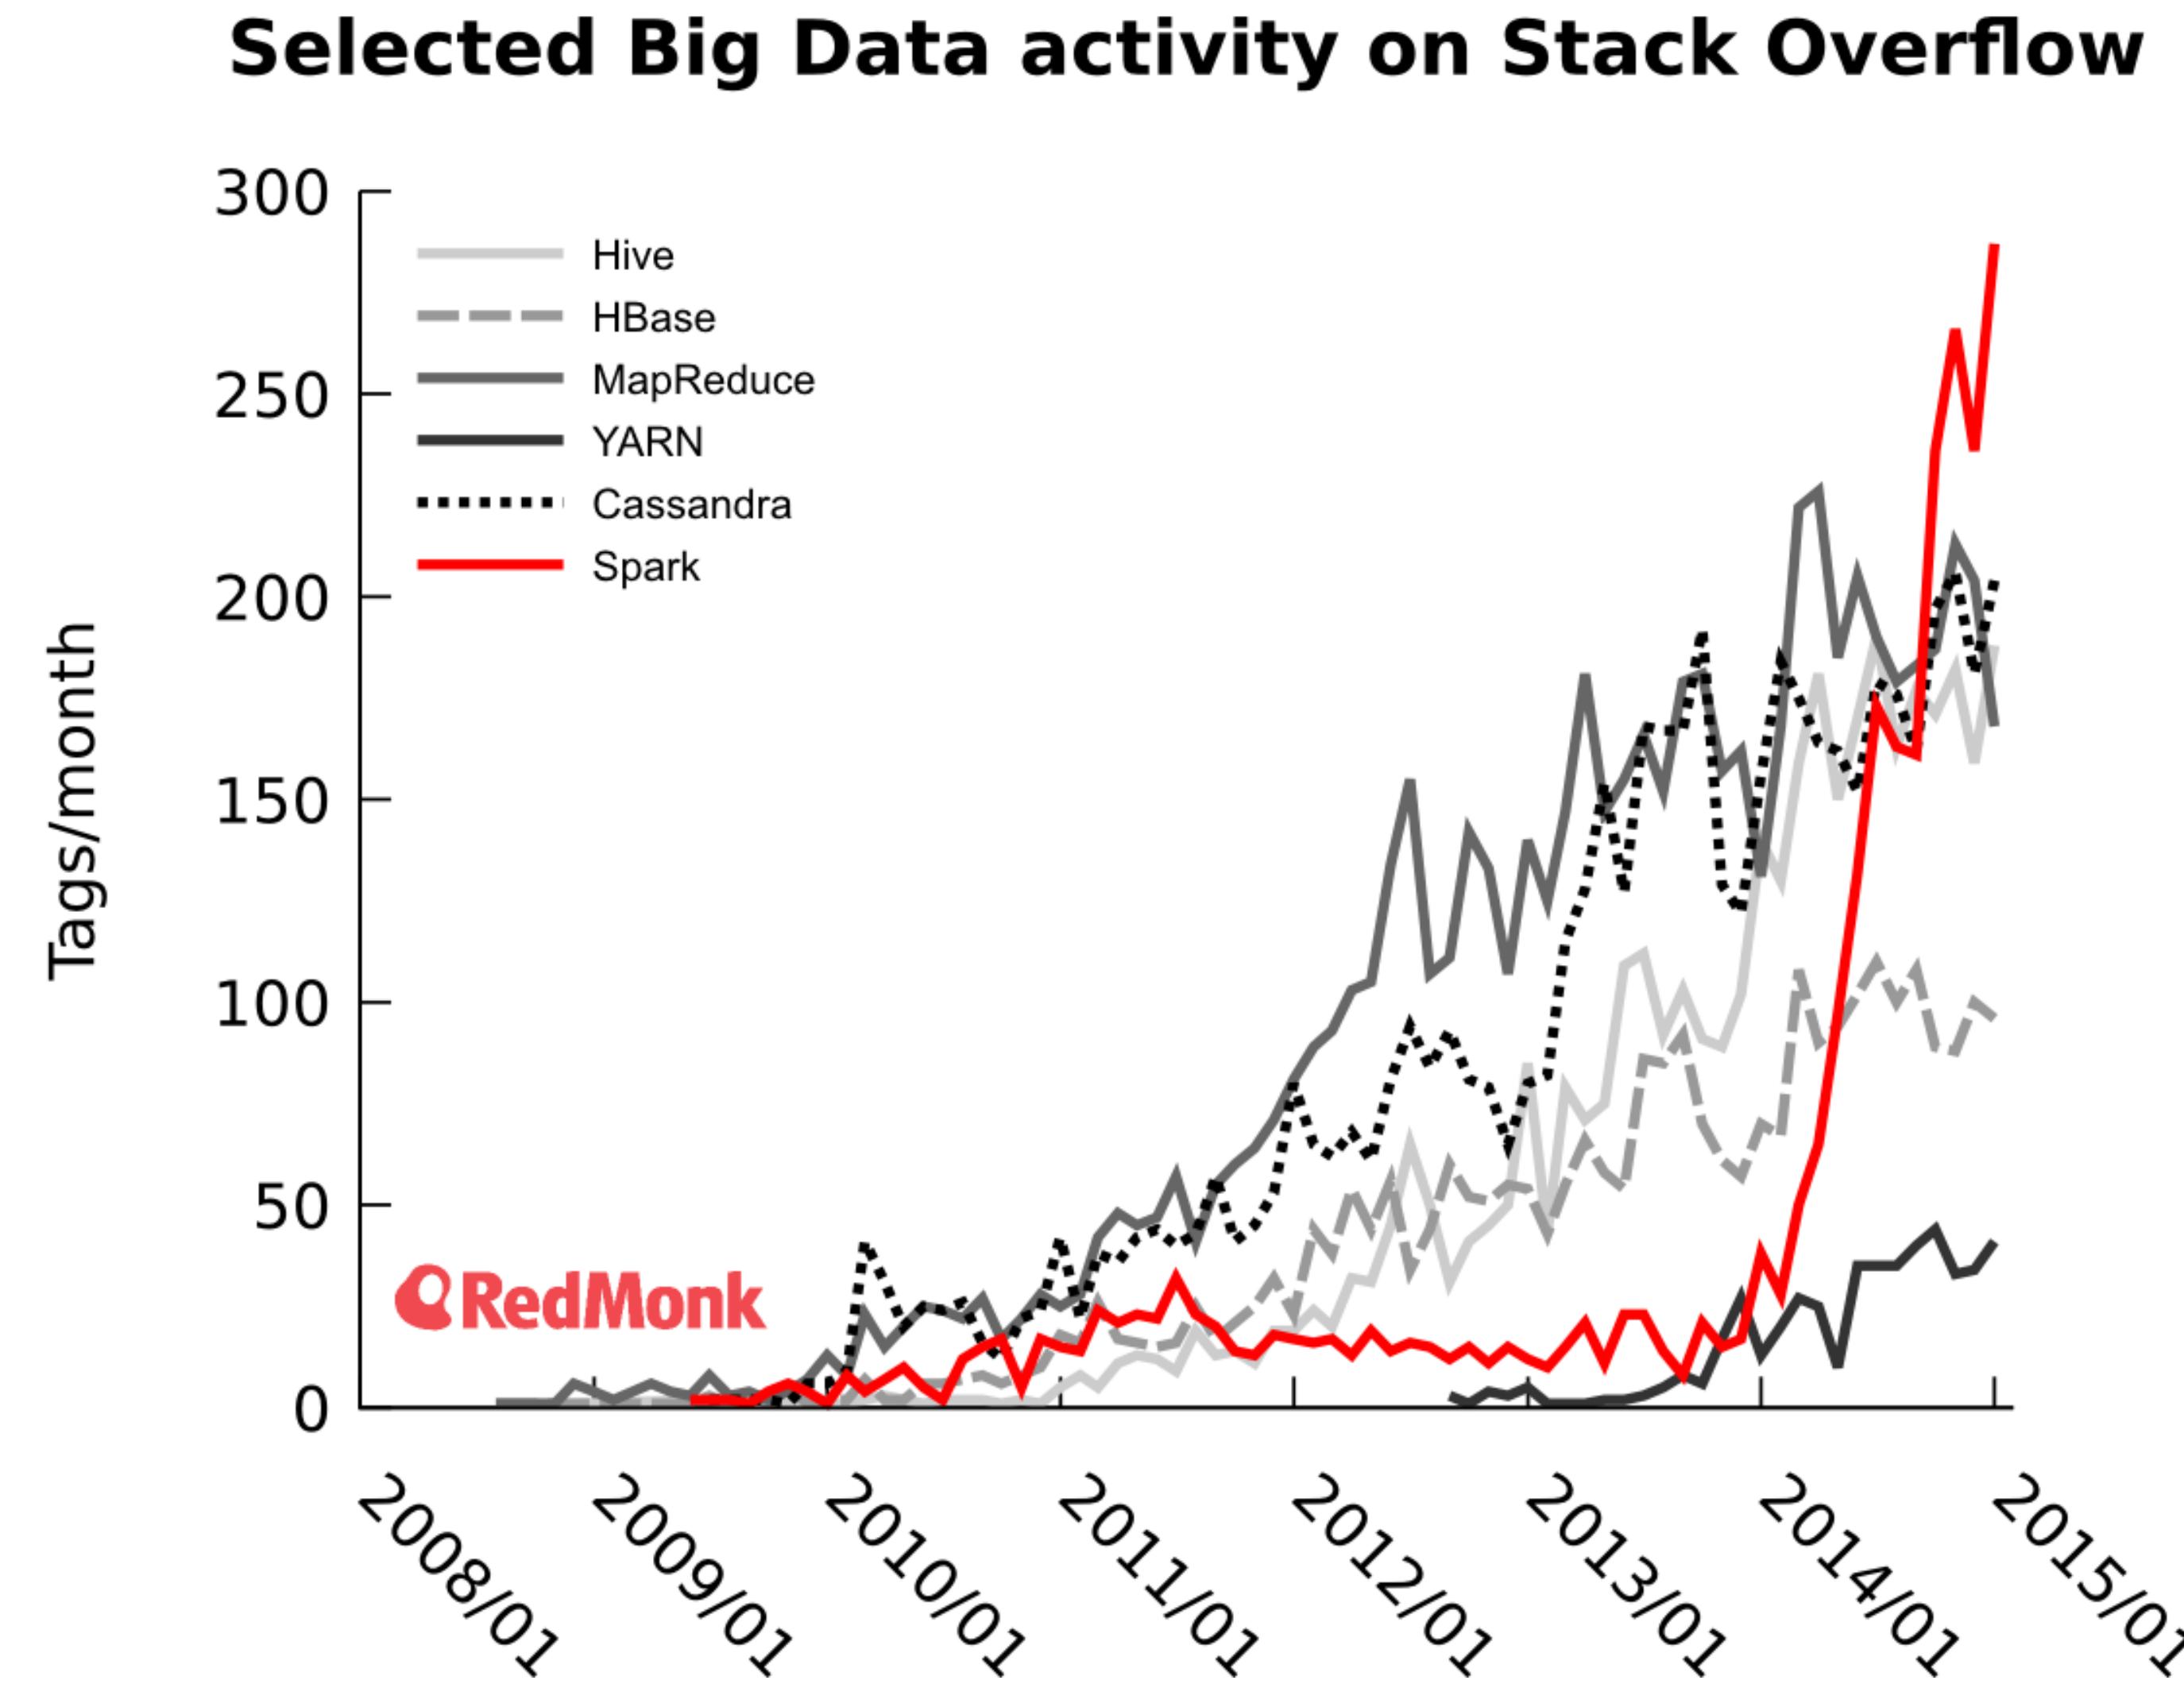


Source : <http://blog.madhukaraphatak.com/history-of-spark/>

Spark largement adopté

Généralités sur Spark

- Projet Big Data le plus activement développé actuellement :
 - ~1000 contributeurs
 - ~100 commits/semaine
- Rapidement et largement adopté par la communauté Big Data
- Utilisé en **production** dans de nombreuses entreprises (Netflix, Uber, Spotify,...)
- Disponible en **SaaS** chez les cloud providers majeurs



Spark Survey 2015

1. Spark Adoption Is Growing Rapidly



Adoption of Spark has spread beyond the technology industry, and Spark is fast becoming the Big Data technology for everyone, not just for Big Data experts.

SPARK IS THE MOST ACTIVE OPEN SOURCE PROJECT IN BIG DATA.

Spark Summit conferences

*Based on Spark Summit East and Spark Summit West, not including Spark Summit Europe

1,164
attendees

453
companies

2014

2,986
attendees

1,144
companies

2015*

Spark contributors



APACHE SPARK'S GROWTH CONTINUES

Spark today remains the most active open source project in Big Data. Today, there are over 1000 Spark contributors, compared to 600 in 2015 from 250+ organizations. With such large numbers of contributors and organizations investing in Spark's future development, it has engaged a community of developers globally.

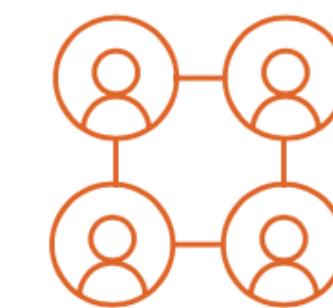


CODE CONTRIBUTORS

+67%

2015
600

2016
1000

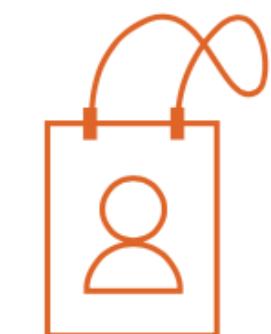


SPARK MEETUP MEMBERS

+240%

2015
66,000

2016
225,000



SPARK SUMMIT ATTENDEES

+30%

2015
3912

2016
5100



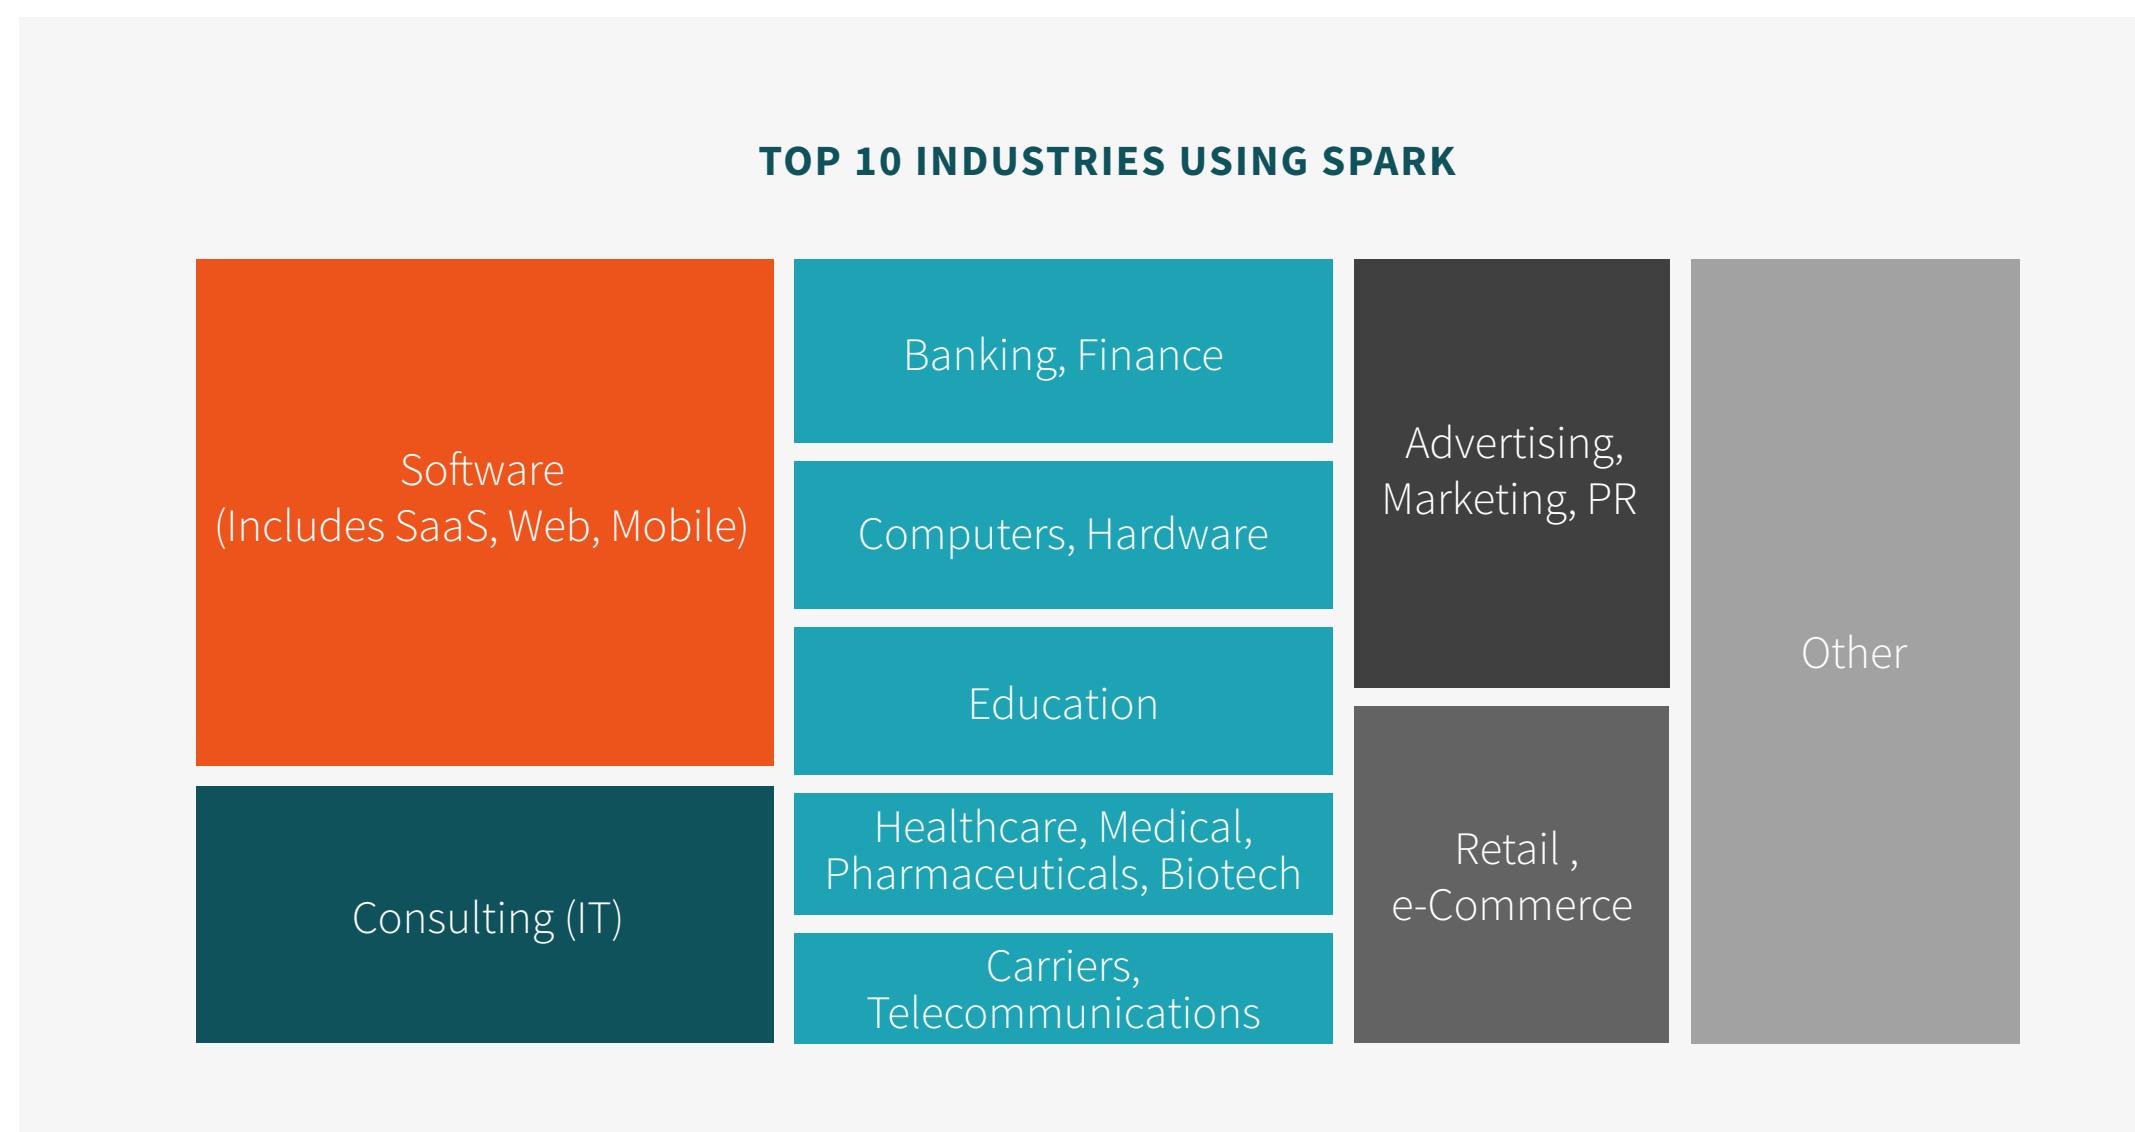
COMPANIES REPRESENTED AT SUMMITS

+57%

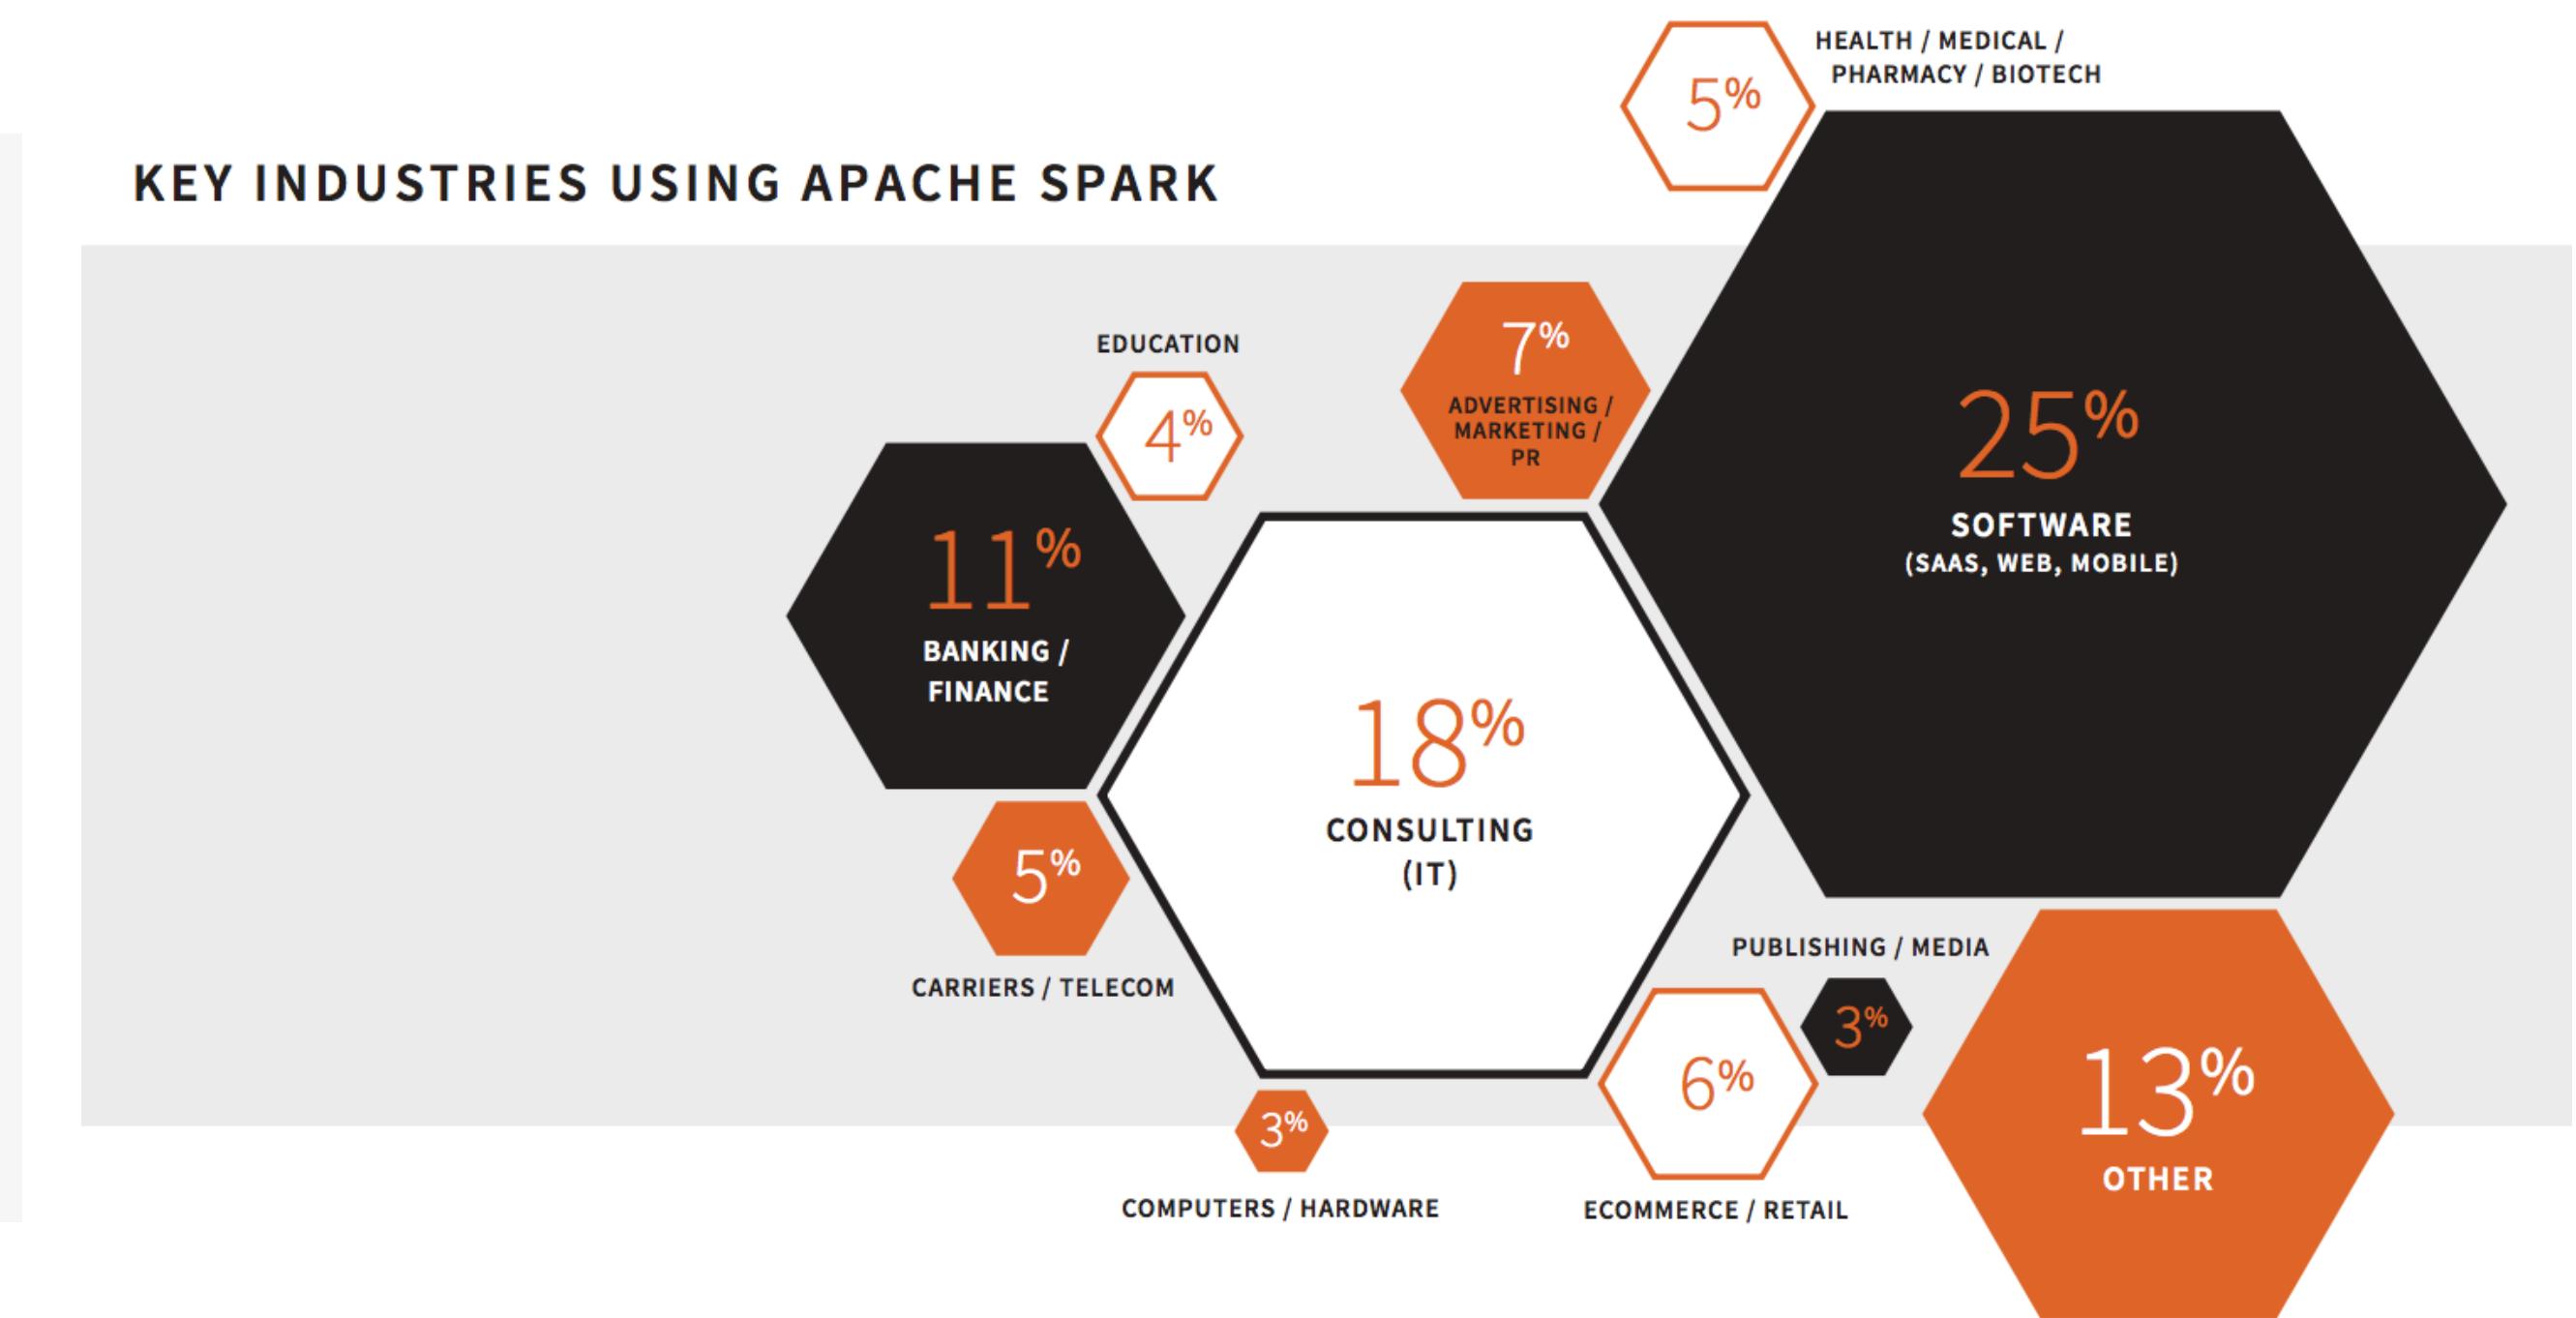
2015
1144

2016
1800

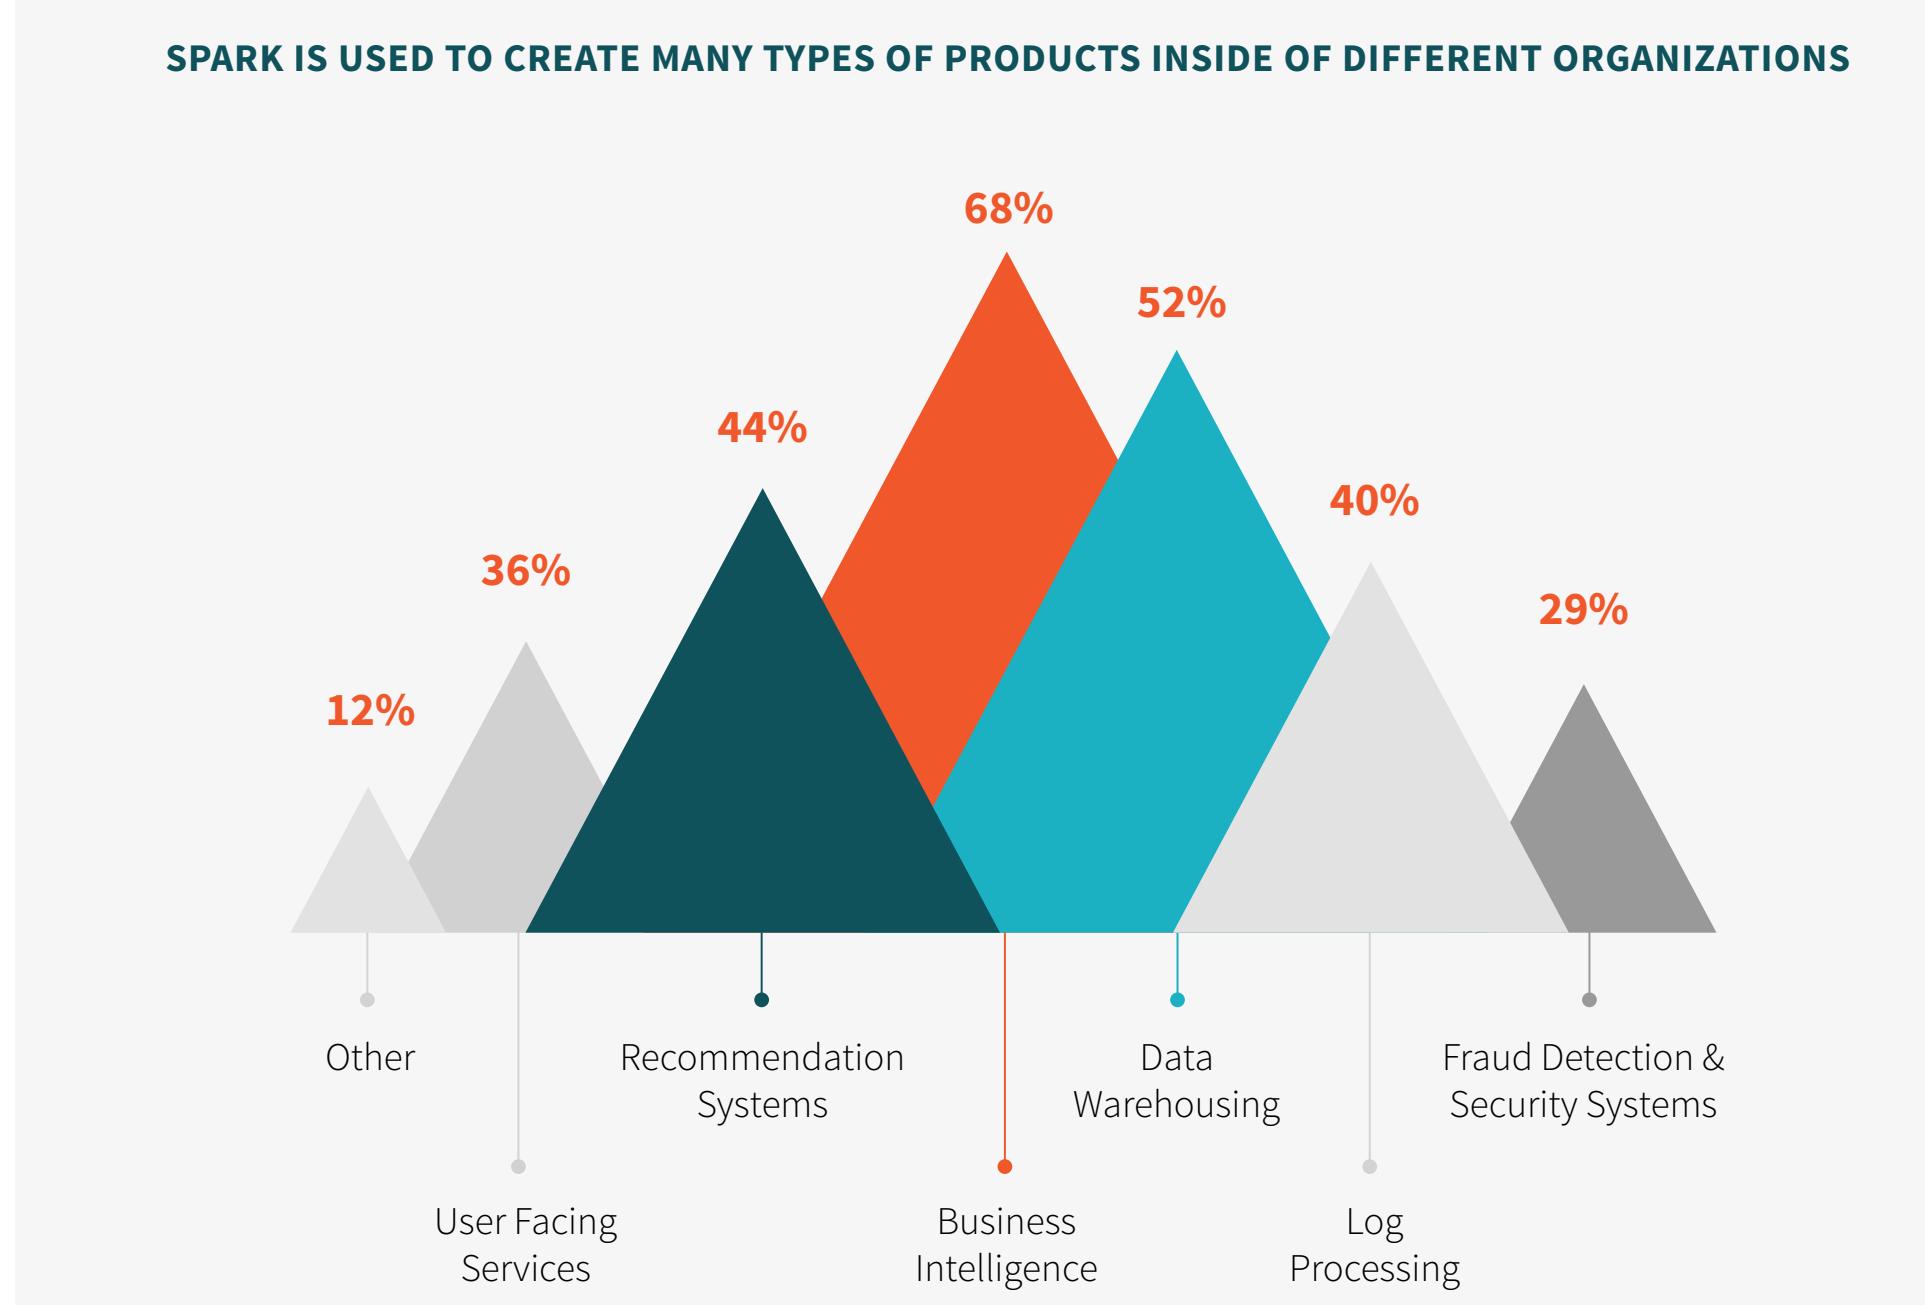
Spark Survey 2015



Spark Survey 2016



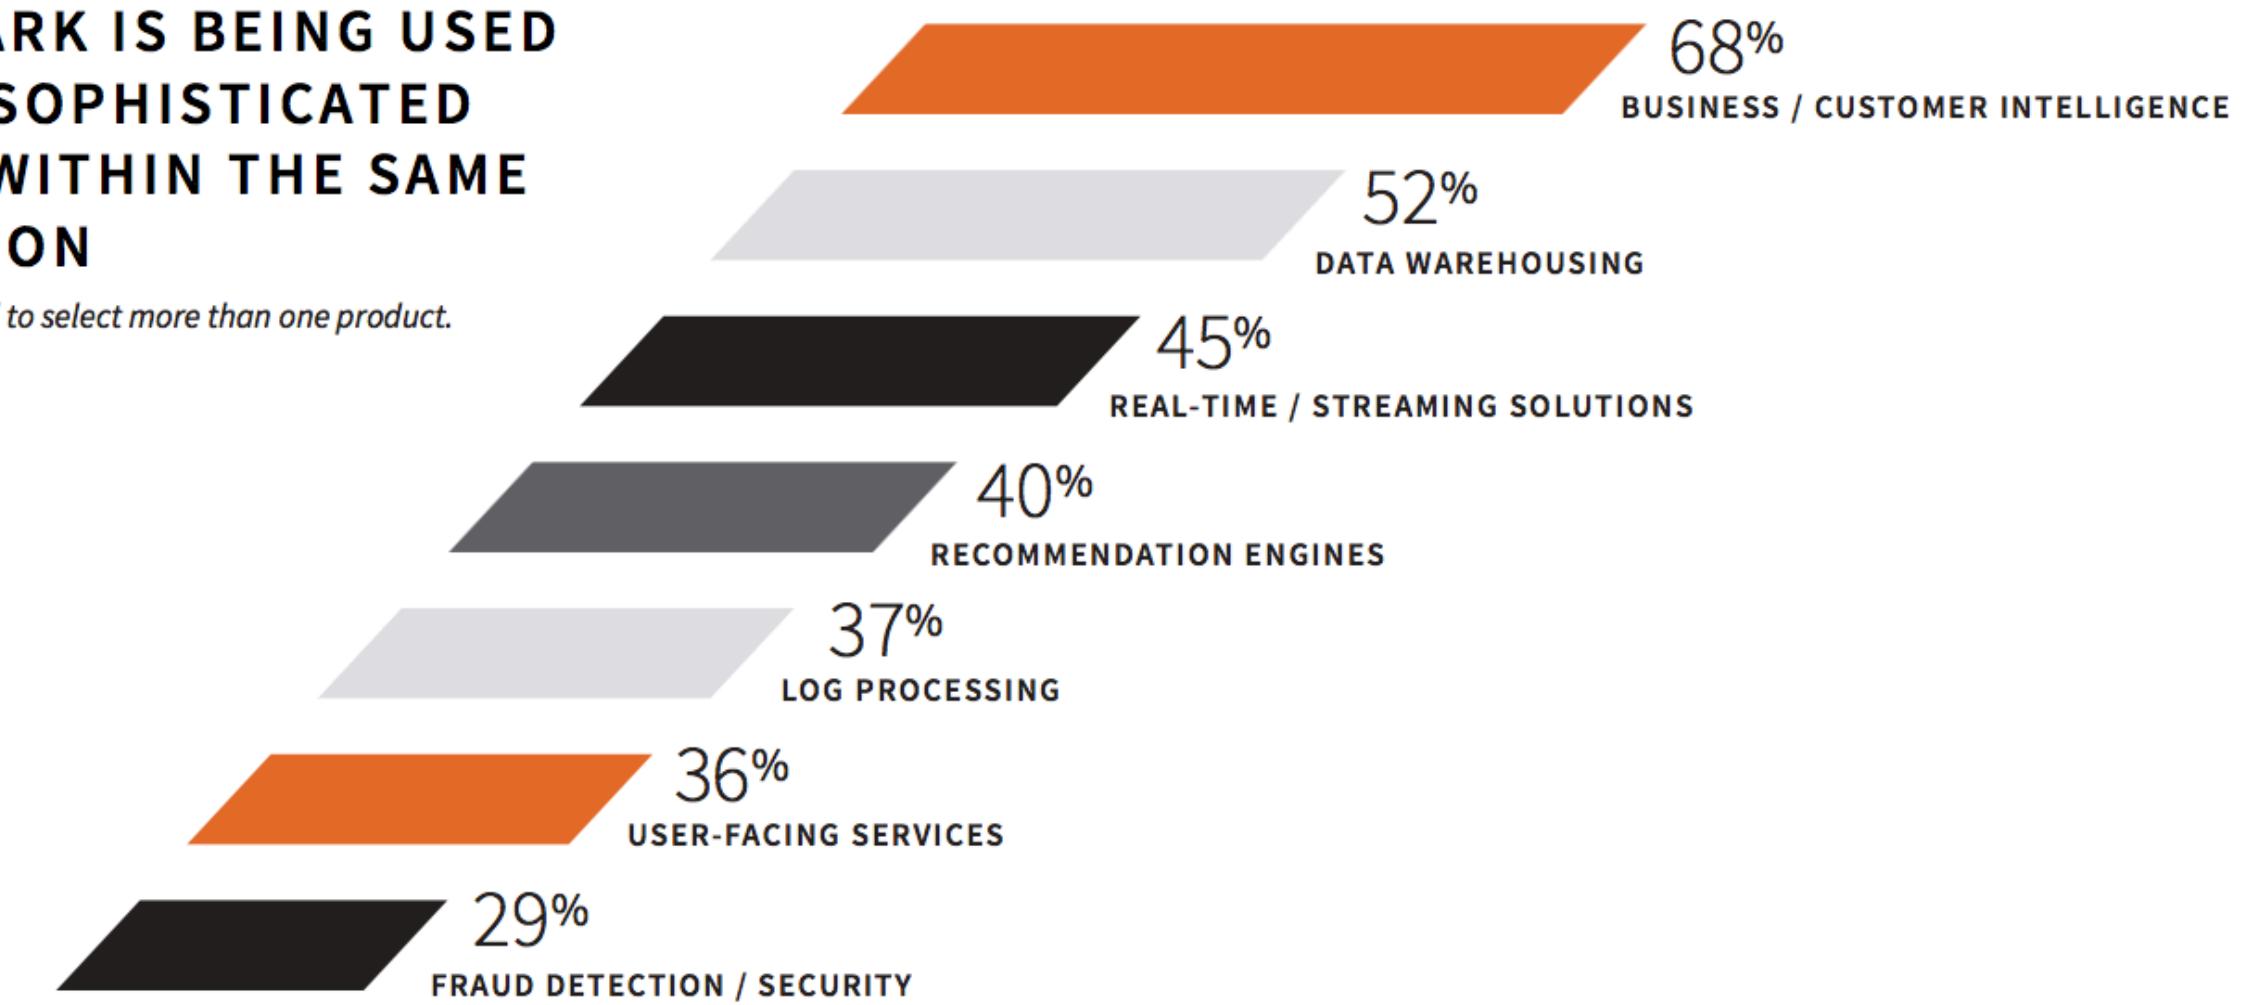
Spark Survey 2015



Spark Survey 2016

APACHE SPARK IS BEING USED TO CREATE SOPHISTICATED PRODUCTS WITHIN THE SAME ORGANIZATION

Respondents were allowed to select more than one product.

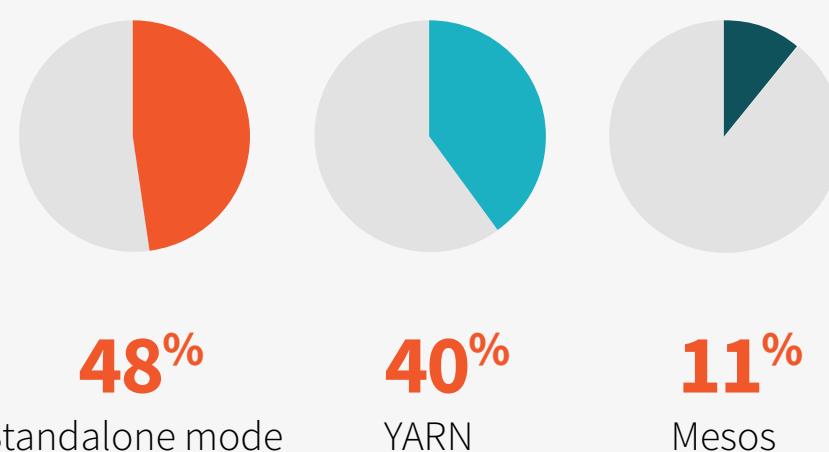


Spark Survey 2015

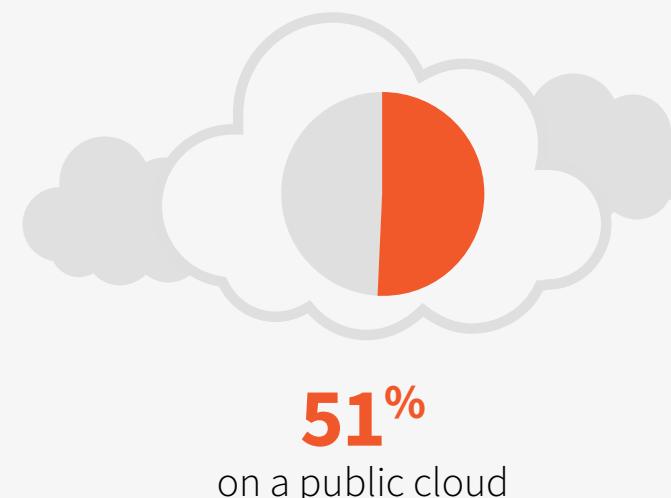
2. Spark Is Growing Far Beyond Hadoop

While many users run Spark in on-premise Hadoop environments, they are not a majority of its users. Spark usage in the cloud and with Spark's own cluster manager have surged in the last year.

MOST COMMON SPARK DEPLOYMENT ENVIRONMENTS (CLUSTER MANAGERS)



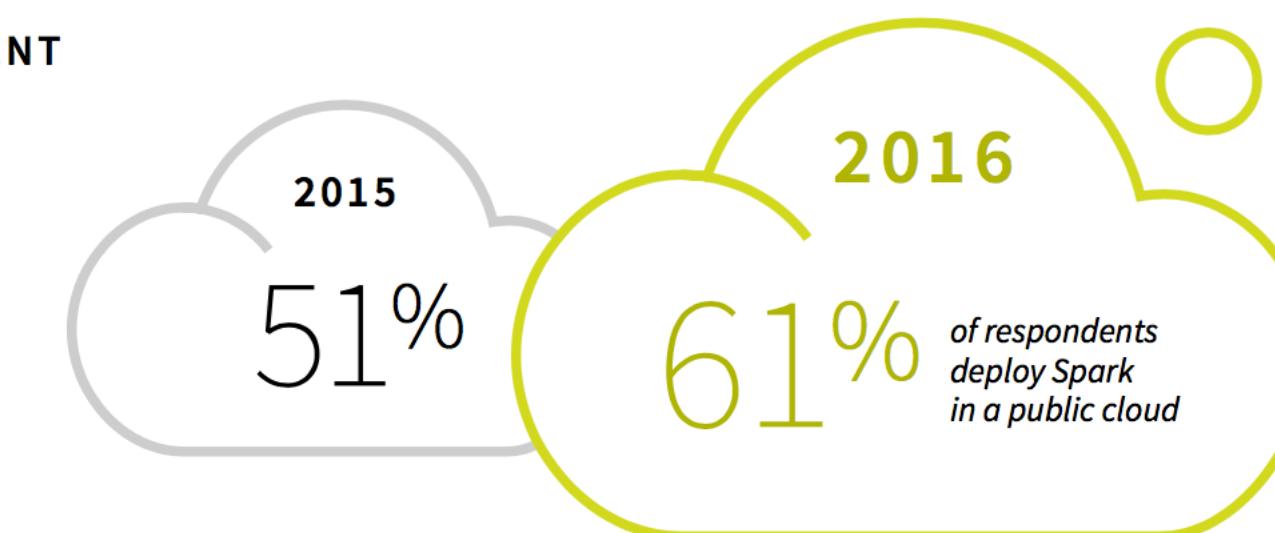
HOW RESPONDENTS ARE RUNNING SPARK



APACHE SPARK IN THE CLOUD IS GROWING

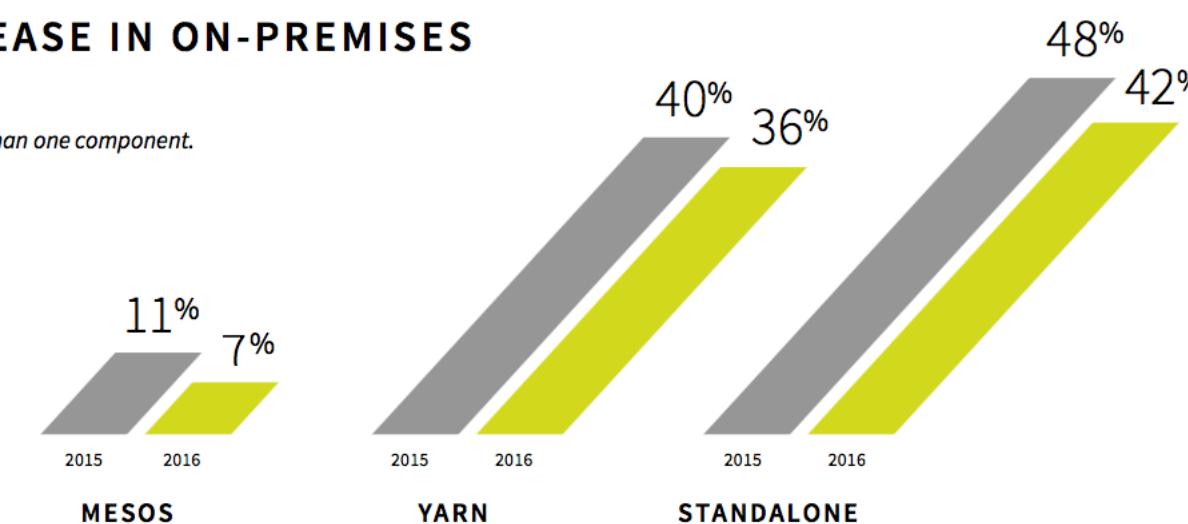
Apache Spark deployments in the public cloud increased in 2016. In contrast, the percentage of Spark deployments on-premises decreased in the past year.

APACHE SPARK DEPLOYMENT IN PUBLIC CLOUDS HAS INCREASED BY 10% SINCE 2015.

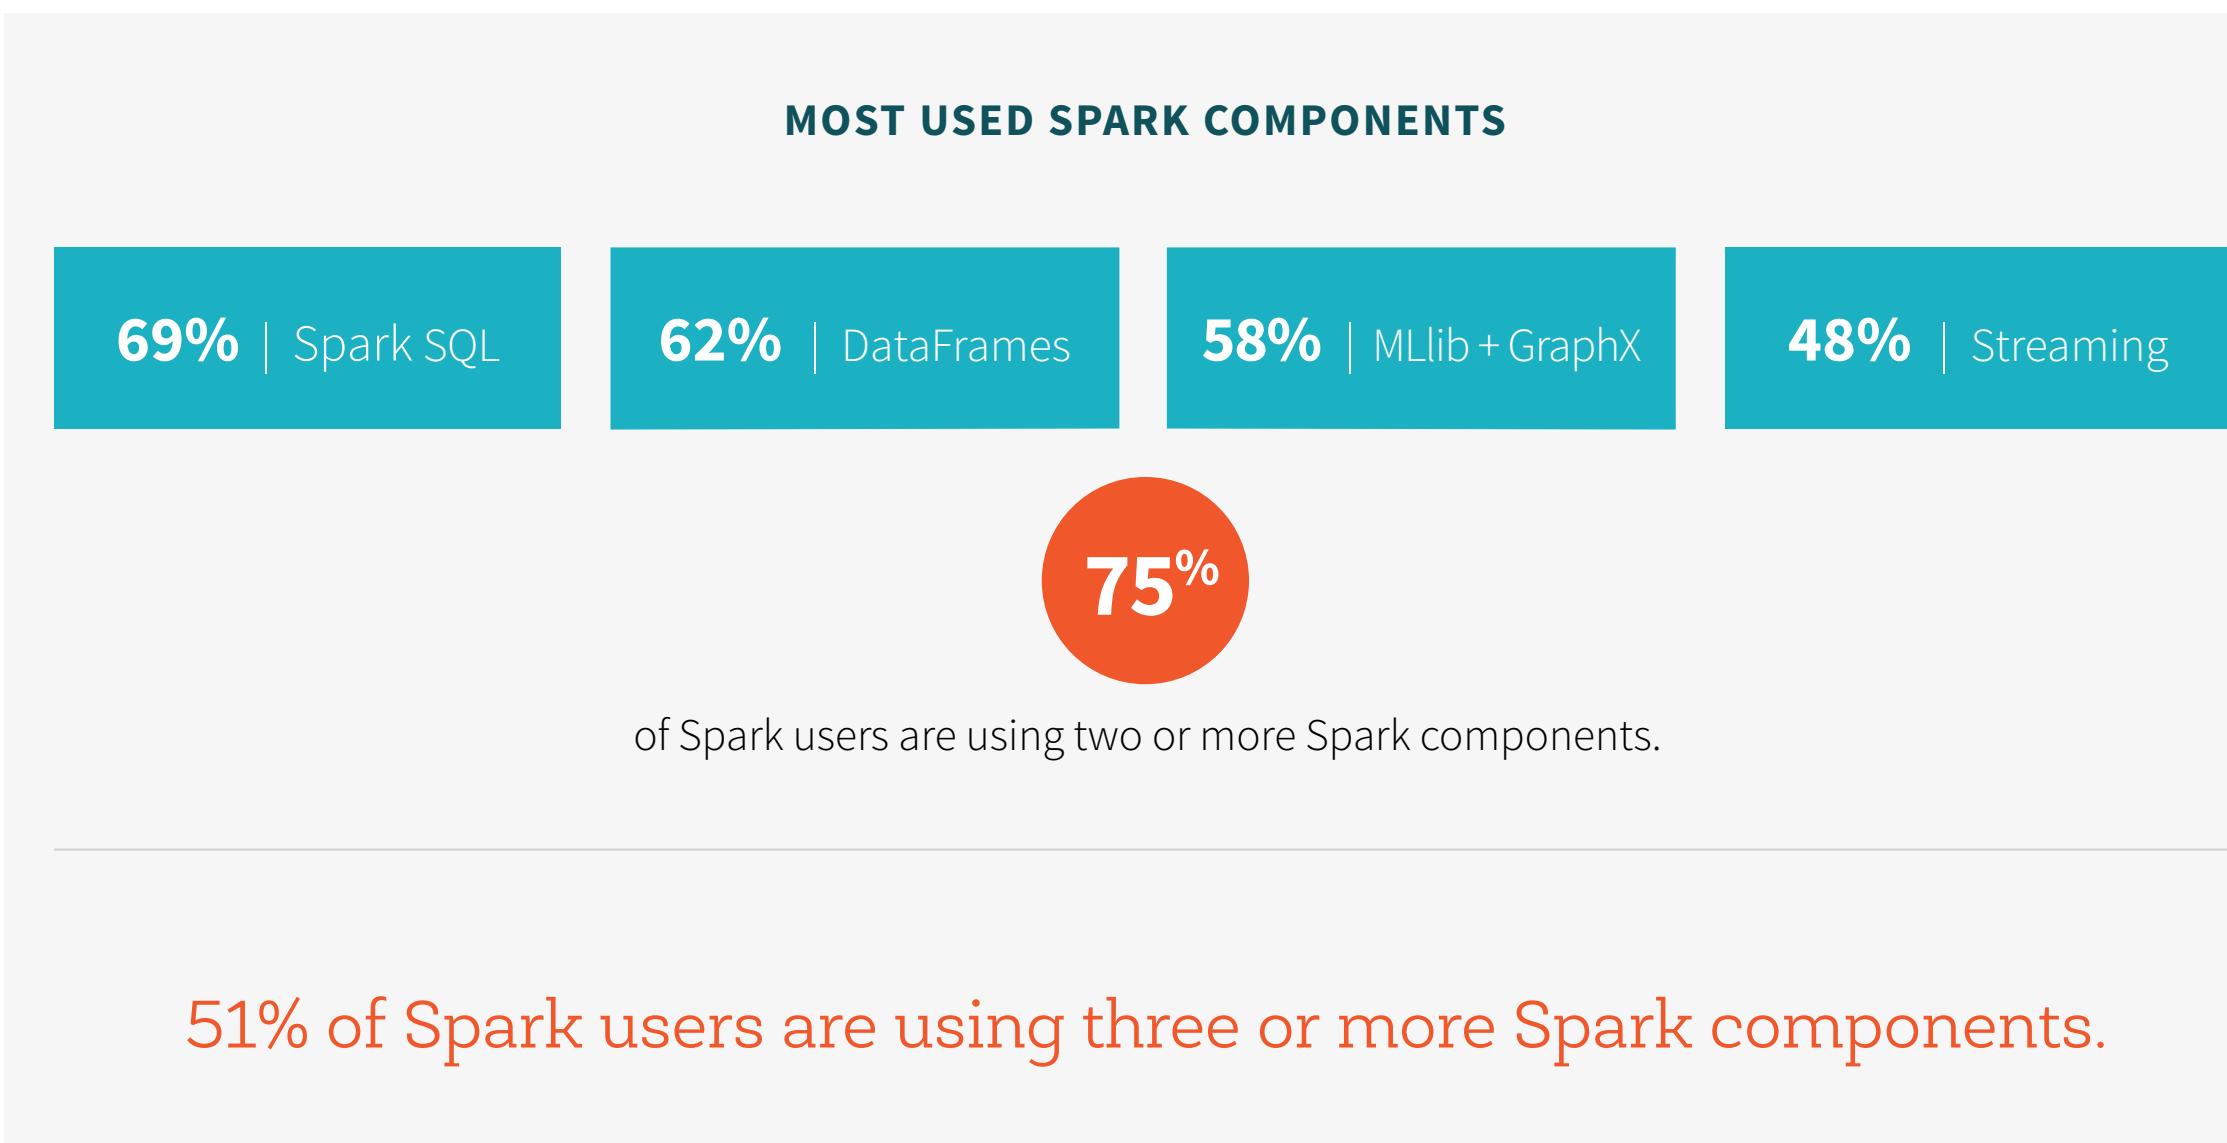


PERCENTAGE DECREASE IN ON-PREMISES DEPLOYMENTS

Respondents were allowed to select more than one component.

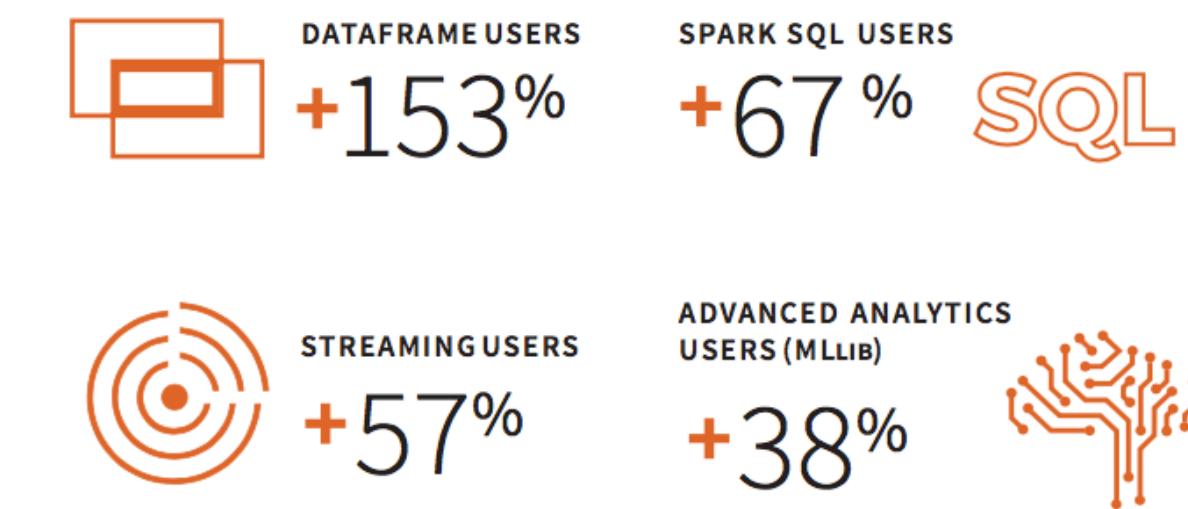


Spark Survey 2015



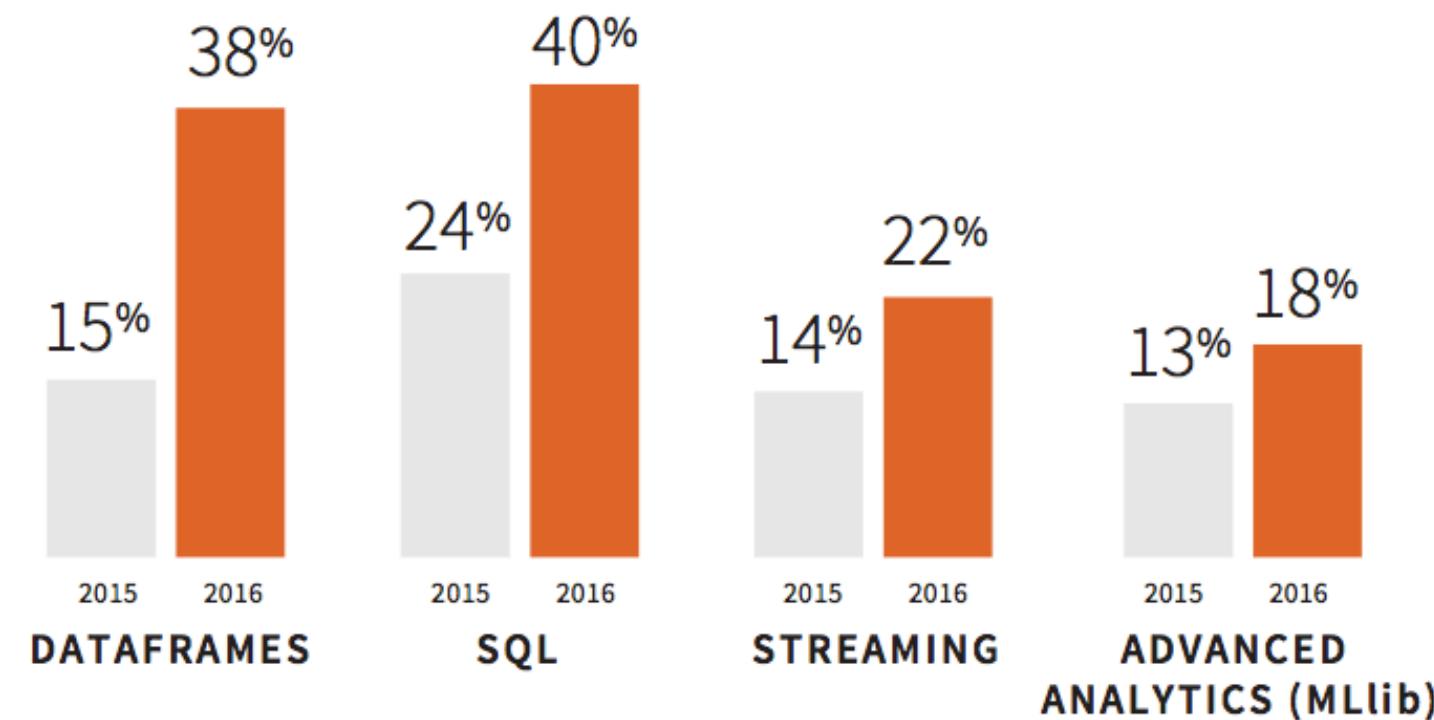
Spark Survey 2016

APACHE SPARK'S FASTEST GROWING AREAS IN 2016



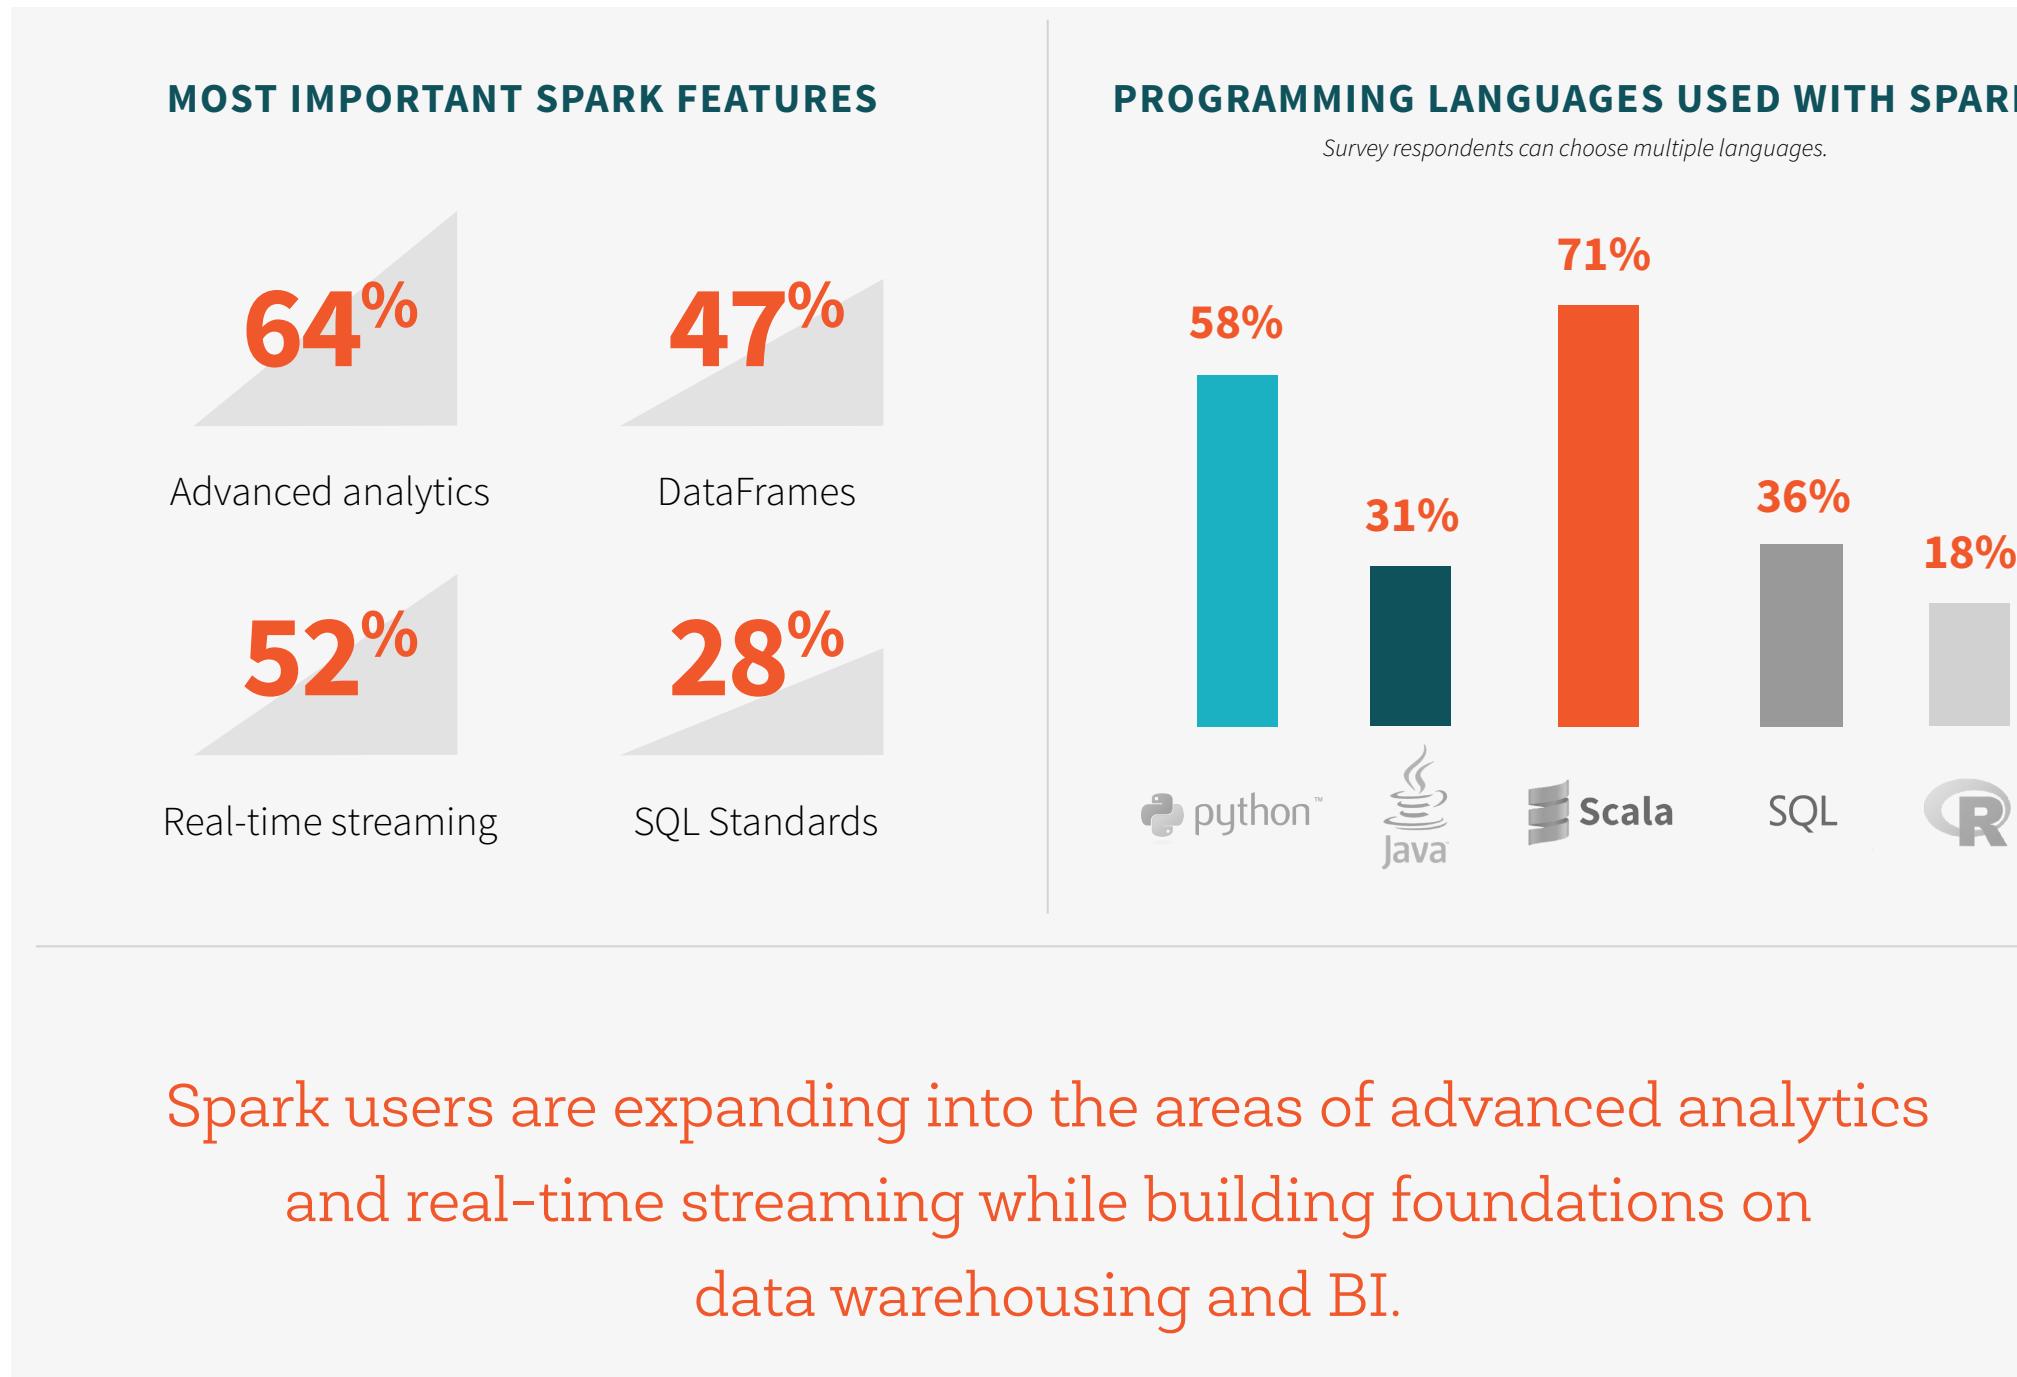
SPARK COMPONENTS USED IN PRODUCTION

Respondents were allowed to select more than one component.



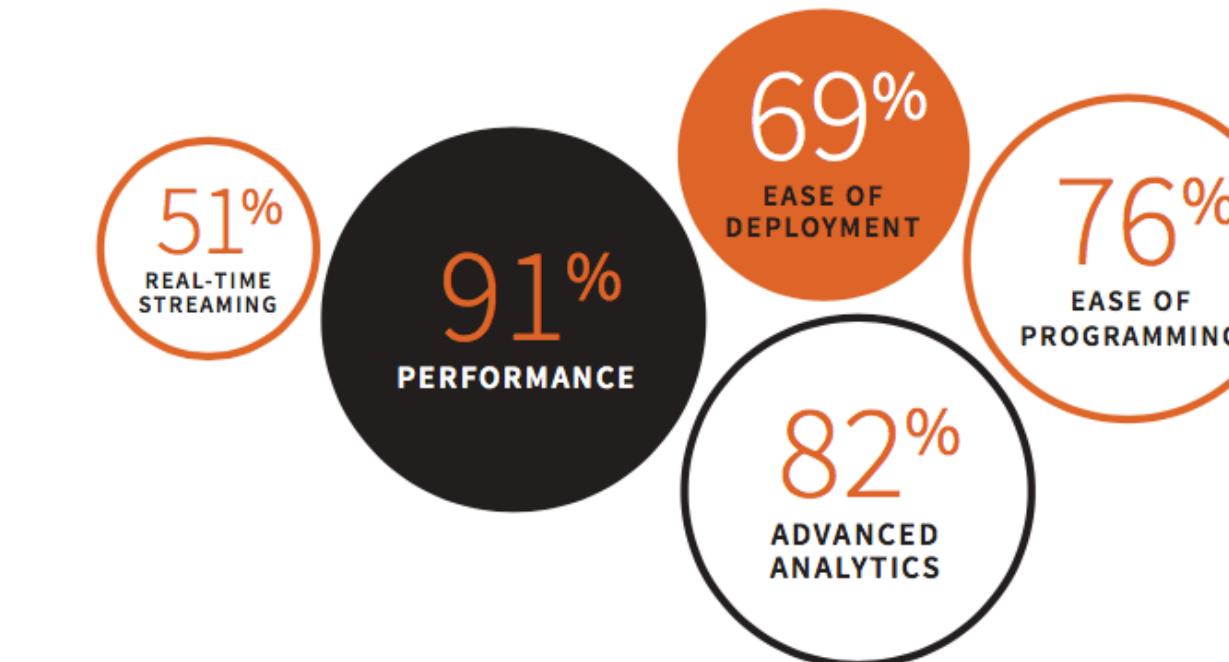
Spark Survey 2015

Spark Survey 2016



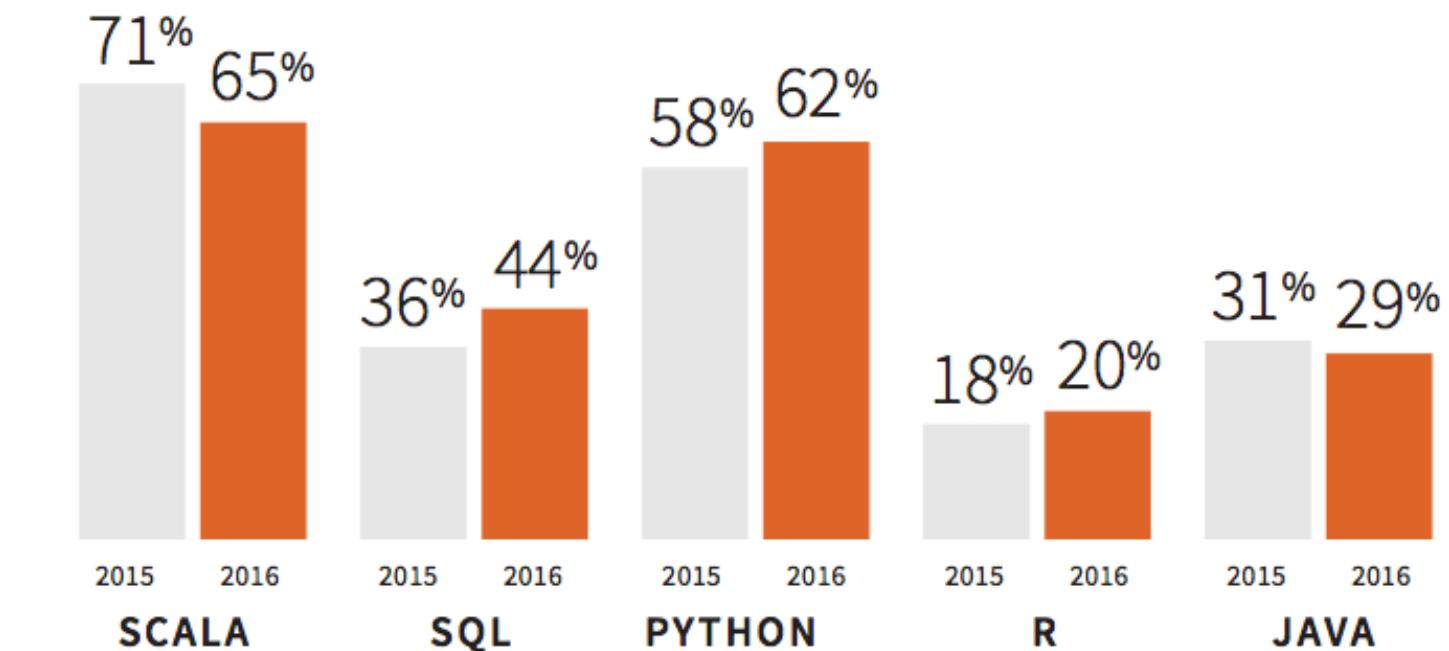
FEATURES USERS CONSIDER IMPORTANT

Respondents were allowed to select more than one feature.



LANGUAGES USED IN APACHE SPARK

Respondents were allowed to select more than one language.



2

Spark vs. MapReduce

Hadoop MapReduce

Spark vs. MapReduce

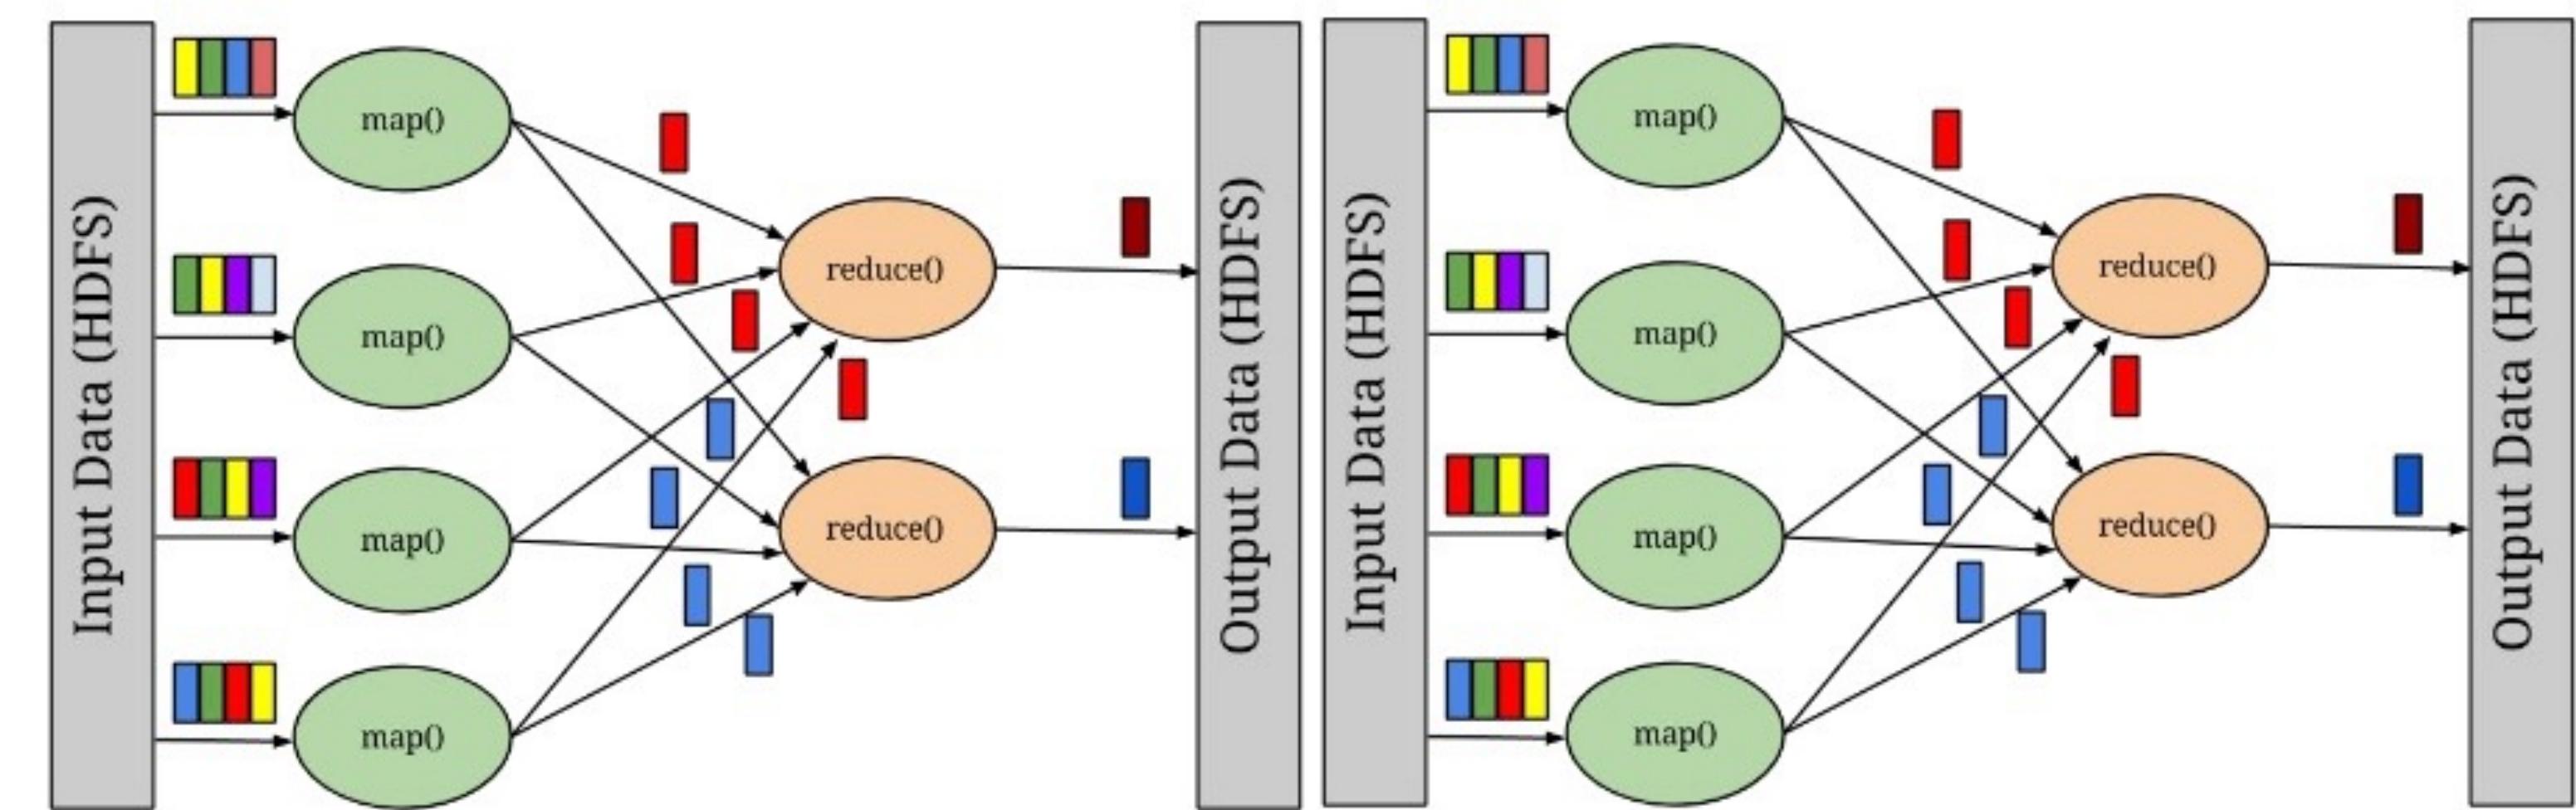
En **2009 et encore en 2014**, l'outil standard pour le traitement des grands volumes de données est **MapReduce** (composant de Hadoop):

- Modèle de programmation popularisé par **Google** (publication en **2004**).
- Une **version open source** est développée dans Hadoop.

Avec MapReduce on code des traitements de données sous forme de **séries de Map et de Reduce**.

Les résultats des Reduce sont **écrits sur HDFS** (système de fichier distribué, utilise les disques durs des machines).

MapReduce Programming Model



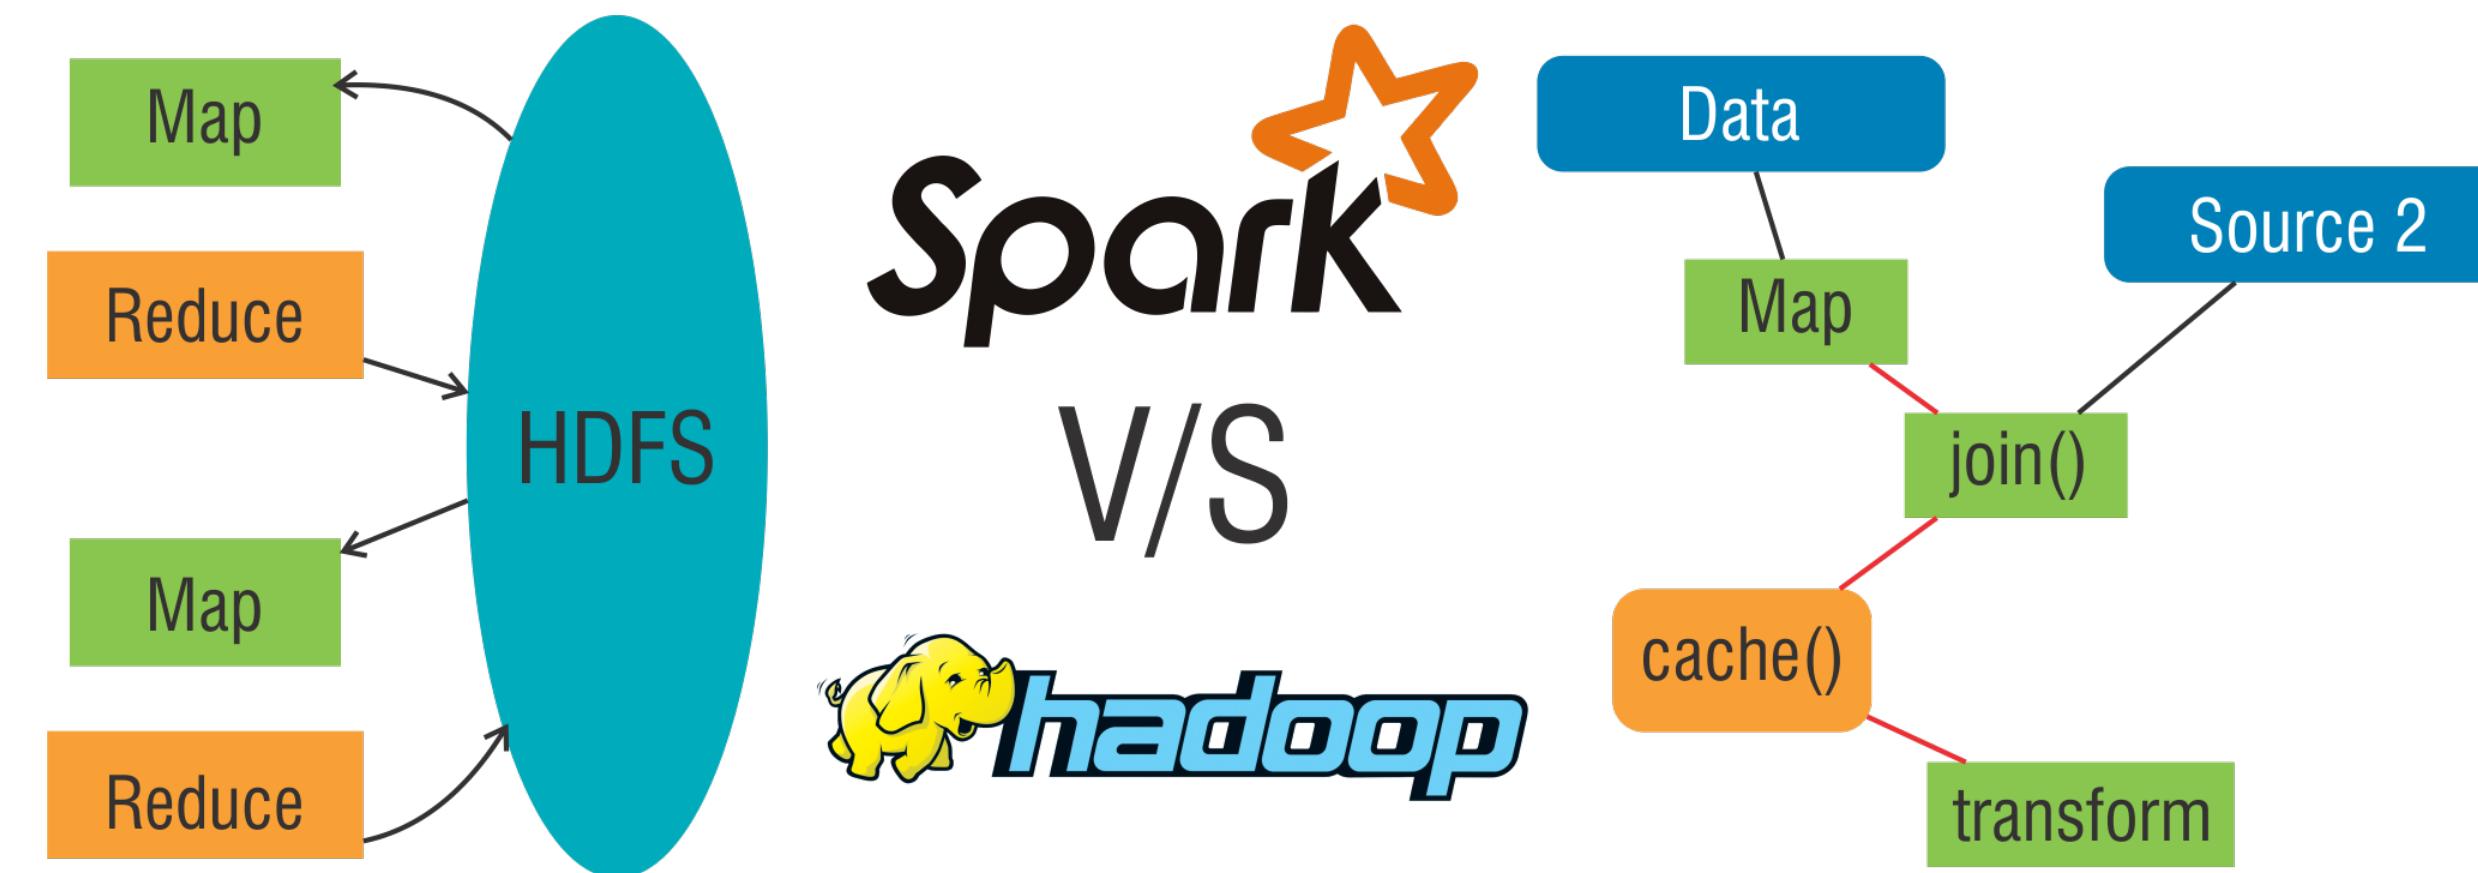
<http://dl.acm.org/citation.cfm?id=1251264>

Limitations de Hadoop MapReduce

Spark vs. MapReduce

Problèmes :

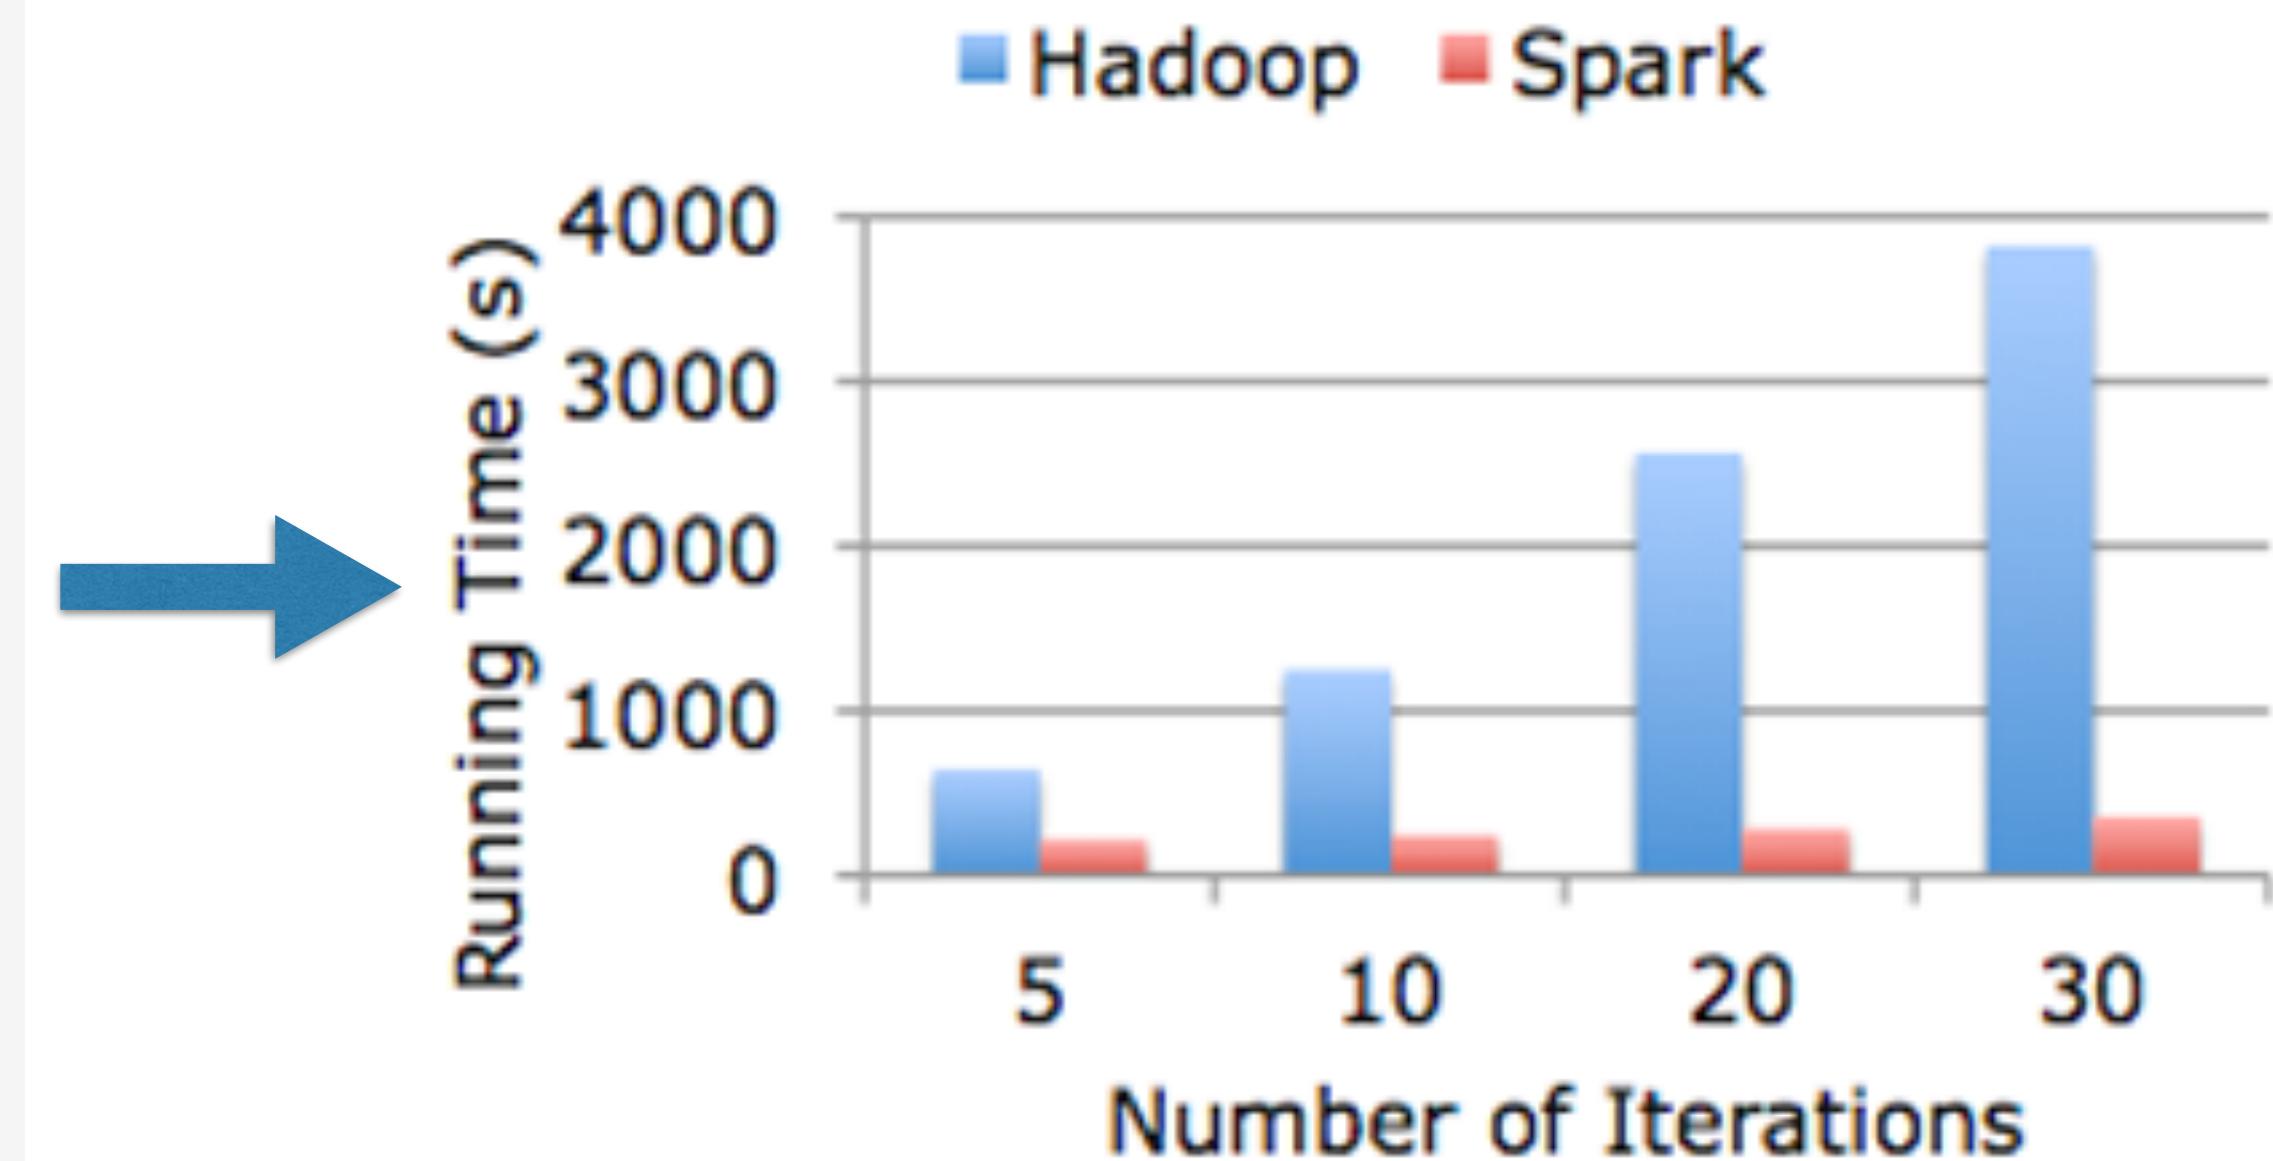
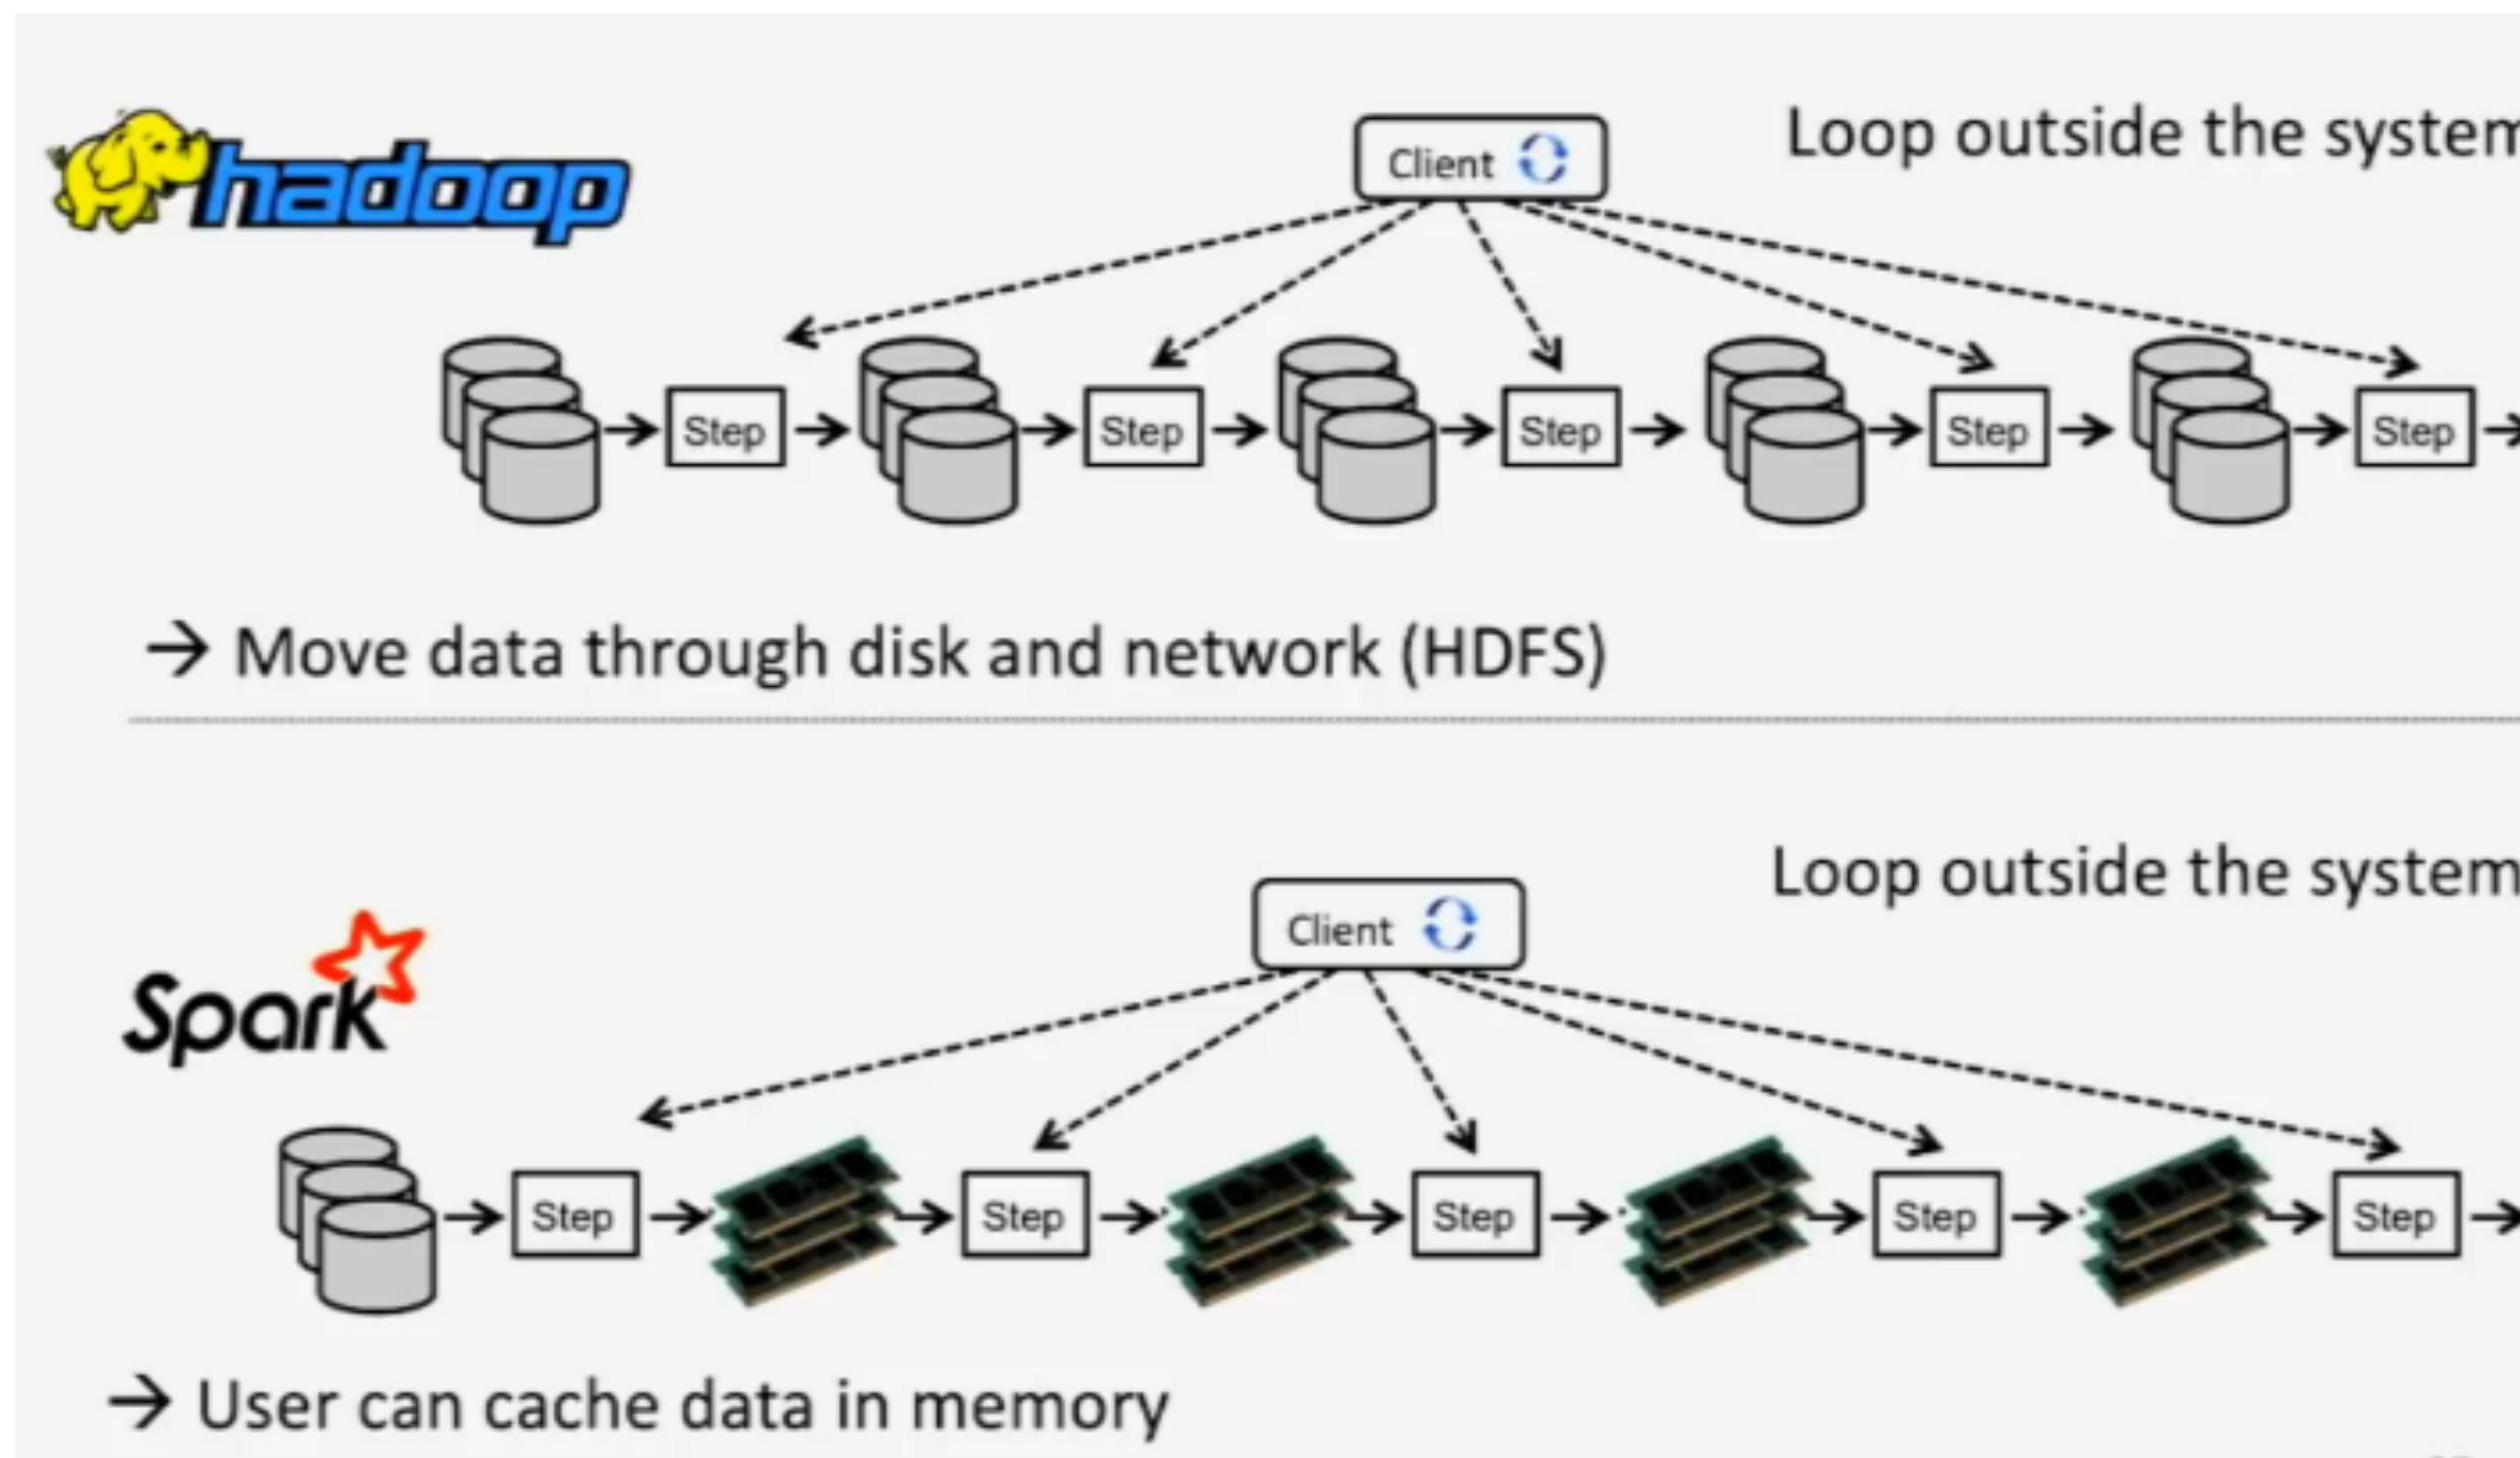
- **Les lectures/écritures de données sur disques** entre chaque étapes d'un job ralentissent les traitements:
 - temps de transfert des données vers les disques
 - temps d'écriture sur disque
 - temps de réplication (données copiées plusieurs fois en cas de panne d'une machine)
- **Le faible nombre d'opérations disponibles :**
 - fonctions Map, Reduce, et très peu d'autres fonctions.
 - le cluster exécute une seule fonction à la fois.



Solution Spark: Mise en cache des données

Spark vs. MapReduce

- Solution proposée par Spark : tirer parti de la RAM, limiter les lectures/écritures sur disque:
- Les données peuvent être mises en cache => **accès plus rapide**.



Le DAG

Directed Acyclic Graph

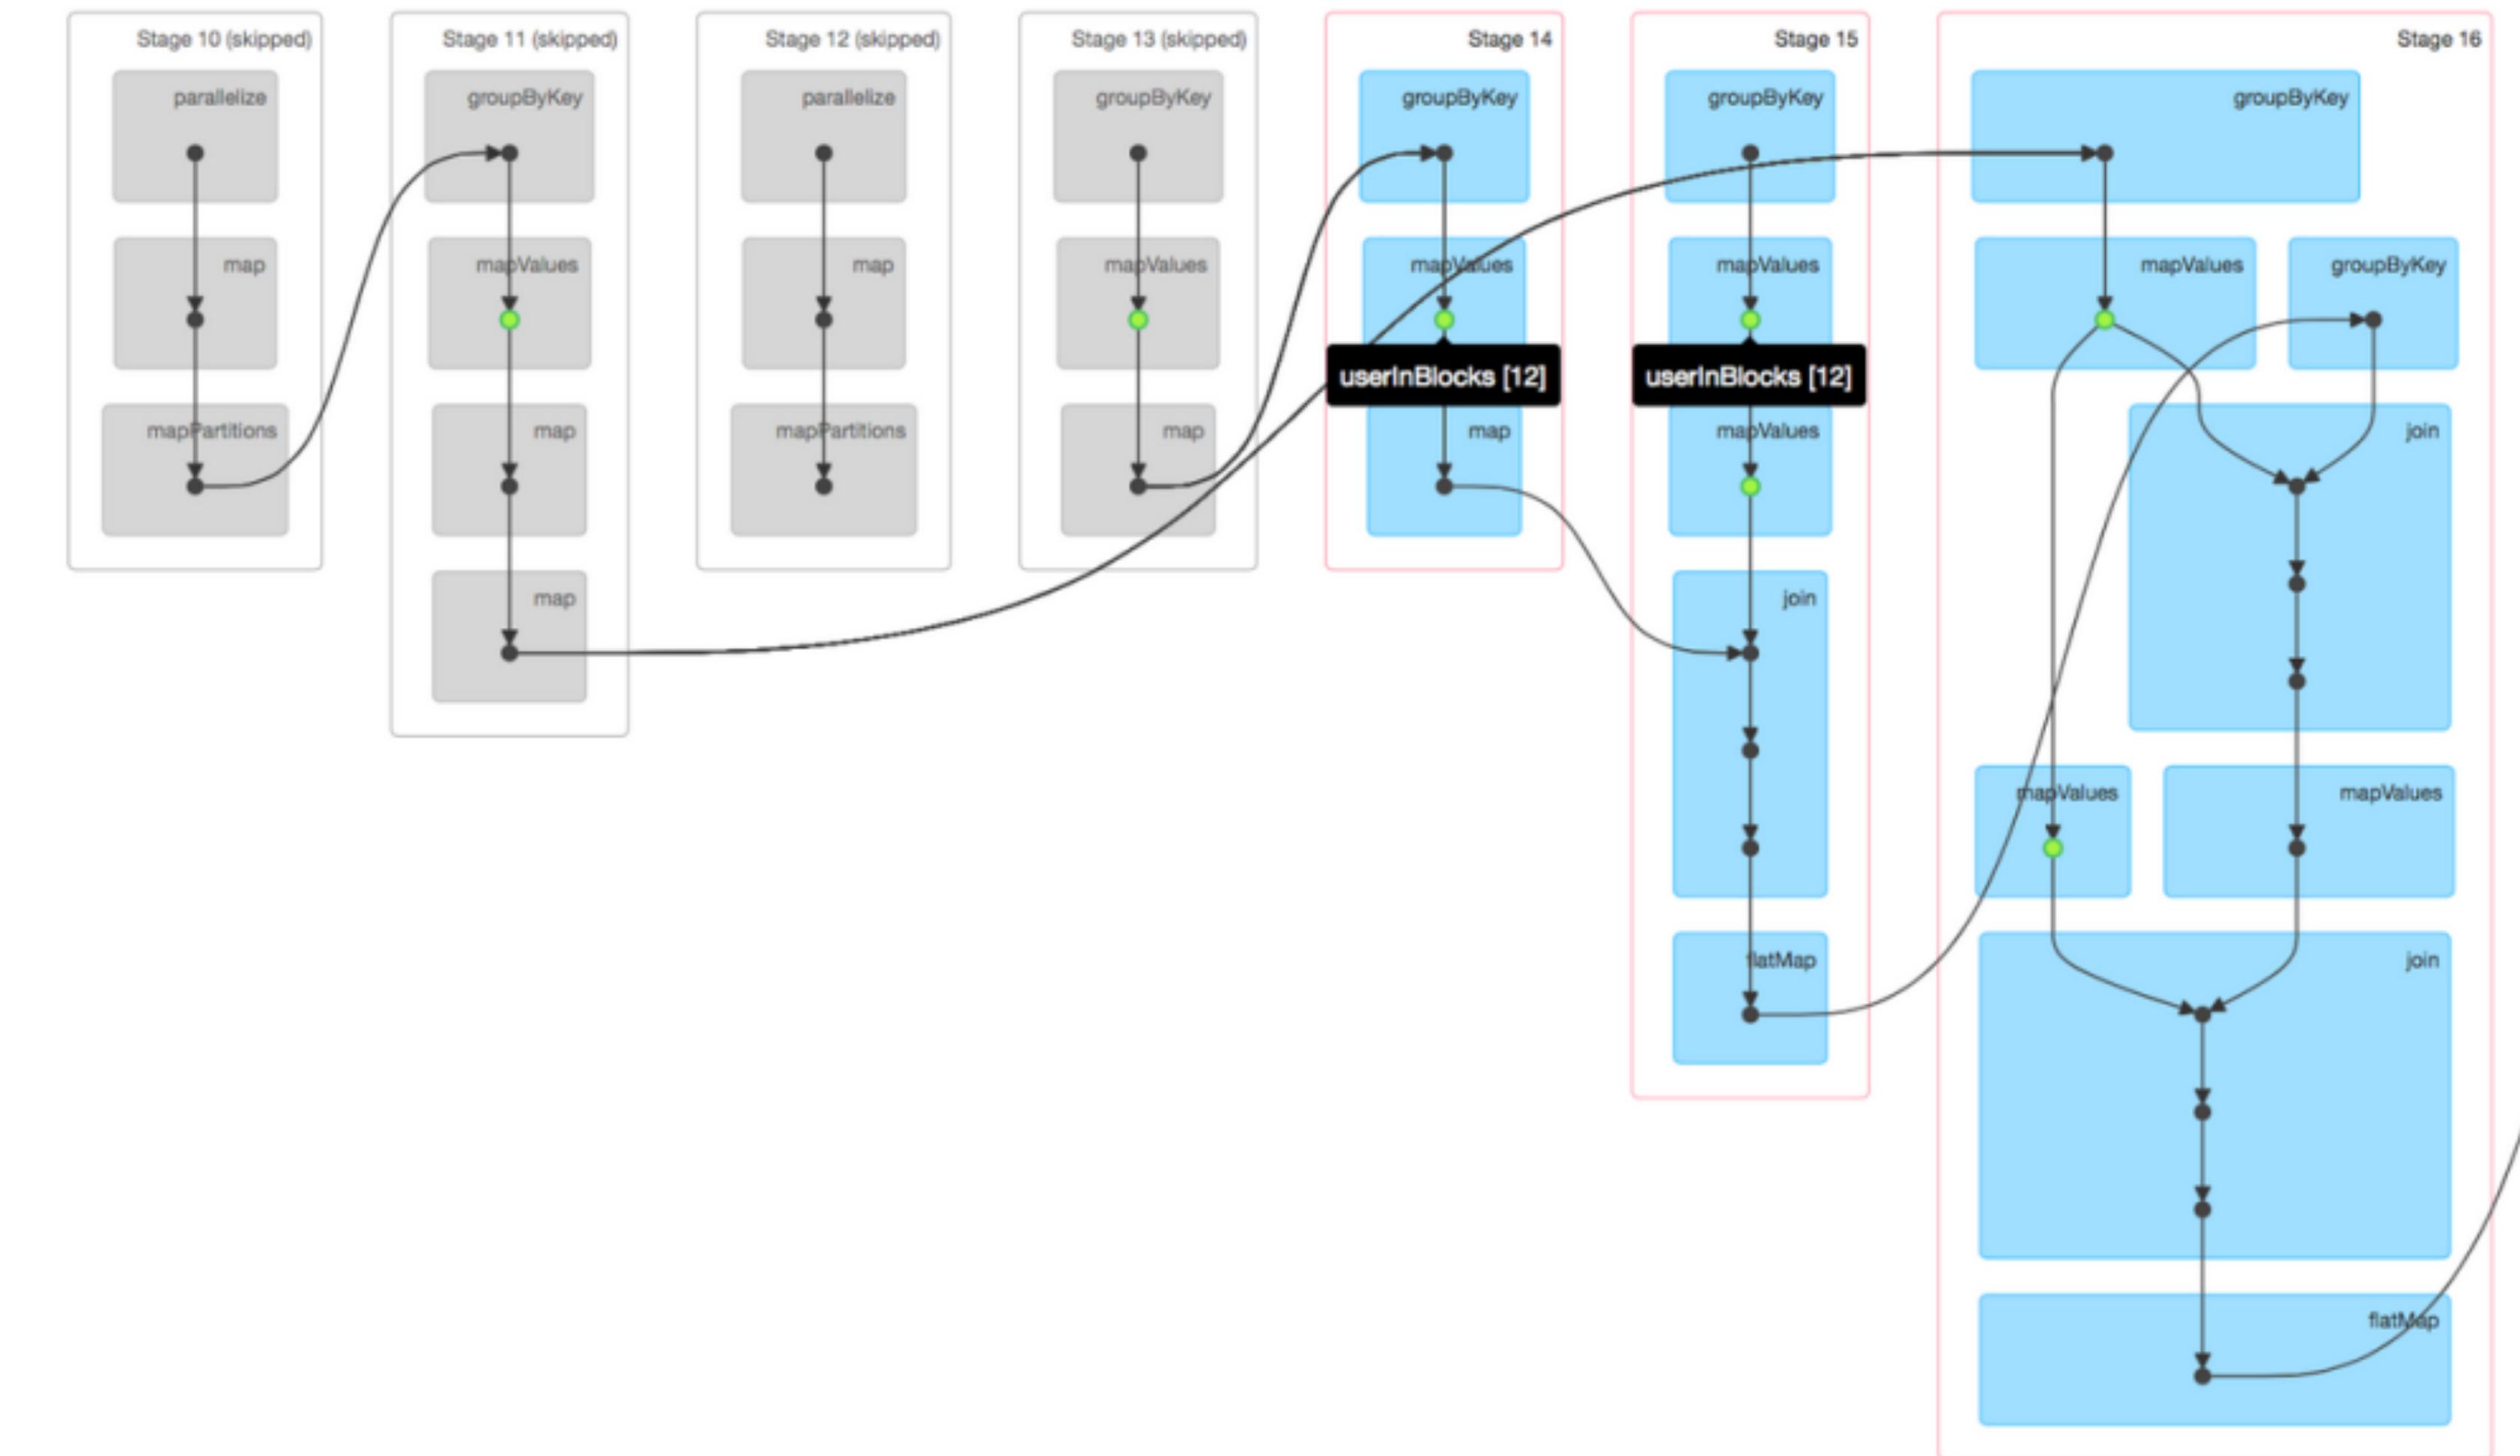
Le **DAGScheduler** permet:

- De découper un script en **Stages** (groupes de tâches qui ne requièrent pas de transfert de données entre les noeuds du cluster, ex: map, filter, ...).
- D'identifier les Stages qui peuvent être exécutés en **parallèle**.
- De déterminer où une tâche doit être exécutée (sur quel exécuteur) pour **minimiser les transferts de données** dans le cluster.
 - ➡ Optimisations du pipeline de traitement des données.
 - ➡ Optimisation de la récupération des données intermédiaires perdues.

Details for Job 4

Status: SUCCEEDED
Completed Stages: 22
Skipped Stages: 4

▶ Event Timeline
▼ DAG Visualization



Facilité de programmation

Exemple du Word Count

Spark

```
val textFile = sc.textFile("hdfs://...")  
val counts = textFile.flatMap(line => line.split(" ")).  
    .map(word => (word, 1))  
    .reduceByKey(_ + _)  
counts.saveAsTextFile("hdfs://...")
```

(En Scala)

→ Adoption massive de Spark !

MapReduce (Hadoop)

```
public class WordCount {  
  
    public static class TokenizerMapper  
        extends Mapper<Object, Text, Text, IntWritable> {  
  
        private final static IntWritable one = new IntWritable(1);  
        private Text word = new Text();  
  
        public void map(Object key, Text value, Context context  
                        ) throws IOException, InterruptedException {  
            StringTokenizer itr = new StringTokenizer(value.toString());  
            while (itr.hasMoreTokens()) {  
                word.set(itr.nextToken());  
                context.write(word, one);  
            }  
        }  
    }  
  
    public static class IntSumReducer  
        extends Reducer<Text, IntWritable, Text, IntWritable> {  
        private IntWritable result = new IntWritable();  
  
        public void reduce(Text key, Iterable<IntWritable> values,  
                          Context context  
                          ) throws IOException, InterruptedException {  
            int sum = 0;  
            for (IntWritable val : values) {  
                sum += val.get();  
            }  
            result.set(sum);  
            context.write(key, result);  
        }  
    }  
  
    public static void main(String[] args) throws Exception {  
        Configuration conf = new Configuration();  
        Job job = Job.getInstance(conf, "word count");  
        job.setJarByClass(WordCount.class);  
        job.setMapperClass(TokenizerMapper.class);  
        job.setCombinerClass(IntSumReducer.class);  
        job.setReducerClass(IntSumReducer.class);  
        job.setOutputKeyClass(Text.class);  
        job.setOutputValueClass(IntWritable.class);  
        FileInputFormat.addInputPath(job, new Path(args[0]));  
        FileOutputFormat.setOutputPath(job, new Path(args[1]));  
        System.exit(job.waitForCompletion(true) ? 0 : 1);  
    }  
}
```

Datasets

(ou Dataframes)

- Structure de données similaire à une table dans une **base de données relationnelle** (ou à une table Excel)
- Les données sont organisées en colonnes typées
- Plusieurs avantages :
 - Aisé à **comprendre**
 - Aisé à **stocker** (optimisations, compression,...)
 - Facilement **distribuable**
- Inconvénients :
 - Fonctionne uniquement sur des **données structurées**

3

Composants

Stack

Composants

Spark SQL

MLlib/ML

Spark Streaming

GraphX

Spark Core

Spark Standalone

Kubernetes

Yarn

Mesos

Storage and Data Sources (HDFS, S3, HBase, Kafka, ...)

- Ce module permet de traiter des **données structurées** (sous forme de table).
- Utilise la structure des données pour optimiser les traitements (façon optimisation de requêtes SQL).
- Les différents moyens d'interagir avec ce module:
 - Requêtes SQL.
 - DataFrames et DataSets.

<http://spark.apache.org/docs/latest/sql-programming-guide.html>

Deux librairies de **machine learning distribué** pour les grands volumes de données.

- MLlib est plus ancien que ML, sera maintenu mais pas développé => **utilisez ML**
- Les DataFrames sont supportés par ML, pas par MLlib (qui supporte uniquement les RDD).
- Outils de **preprocessing** des données (ml.feature)
- Les **algorithmes d'apprentissage** distribués les plus courants sont implémentés dans ml et mllib
(ex: ml.classification, ml.regression, ml.clustering, ml.recommendation)
- Outils de **tuning** des algorithmes (ml.evaluation et ml.tuning)

<https://spark.apache.org/docs/latest/ml-guide.html>

Librairie permettant de traiter en **temps réel** des données

- Pas exactement du streaming mais du **micro-batch**
- Nombreux connecteurs pré-existants (Kafka, Flume, Kinesis, ...)
- Crée des **RDD** à chaque pas de temps et les traite ensuite normalement
- Possibilité de créer des fonctions sur des **fenêtres de temps** (ex : moyenne glissante du nombre de tweets)

<http://spark.apache.org/docs/latest/streaming-programming-guide.html>

<http://spark.apache.org/docs/latest/structured-streaming-programming-guide.html>

Librairie de **calcul distribué sur graphes**.

- Ne supporte que les RDD (pas les DataFrames/DataSets)
- **Uniquement pour les graphes dirigés (construire un graphe non-dirigé oblige à doubler les arêtes)**
- Librairie peu fournie en algorithmes pour l'instant (voir `spark.graphx.lib`)
- Mais toujours en développement ! (voir les derniers commits sur [github](#))

<https://spark.apache.org/docs/latest/graphx-programming-guide.html>

API (Application Programming Interface)

	% utilisation	Commentaires
Scala	65 %	<ul style="list-style-type: none">• Langage typé et compilé• Pas besoin d'interface (Spark est codé en Scala)<ul style="list-style-type: none">• une source de bugs en moins !• plus rapide dans certains cas• API plus rapidement à jour• Usage :<ul style="list-style-type: none">• utilisable en production,• langage utilisé dans de nombreux back-ends
Python	62 %	<ul style="list-style-type: none">• Langage non-typé non-compilé il faut lancer le script pour vérifier qu'il n'y a pas d'erreurs.• Requiert une interface python-scala.• Usage : Python est un langage très utilisé dans la R&D
Java	29 %	<ul style="list-style-type: none">• Langage typé et compilé.• Pas particulièrement d'avantages sur Scala.• Usage: souvent utilisé dans un système déjà développé en Java (legacy)
R	20 %	<ul style="list-style-type: none">• Peu recommandé, trop peu développé

4

Infrastructure

Ecosystème

Infrastructure

Spark SQL

MLlib/ML

Spark Streaming

GraphX

Spark Core

Spark Standalone

Kubernetes

Yarn

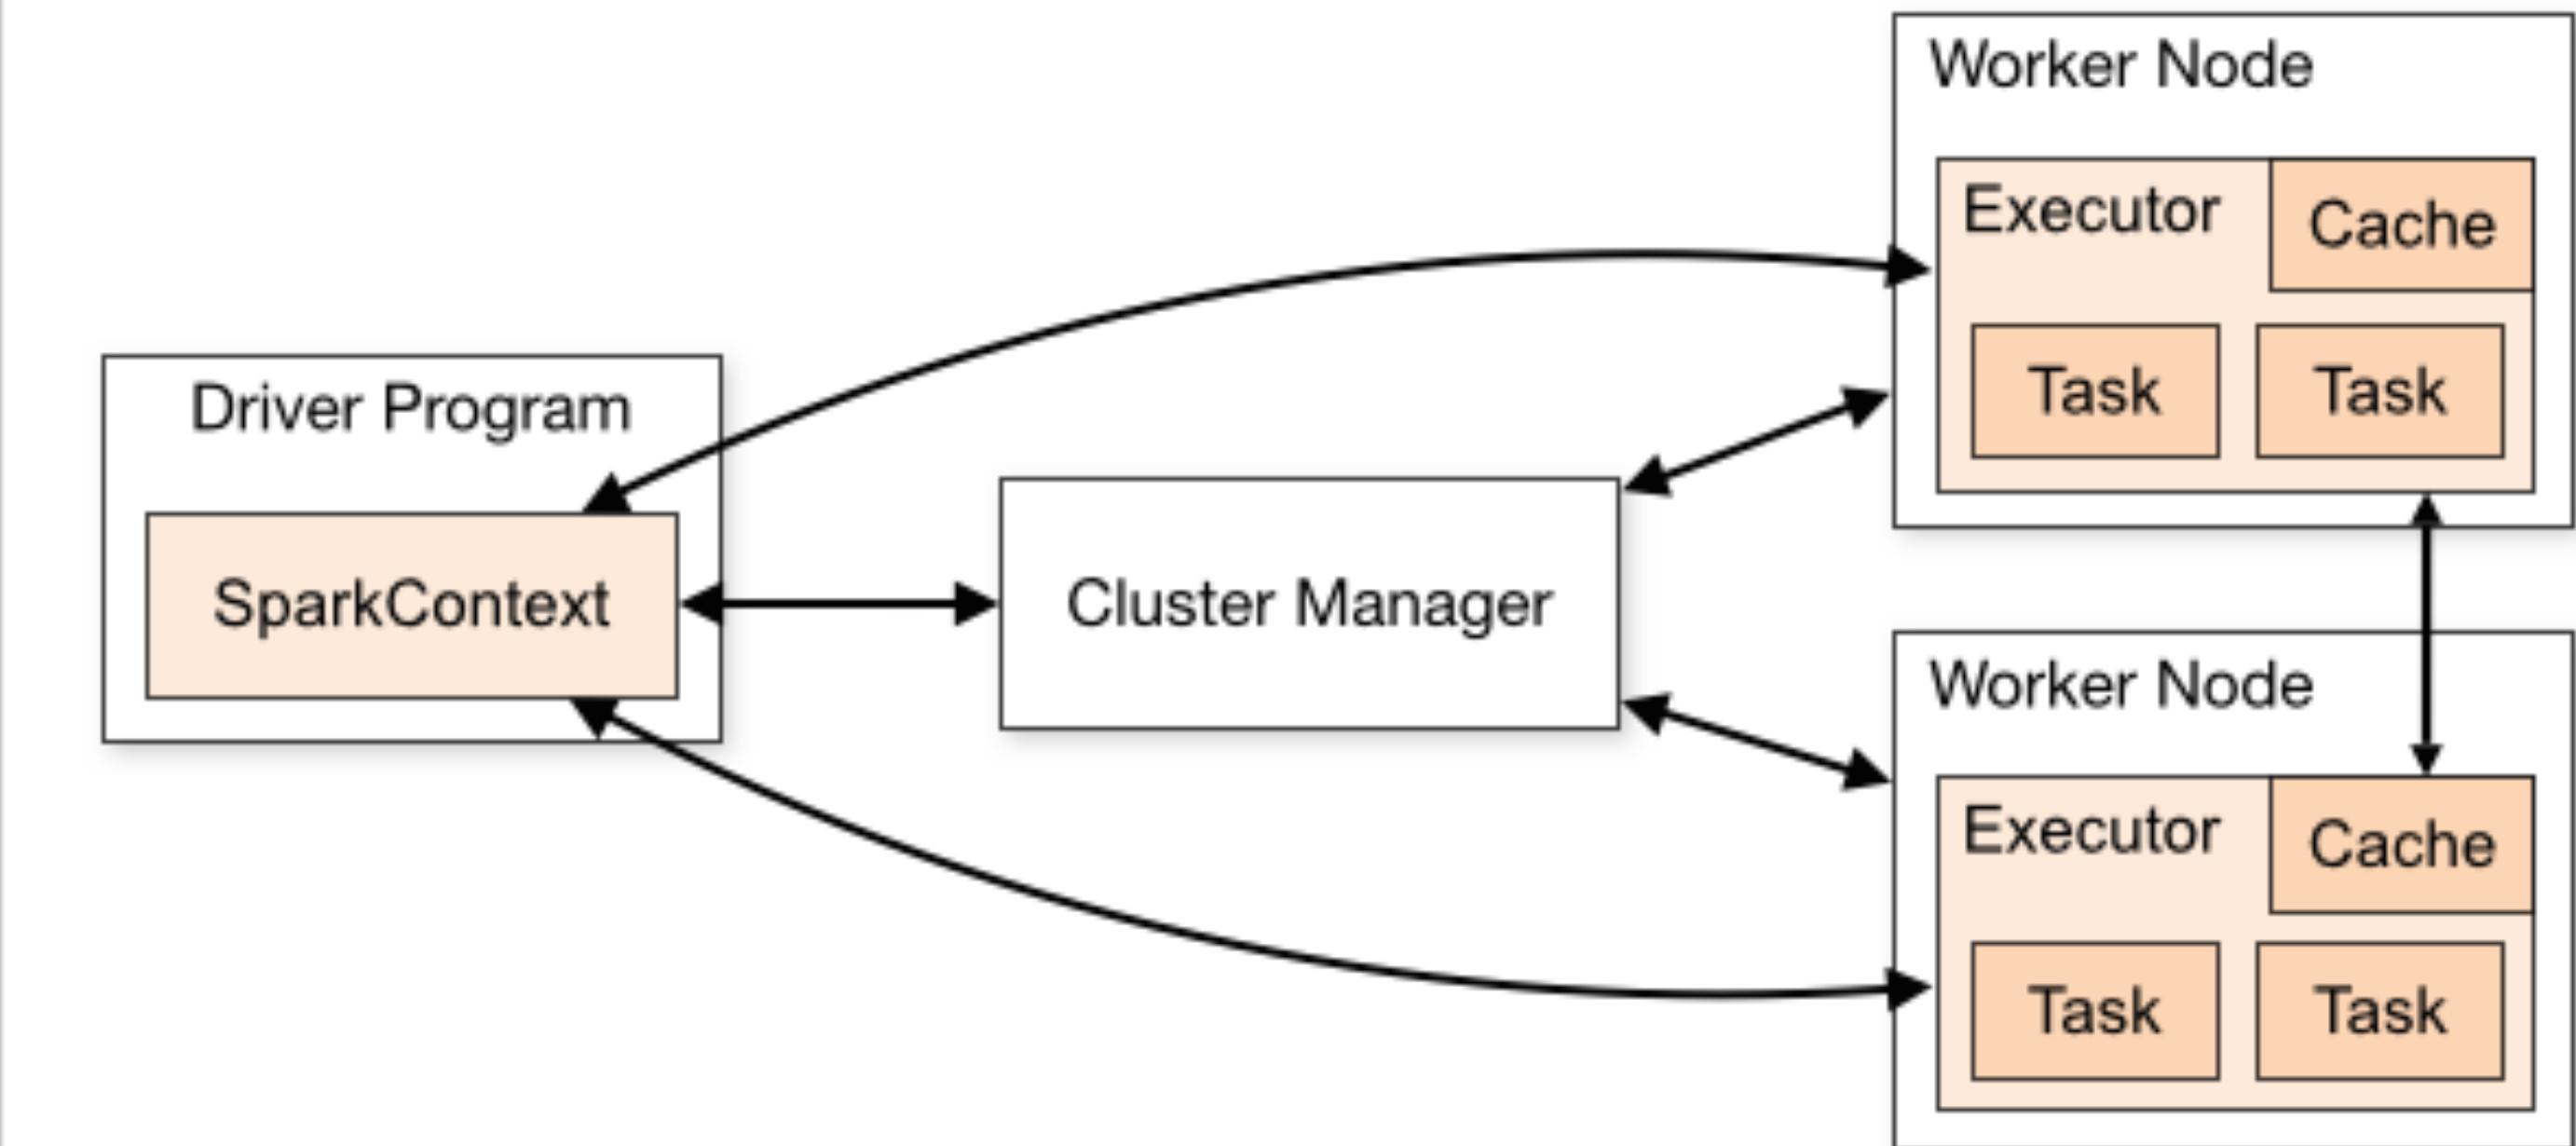
Mesos

Storage and Data Sources (HDFS, S3, HBase, Kafka, ...)

Cluster

Infrastructure

Cluster Hardware	Master node
	Worker node
	Cluster manager
	Driver program
	Executor
	Application
	Job
	Stage
	Task
	Application soumise par l'utilisateur



Cluster

Infrastructure

Component	Description
Cluster manager	Service externe regroupant l'ensemble des ressources du cluster (i.e. standalone manager, Mesos, YARN)
Master node	Noeud sur lequel est installé le cluster manager en mode Standalone
Worker node	Noeud mis à disposition dans le cluster pour faire tourner une application
Driver program	Processus sur lequel tourne le <i>main()</i> de l'application. Il crée le <i>SparkContext</i>
Executor	Processus lancé pour une application sur un <i>Worker node</i> . C'est le processus qui exécute les tâches "lourdes" de l'application et stocke en mémoire les résultats intermédiaires.
Application	Application Spark. Elle est constituée d'un <i>driver</i> et d' <i>executors</i> .
Job	Un calcul parallélisé au sein d'une application consistant en un ensemble de <i>stages</i> menant à une <i>Action</i> (ex : <i>collect</i>)
Stage	Ensemble de <i>tasks</i> interdépendantes (ex : <i>map</i> puis <i>reduce</i>)
Task	Unité de travail distribuée sur un <i>executor</i>

Fault-Tolerance

Infrastructure

Propriété permettant à un système de continuer à **fonctionner normalement** en cas de panne de l'un ou plusieurs de ses composants. L'idée sous-jacente est de ne jamais avoir de **Single Point of Failure** dans le système.

Dans le cas de Spark, cela s'applique à plusieurs parties du système :

- Si un *executor* tombe, le job continue normalement et relance les tâches perdues par l'*executor* perdu.
- Si un *worker* (hardware) vient à disparaître, les *executors* sont perdus (on revient au cas précédent).

High-Availability

Infrastructure

L'**High Availability** est un concept très présent en systèmes distribués. Cela consiste à minimiser la probabilité et le temps de downtime d'un système.

Dans le cas de Spark, il existe plusieurs moyens de renforcer un cluster :

- Plusieurs machines distinctes peuvent jouer le rôle de *cluster manager* (l'une est **active**, les autres sont **passives**)
- Le *cluster manager* peut lancer le driver en mode “**supervise**” auquel cas un driver est automatiquement relancé après crash
- Possibilité de localiser les machines dans différents racks/**availability zones**/data centers pour être résistant à une panne système
- Possibilité de **duplicer** complètement un système **cross-datacenters**

5

Spark Internals

Actions / Transformations

Spark Internals

Actions / Tranfo.

Shuffling

Persistence

Partitionnement

Broadcasting

Jointures

- Les **Transformations** sont des opérations chaînables qui produisent des Datasets à partir de Datasets (ex : drop, filter, select,...).
- Les **Actions** sont des opérations qui retournent des valeurs (ex : count, show, take,...).
- Seules les Actions provoquent le lancement d'un calcul à travers le cluster : il est très important d'en minimiser le nombre.

<https://spark.apache.org/docs/2.0.0/api/scala/index.html#org.apache.spark.sql.Dataset>

- Etape de **redistribution** des données à travers le cluster.
- Plusieurs points négatifs :
 - Souvent très coûteux
 - Nécessite d'écrire sur disque
 - Le **coût augmente** avec la taille du cluster !!
- Best practices :
 - Forcer la mise en **cache** des données
 - Essayer de **partitionner** au mieux les données initiales
 - Evaluer la possibilité d'utiliser du **Broadcasting**

- Opération permettant de **mettre en cache** un DataSet pour une réutilisation future. (opération **persist**)
- Très utile notamment en Machine Learning (nombreuses **itérations**)
- Faire attention cependant à bien vérifier la taille des données (elles doivent tenir en RAM/sur disque et laisser de la place pour les calculs)

Partitionnement

Spark Internals

Actions / Tranfo.

Shuffling

Persistence

Partitionnement

Broadcasting

Jointures

- Manière dont sont découpés les DataSets sur le cluster
- Une **clé de partitionnement** permet de diviser le DataSet, il faut bien la contrôler pour avoir une division correcte.
- Best practices :
 - Avoir environ **10 partitions par cœur**
 - Ne pas avoir de partitions trop petites (ie calculs ~100ms par partition)
 - **Expérimenter** est la seule manière sûre

Broadcasting

Spark Internals

Actions / Tranfo.

Shuffling

Persistence

Partitionnement

Broadcasting

Jointures

- Manière de forcer la mise en cache d'un DataSet en entier sur tous les slaves du cluster
- Best practices :
 - Ne pas le faire avec de trop grosses tables
 - Très utile pour effectuer des **jointures**
 - Compliqué à débugger
- Usage :
 - to create : val broadcastVal = spark.broadcast(val)
 - to access : broadcastVal.value
 - to delete : broadcastVal.unpersist

Jointures

Spark Internals

Actions / Tranfo.

Shuffling

Persistence

Partitionnement

Broadcasting

Jointures

- Similaire aux jointures au SQL (inner, left, right, full)
- Best practices :
 - Si une table est beaucoup plus petite, penser au **broadcasting**
 - Attention aux **collisions** de colonnes
 - Attention aux **multiplications** des lignes

6

Quelques usecases

Ingestion en streaming

Quelques usecases

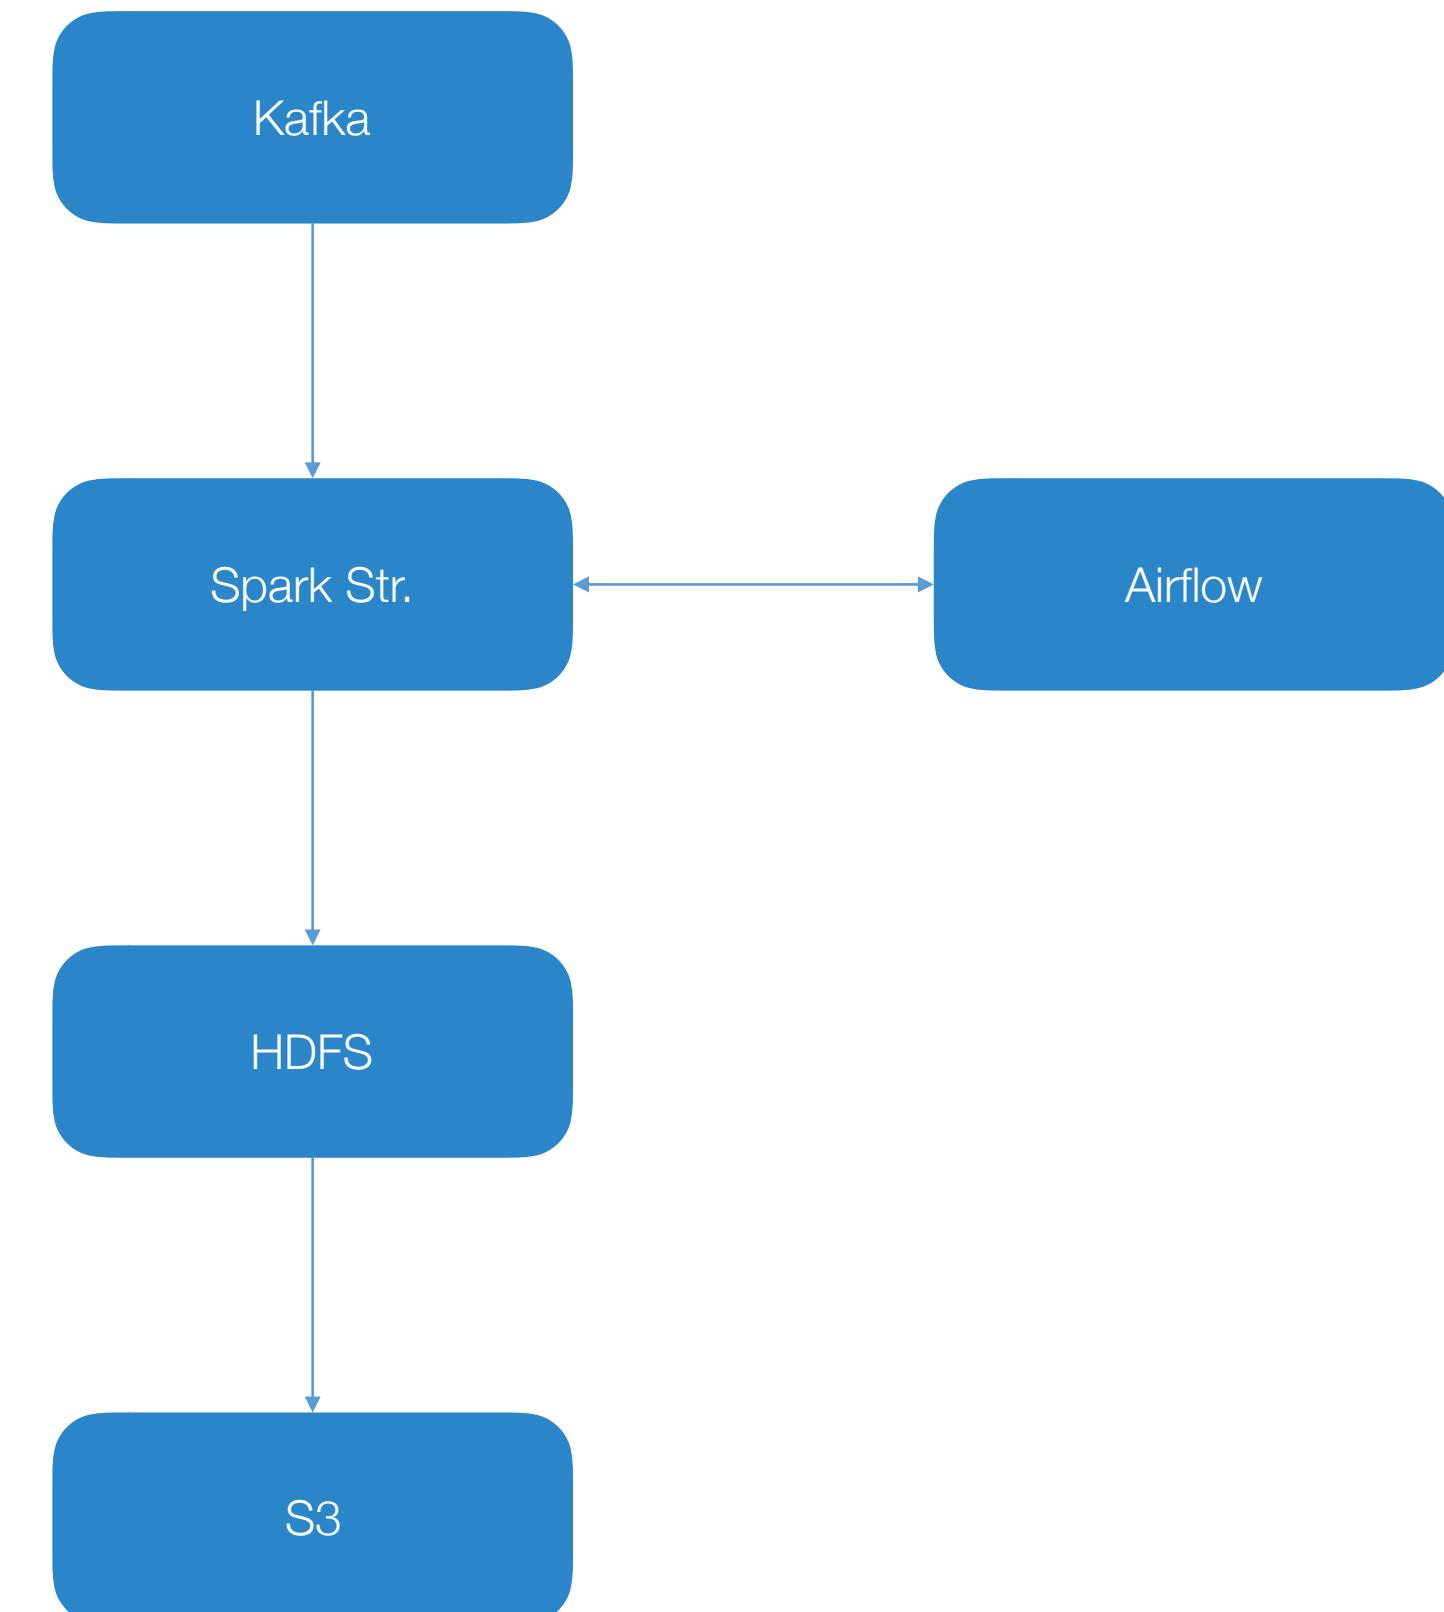
But : Ingestion de données volumineuses en temps réel

Tâches :

- Formatage et normalisation des données
- Création de partitions à l'écriture
- Optimisation de la taille des fichiers
- Stockage en format Parquet

Spécificités :

- Time windows de 30s
- Stockage temporaire dans HDFS puis dans S3
- Airflow pour monitorer le cluster



Segmentation d'utilisateurs : socio-démo

Quelques usecases

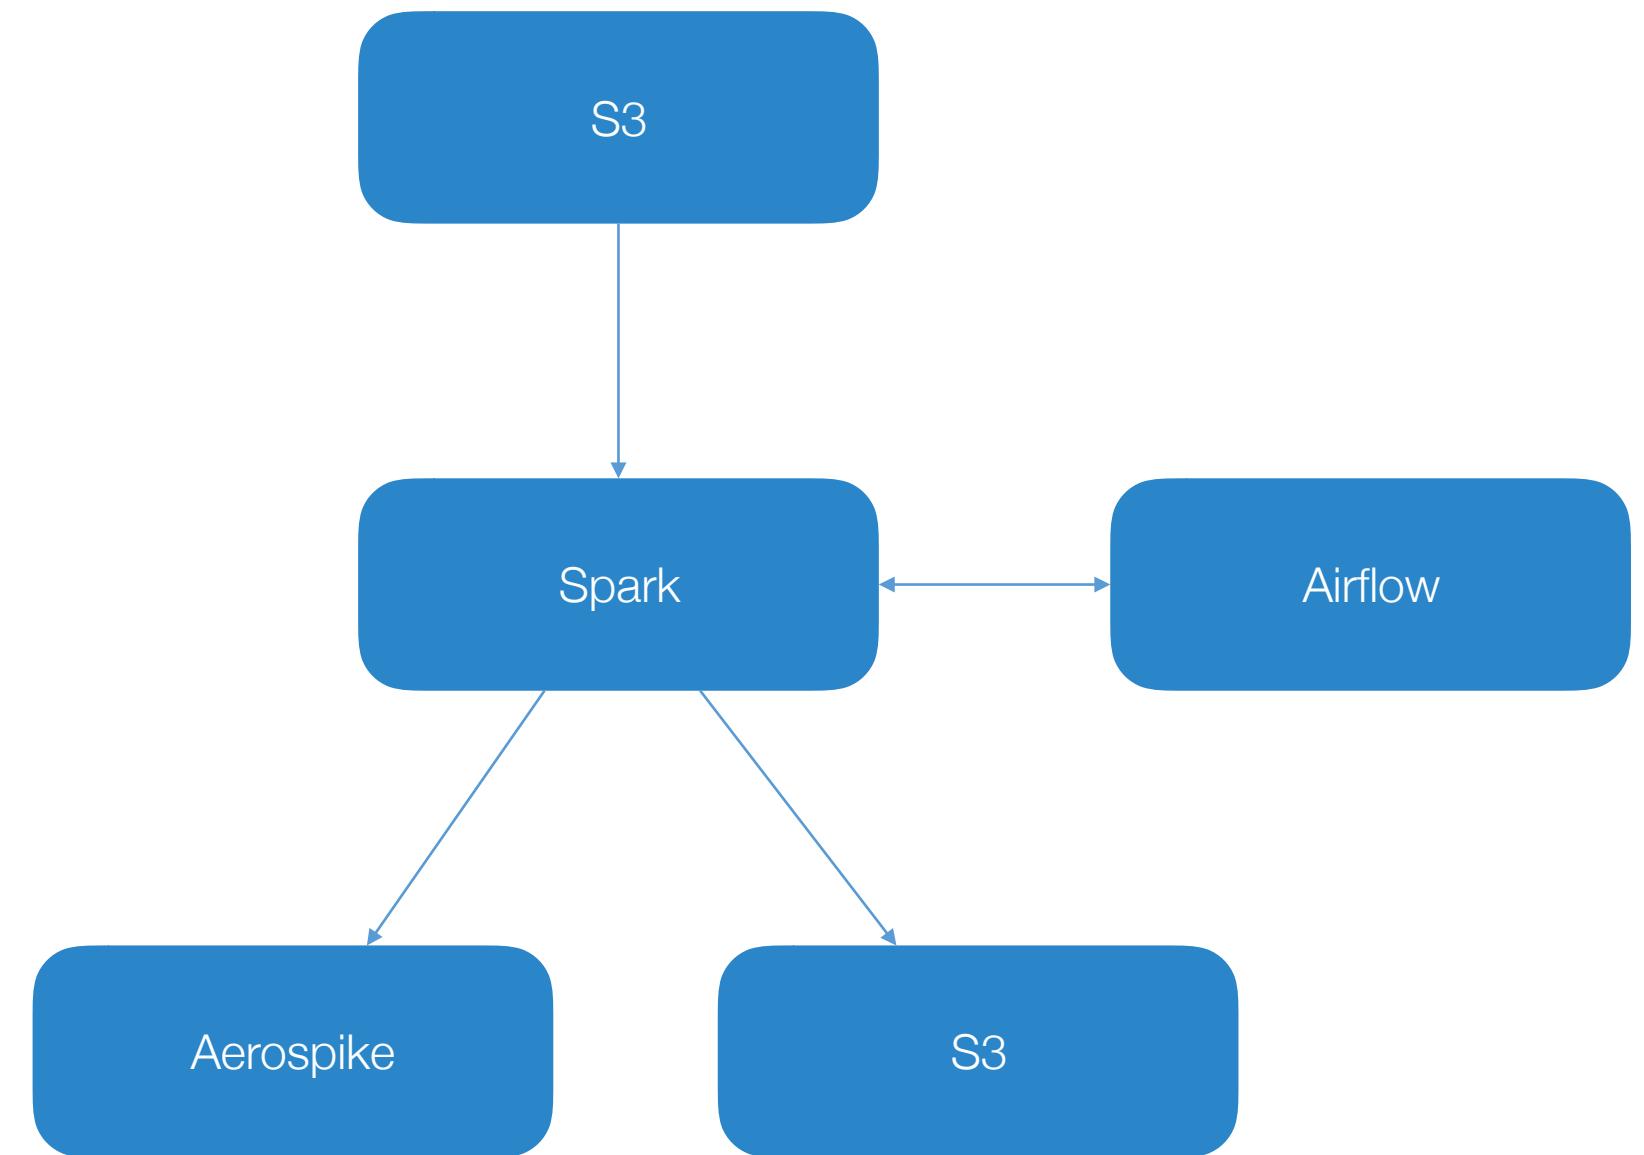
But : Estimer le genre, l'âge et la CSP d'utilisateurs

Tâches :

- Déterminer et construire l'ensemble des features nécessaires
- Tester différents types de classification supervisée
- Mise à disposition de ces segments d'utilisateurs pour les équipes opérationnelles

Spécificités :

- > 10k features (navigation, device, timestamps,...)
- Update quotidien de la base



Segmentation d'utilisateurs : tags thématiques (1/2)

Quelques usecases

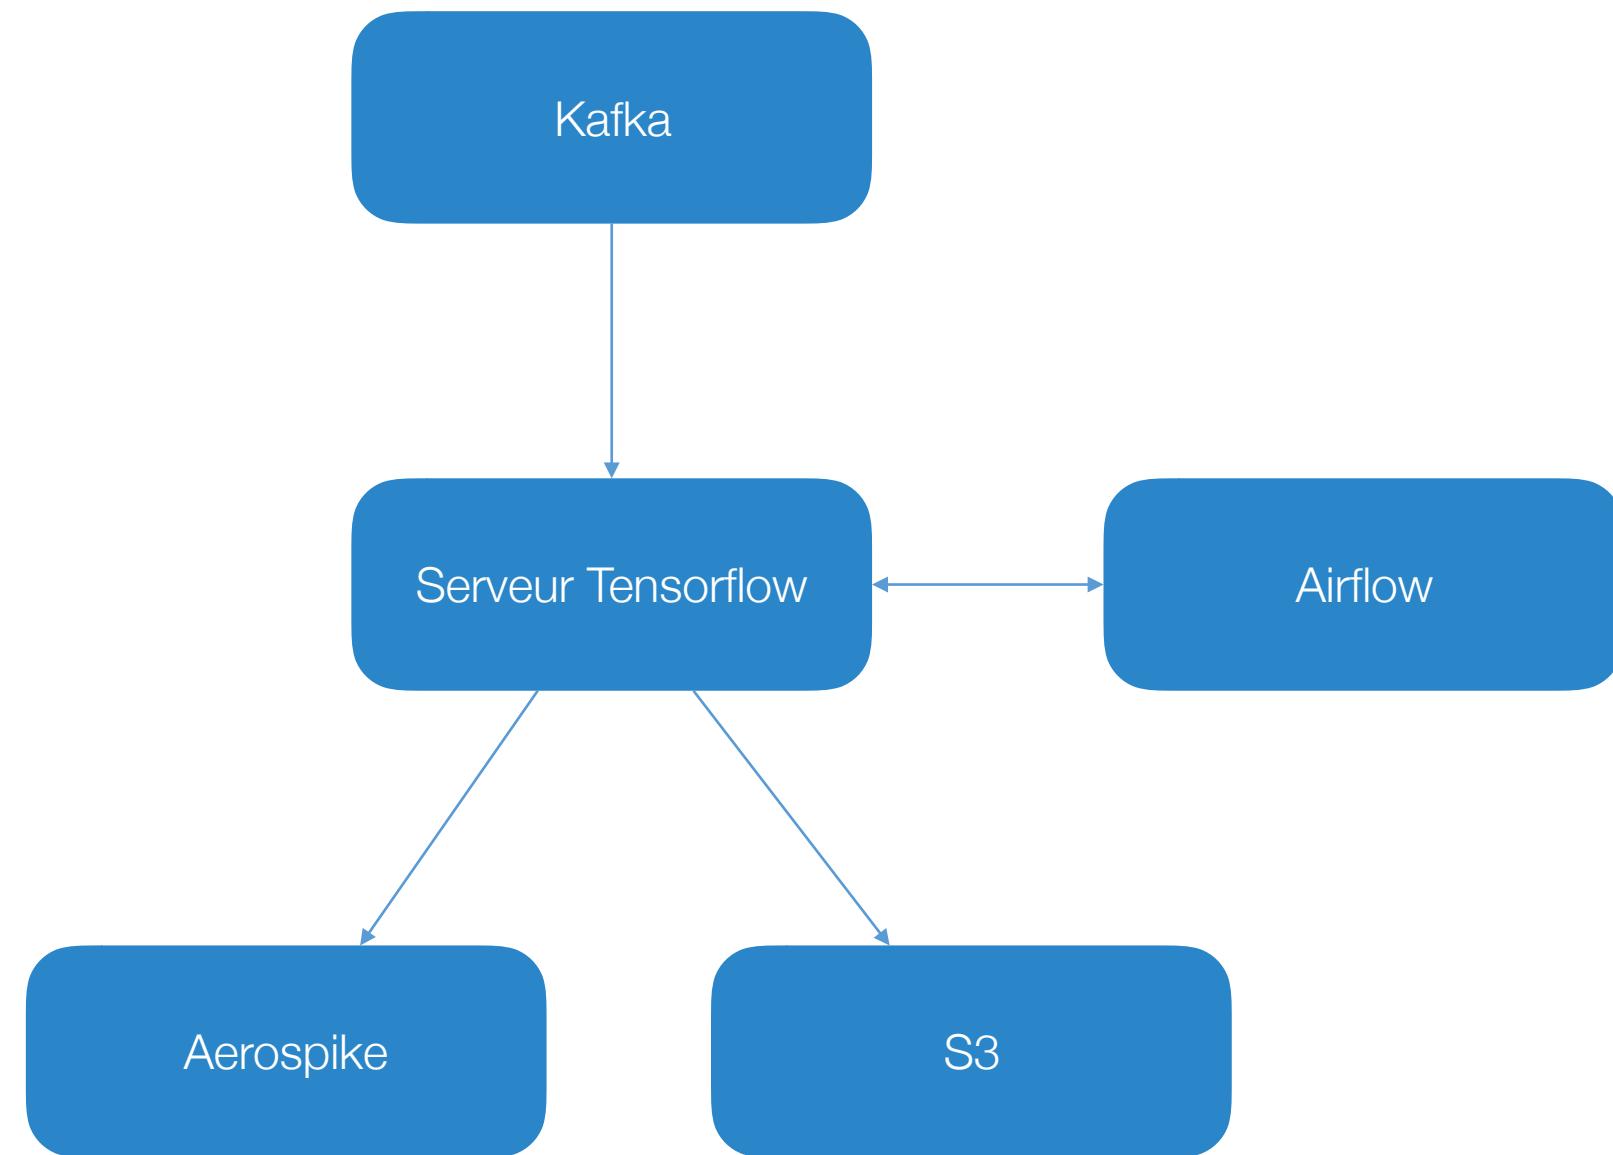
But : Classification de contenu web sur une liste de tags donnés

Tâches :

- Pour chaque URL reçue, utiliser un modèle pré-entraîné pour lui associer des tags

Spécificités :

- Modèles de NLP entraînés sur [Keras/Tensorflow](#) (réseaux de neurones à une couche cachée)
- Modèle ré-entraîné périodiquement
- Classification de plus de [10M urls](#) par jour



Segmentation d'utilisateurs : tags thématiques (2/2)

Quelques usecases

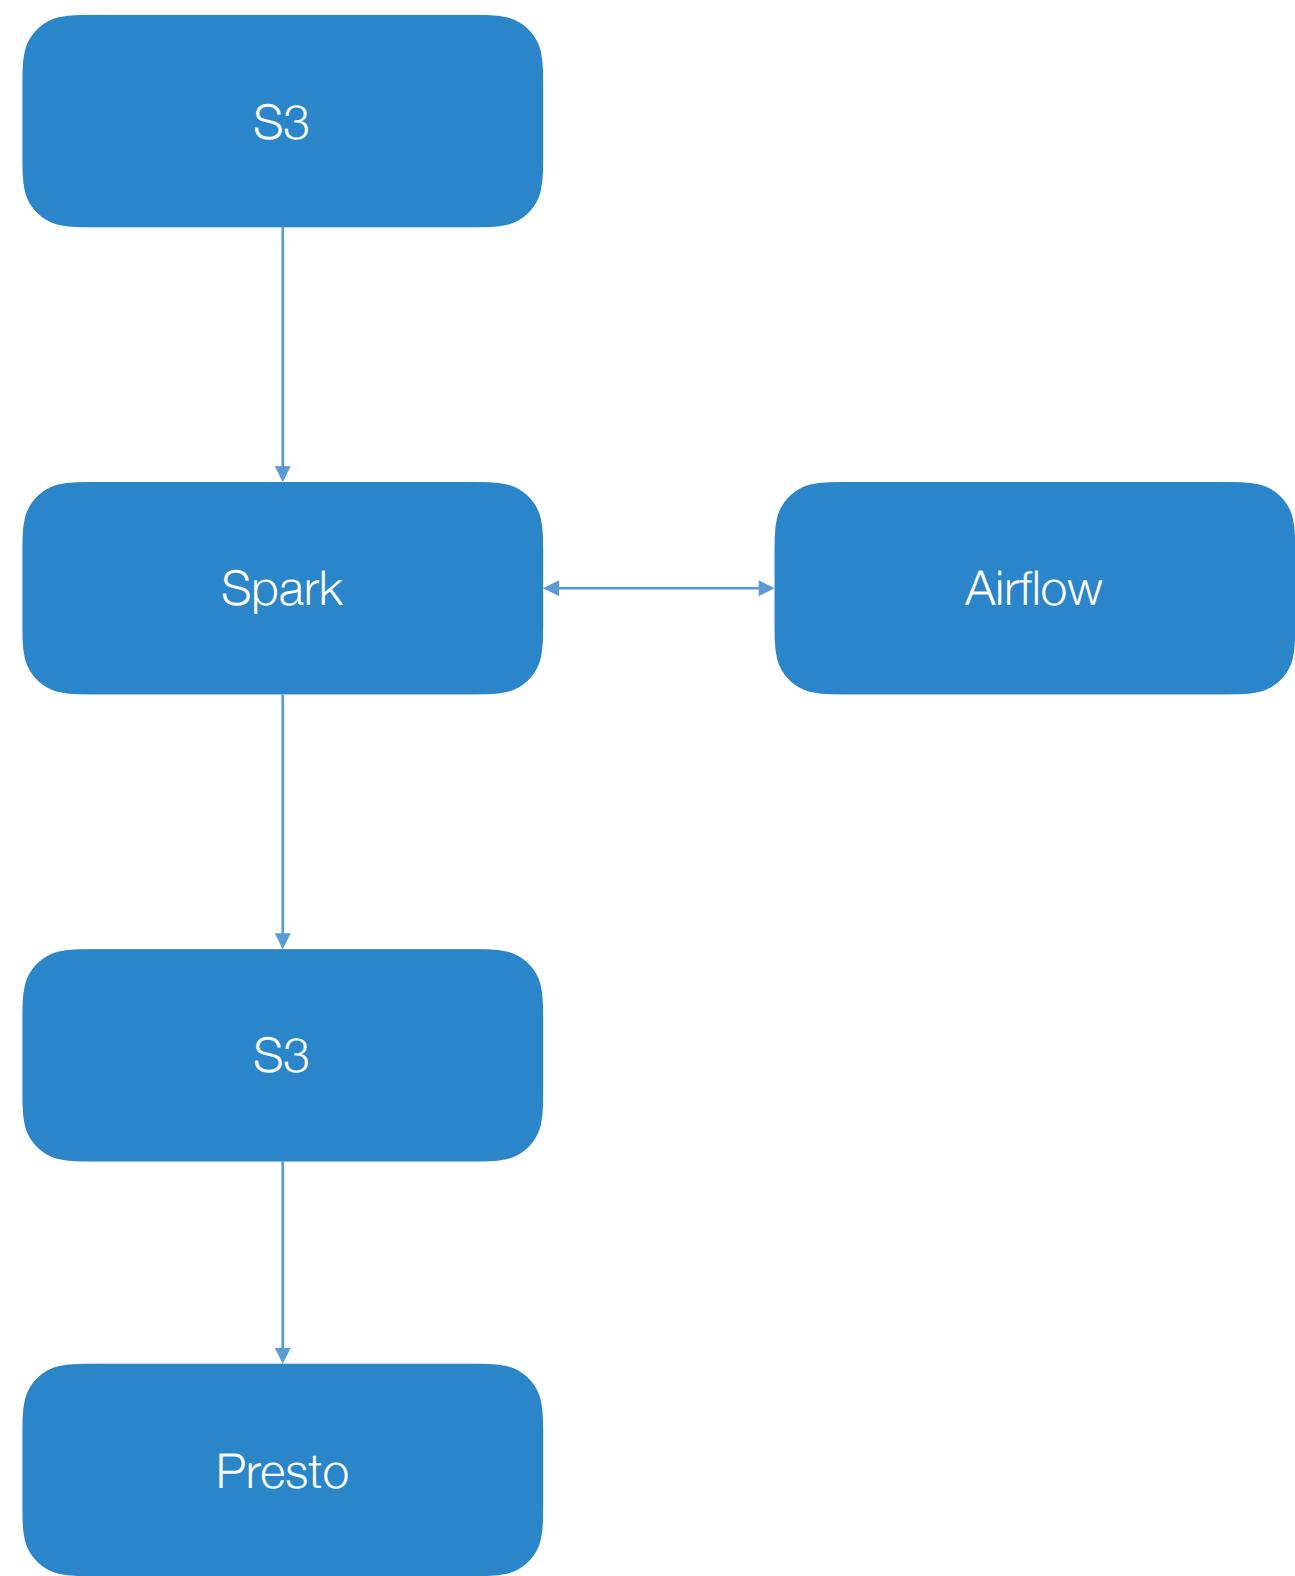
But : Associer des affinités entre des utilisateurs et des tags thématiques

Tâches :

- Mettre à jour quotidiennement notre matrice d'affinité utilisateurs/tags pour des besoins de segmentation

Spécificités :

- Environ 400M utilisateurs et 4000 tags
- Différents niveaux de hiérarchie dans les tags
- Notion temporelle pour calculer l'affinité



Algorithme cross-device

Quelques usecases

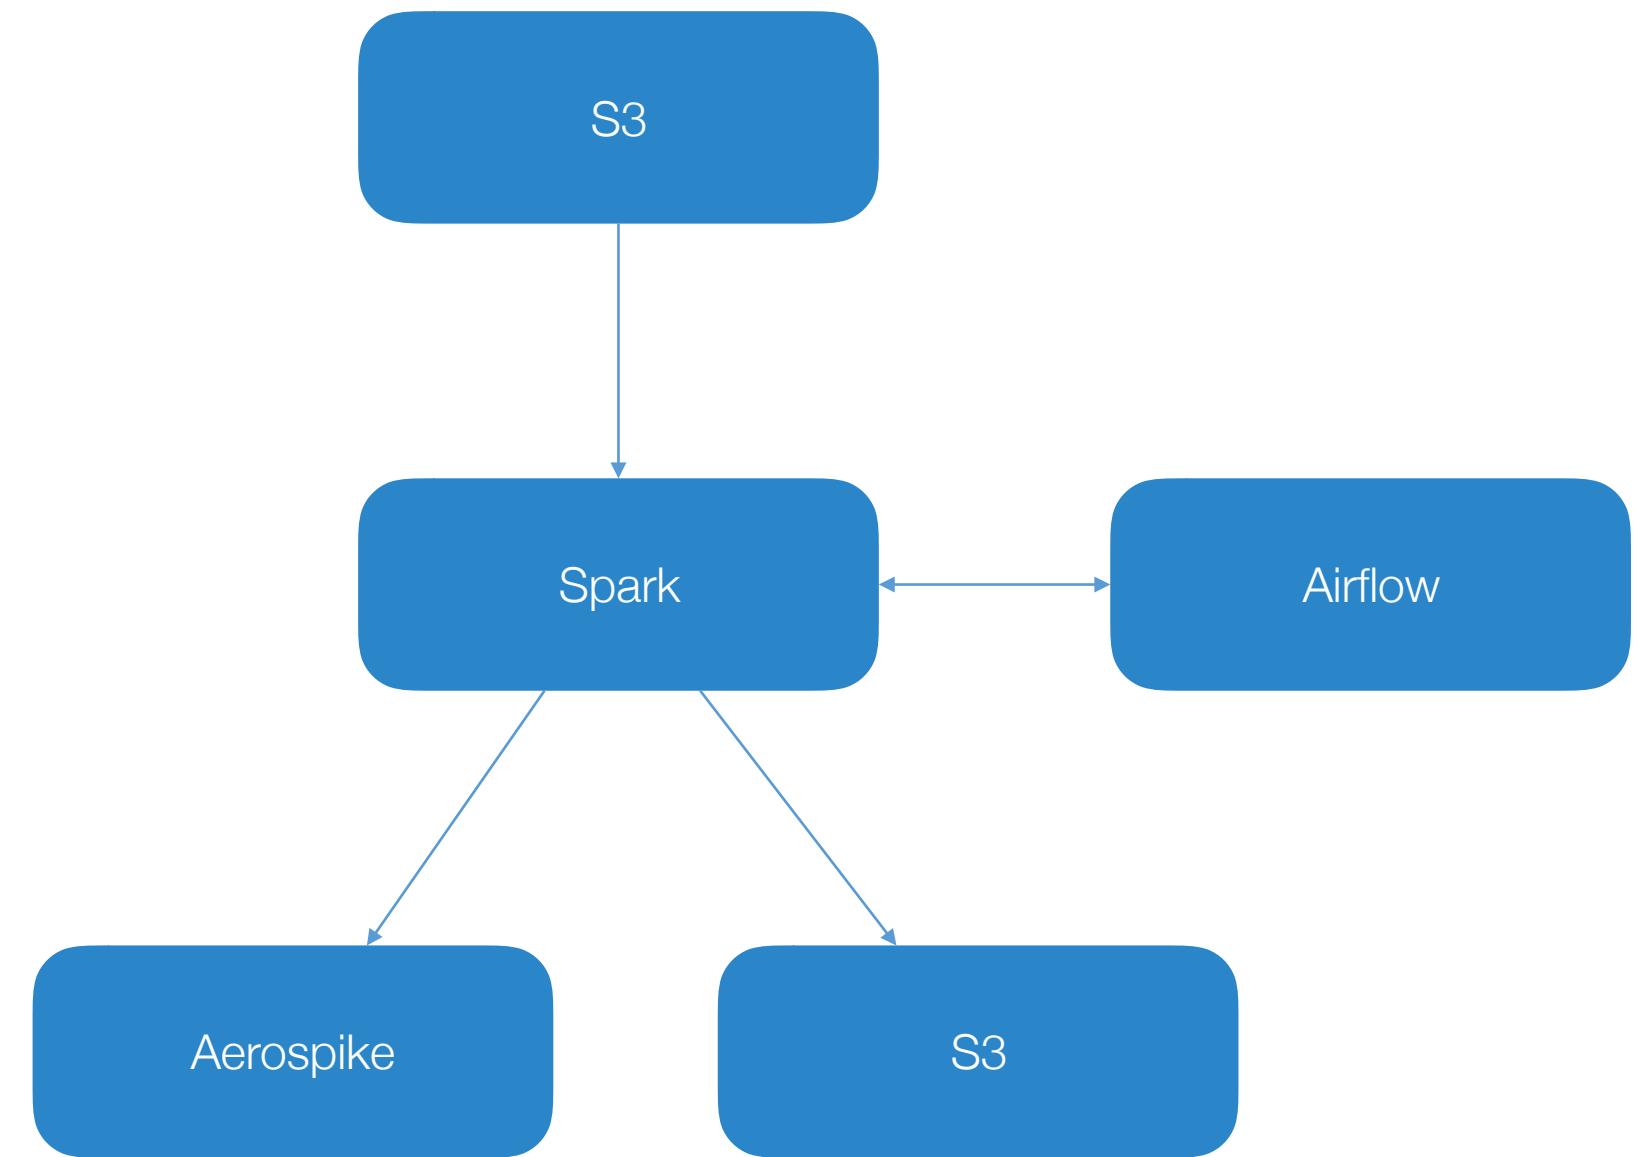
But : Associer ensemble les différents appareils d'une même personne

Tâches :

- Déterminer et construire un “device-graph” à partir de données déterministes en 2 étapes :
 - Construction d'un graphe d'interactions via les addresses IP et isolation des couples potentiels
 - Développement d'un algorithme de scoring supervisé pour déterminer si les 2 ids appartiennent bien à une même personne

Spécificités :

- Set de données déterministes conséquent
- > 100k features (navigation, device, timestamps, IP, ...)
- Update mensuel de la base



7

Bibliographie

Scala

Bibliographie

- Une vidéo pour débuter : <https://databricks.com/session/just-enough-scala-for-spark>
- Le repo GitHub associé : <https://github.com/deanwampler/JustEnoughScalaForSpark>
- Quelques bouquins :
 - Programming in Scala : http://ccfit.nsu.ru/~den/Scala/programming_in_scala_2nd.pdf
 - Essential Scala : <https://underscore.io/books/essential-scala/>
- Le MOOC de M. Odersky, Functional programming in Scala : https://courseware.epfl.ch/courses/course-v1:EPFL+progfun1+2018_T1/about
- Guidelines : <http://www.lihaoyi.com/post/StrategicScalaStylePrincipleofLeastPower.html>

Spark

Bibliographie

- Pour débuter :
 - Learning Spark : pas dispo gratuitement
 - Fast Data Processing with Apache Spark : pas dispo gratuitement
 - La doc Spark ! : <https://spark.apache.org/docs/2.3.1/>
- Quelques MOOCs :
 - Big Data Analysis with Scala and Spark : <https://courseware.epfl.ch/courses/course-v1:EPFL+scala-spark-big-data+2018-T1/about>
 - Big Data Analysis with Apache Spark : <https://www.edx.org/course/big-data-analysis-apache-spark-uc-berkeleyx-cs110x>

Python

Bibliographie

- Pour débuter :
 - The Hitchhiker's guide to Python : <https://docs.python-guide.org/>
 - Intro to Pandas and Jupiter notebooks : <https://www.youtube.com/watch?v=5JnMutdy6Fw>
 - Pandas in a nutshell : <http://kanoki.org/2017/07/16/pandas-in-a-nutshell/>
- Pour avancer :
 - Python for Data Analysis : <http://opencarts.org/sachlaptrinh/pdf/28232.pdf>
 - The little book of Python anti-patterns : <https://docs.quantifiedcode.com/python-anti-patterns/index.html>
 - Construire une API avec Flask : <http://flask.pocoo.org/docs/0.12/>